



Politechnika Wrocławskiego

Wydział Matematyki

Kierunek studiów: Matematyka stosowana

Specjalność: –

Praca dyplomowa – inżynierska

MATEMATYCZNA ANALIZA KONFLIKTÓW ZBROJNYCH

Yana Negulescu

słowa kluczowe:
Konflikty zbrojne, Matematyczne modelowanie, Analiza ilościowa, Regresja wielowymiarowa, Konflikty międzynarodowe, Prognozowanie konfliktów

krótkie streszczenie:

Praca analizuje konflikty zbrojne z wykorzystaniem modelu J. Davida Singera, opartego na regresji wielowymiarowej. Model Singera bada wpływ koncentracji mocy, jej redystrybucji i zmienności w systemie międzynarodowym na prawdopodobieństwo konfliktów. Przeprowadzona analiza obejmuje empiryczną ocenę modelu oraz jego adaptację do współczesnych danych. Wyniki umożliwiają lepsze zrozumienie dynamiki konfliktów i wspierają strategie ich minimalizacji.

Opiekun pracy dyplomowej	dr Tomasz Stroiński
	Tytuł/stopień naukowy/imię i nazwisko	ocena	podpis

*Do celów archiwalnych pracę dyplomową zakwalifikowano do:**

- a) kategorii A (akta wieczyste)
- b) kategorii BE 50 (po 50 latach podlegające ekspertryzje)

* niepotrzebne skreślić

pieczętka wydziałowa

Wrocław, rok 2025



Faculty of Pure and Applied Mathematics

Field of study: Applied Mathematics

Specialty: –

Engineering Thesis

MATHEMATICAL ANALYSIS OF ARMED CONFLICTS

Yana Negulescu

keywords:

Armed conflicts, Mathematical modeling,
Quantitative analysis, Multivariate regression,
International conflicts, Conflict forecasting

short summary:

This thesis focuses on the mathematical analysis of armed conflicts using J. David Singer's model, based on multivariate regression. Singer's model examines the influence of power concentration, its changes, and movements within the international system on conflict probability. The analysis includes an empirical evaluation of the model as well as its adaptation to modern data. The results enhance understanding of conflict dynamics and support effective mitigation strategies.

Supervisor	dr Tomasz Stroiński
	Title/degree/name and surname	grade	signature

For the purposes of archival thesis qualified to:*

a) category A (perpetual files)

b) category BE 50 (subject to expertise after 50 years)

* delete as appropriate

stamp of the faculty

Wrocław, 2025

Spis treści

Wstęp	3
1 Teoretyczne podstawy analizy konfliktów zbrojnych	5
1.1 Wprowadzenie	5
1.2 Matematyczny opis modelu Singera	7
1.2.1 Charakterystyka zmiennych modelu i metody ich pomiaru	7
1.2.2 Konstrukcja i działanie modelu Singera	11
2 Empiryczna analiza modelu Singera	15
2.1 Przeprowadzenie analizy zgodnie z założeniami modelu Singera	17
2.2 Własna analiza modelu Singera ze zmianą parametru t	33
2.3 Prognozowanie wojen dla okresu czasowego do roku 2000	56
Podsumowanie	89
Dodatek	91
Bibliografia	93

Wstęp

Współczesny świat staje przed coraz większymi wyzwaniami związanymi z konfliktami zbrojnymi. Konflikty międzynarodowe, wewnętrzne i o charakterze regionalnym pozostają jednym z największych zagrożeń dla globalnej stabilności i bezpieczeństwa. Ich analiza i zrozumienie są niezwykle ważne, szczególnie w dobie dynamicznych zmian politycznych, ekonomicznych i społecznych. Choć wizja całkowitego przewidywania wojen i ich eliminacji wydaje się być utopijna, każde doskonalenie metod analizy konfliktów przynosi korzyści w postaci ograniczenia ich skutków oraz potencjalnych eskalacji. Celem niniejszej pracy jest wniesienie wkładu w ten proces poprzez matematyczne podejście do analizy konfliktów zbrojnych. Badanie konfliktów zbrojnych nie tylko pozwala na lepsze zrozumienie ich przyczyn i mechanizmów, ale także umożliwia rozwój strategii ich minimalizowania.

Rozwój teorii i modeli konfliktów zbrojnych przynosi wiele różnych propozycji, które jednak nie zawsze wspierają proces naukowego poznania. Nadmiar modeli może prowadzić do zakłóceń w nauce o konfliktach, generując sprzeczne wyniki i interpretacje. Przykładowo, modele opierające się na zbyt uproszczonych założeniach o racjonalności podmiotów konfliktu często nie sprawdzają się w kontekście konfliktów nietypowych, gdzie decydujące są czynniki kulturowe i historyczne. Dlatego ważne jest wybieranie tych modeli, które są nie tylko teoretycznie poprawne, ale także nadają się do matematycznego odwzorowania i praktycznej analizy. Niniejsza praca podejmuje próbę takiego podejścia, zaczynając od zbadania istniejących koncepcji i narzędzi.

Pierwszym krokiem w pracy było zapoznanie się z artykułem „Natural Resources, Conflict, and Conflict Resolution: Uncovering the Mechanisms” autorstwa Macartana Humphreysa [2]. Autor ten omawia sześć głównych mechanizmów łączących zasoby naturalne z konfliktami zbrojnymi, w tym:

- Mechanizm „chciwości rebeliantów” (rebel greed), gdzie zasoby służą jako źródło finansowania konfliktów;
- Mechanizm „chciwości zewnętrznej” (greedy outsiders), wskazujący na rolę państw trzecich i korporacji w eksplotacji zasobów;
- Mechanizm „słabych państw” (weak states), gdzie uzależnienie od zasobów osłabia struktury państwowie;
- Mechanizm „słabych sieci” (sparse networks), wskazujący na brak silnych powiązań gospodarczych w gospodarkach opartych na zasobach.

Chociaż powyższe mechanizmy są niezwykle interesujące, zastosowanie ich w matematycznym modelu napotyka wiele przeszkód. Brak jednolitych danych oraz trudność w operacyjnej realizacji tych mechanizmów sprawiają, że stają się one mniej praktyczne w tworzeniu modeli ilościowych.

Alternatywą okazał się projekt Correlates of War (COW), kompleksowa baza danych zapoczątkowana przez J. Davida Singera [1]. Autor ten, uznawany za jednego z najważniejszych badaczy pokoju i konfliktów, stworzył ten projekt w latach 60. XX wieku jako narzędzie do analizy konfliktów międzynarodowych. COW powstał w odpowiedzi na potrzebę uporządkowanej wiedzy o wojnach i ich determinantach, zwłaszcza w kontekście polityki administracji prezydenta Richarda Nixon'a. Projekt ten umożliwia systematyczną analizę wojen międzynarodowych, dostarczając danych na temat potencjałów państw, konfliktów zbrojnych, środków militarnych i dyplomatycznych oraz ich skutków.

Dzięki istnieniu tej bazy danych i pogłębionym analizom jej twórcy, zastosowanie matematycznych metod w analizie konfliktów zbrojnych stało się możliwe. Niniejsza praca przyjmuje podejście Singera jako podstawę do stworzenia modelu analitycznego, który jednocześnie zostanie zmodyfikowany i dostosowany do współczesnych wymagań badawczych.

Dzięki istnieniu tej bazy danych możliwe stało się systematyczne badanie konfliktów międzynarodowych, ich przyczyn oraz konsekwencji. Pogłębione analizy jej twórcy, wsparte treścią książki „Advancing Peace Research”, umożliwiły stworzenie spójnego modelu analitycznego [9]. Książka ta stanowi główne źródło w tej pracy i dostarcza narzędzi do podejścia, które pozwala na bardziej precyzyjne odwzorowanie dynamiki konfliktów zbrojnych. Model opisany w książce Singera oparty jest na regresji wielowymiarowej, polega na identyfikacji kluczowych czynników konfliktów zbrojnych oraz ich wzajemnych relacji, co umożliwia praktyczne wykorzystanie danych w przewidywaniu i zrozumieniu dynamiki konfliktów. Model ten podkreśla znaczenie ustrukturyzowanych danych i ich wzajemnych relacji, co umożliwia zarówno historyczną, jak i prognostyczną analizę konfliktów.

Celem pracy jest zatem nie tylko przedstawienie podejścia Singera do analizy konfliktów zbrojnych, ale także podjęcie próby jego modyfikacji w oparciu o współczesne dane. Wierzymy, że takie podejście przyczyni się do lepszego zrozumienia dynamiki konfliktów oraz do rozwoju skuteczniejszych metod ich analizy i przewidywania.

Rozdział 1

Teoretyczne podstawy analizy konfliktów zbrojnych

1.1 Wprowadzenie

Definicja konfliktu zbrojnego w kontekście jego matematycznej analizy

Konflikt zbrojny można zdefiniować jako zjawisko społeczne i polityczne, w którym co najmniej dwa podmioty, takie jak państwa, grupy społeczne czy organizacje, wykorzystują środki militarne lub zbrojne do realizacji sprzecznych interesów politycznych, gospodarczych, terytorialnych lub ideologicznych. Konflikt ten charakteryzuje się dynamicznością, złożonością oraz oddziaływaniem wielu czynników politycznych, społecznych, ekonomicznych i technologicznych.

W kontekście matematycznej analizy konflikt zbrojny jest postrzegany jako system dynamiczny, w którym interakcje między stronami konfliktu mogą być modelowane za pomocą zmiennych reprezentujących zasoby, strategie, cele oraz potencjalne wyniki działań. Kluczowe elementy w matematycznej analizie konfliktów obejmują:

1. podmioty konfliktu – strony zaangażowane w konflikt, które dążą do osiągnięcia swoich celów przy użyciu dostępnych środków. Mogą to być państwa, koalicje, grupy zbrojne lub inne organizacje.
2. zasoby – środki, jakimi dysponują strony konfliktu, w tym siły zbrojne, zaplecze ekonomiczne, wsparcie polityczne czy terytorium.
3. strategie – możliwe działania, jakie mogą podjąć strony konfliktu, takie jak atak, obrona, negocjacje czy wycofanie.
4. zmienne i parametry – wielkości matematyczne reprezentujące istotne aspekty konfliktu, takie jak liczba jednostek militarnych, intensywność działań, czas trwania konfliktu czy prawdopodobieństwo określonego wyniku.
5. interakcje – mechanizmy i zależności, które określają, jak działania jednej strony wpływają na działania i wyniki drugiej strony.

Matematyczna analiza konfliktów zbrojnych polega na tworzeniu modeli, które pozwalają na ilościowe ujęcie zależności między tymi elementami.

Zastosowanie modeli matematycznych w badaniach konfliktów międzynarodowych

W podejmowaniu decyzji związanych z konfliktami zbrojnymi, opieranie się wyłącznie na psychologii lub intuicji jednej osoby jest niezwykle ryzykowne. Jak zauważa J. David Singer w swoich pracach, polityka oparta na „intuicyjnych przeczuciach” prowadzi do błędnych prognoz i niewłaściwych decyzji. Brak solidnych kryteriów wyboru zachowań sprawia, że decydenci są skłonni podejmować decyzje pod wpływem najbardziej przekonujących zwolenników, niezależnie od tego, czy ich teorie są rzetelne, czy nie.

Podkreśla to konieczność stosowania bardziej obiektywnych i systematycznych podejść do analizy konfliktów. Alternatywą jest modelowanie matematyczne, które pozwala nie tylko przewidywać rozwój wojny, ale także analizować konflikty z zupełnie innej perspektywy. Takie modele umożliwiają badanie struktury konfliktu, identyfikację jego prawidłowości oraz ocenę skutków różnych decyzji politycznych, co w rezultacie może pomóc uniknąć katastrofalnych błędów i zminimalizować ryzyko [6].

Warto podkreślić, że celem analizy matematycznej konfliktów zbrojnych nie jest jedynie przewidywanie przebiegu wojny. Modele te służą również jako narzędzia do lepszego zrozumienia mechanizmów konfliktu, identyfikacji potencjalnych punktów krytycznych oraz wspierania procesów pokojowych poprzez ocenę skuteczności alternatywnych strategii deeskalacji. W ten sposób matematyczna analiza konfliktów może przyczynić się do bardziej świadomego i racjonalnego podejmowania decyzji w dziedzinie polityki międzynarodowej i bezpieczeństwa.

Jednak istnieją niedoskonałości wielu modeli istniejących w literaturze. Często nie spełniają one podstawowych wymagań metodologicznych i brakuje im perspektywy podłużnej, która uwzględniałaby historyczne kontinuum konfliktów. Wiele modeli koncentruje się wyłącznie na jednym poziomie analizy, pomijając powiązania między nimi, czyli poziomy: indywidualny, narodowy oraz międzynarodowy. Dlatego bardziej efektywny model musi obejmować podejście wielopoziomowe, które rozpoznaje złożoną interakcję między naturą ludzką, interesami narodowymi i szerszym systemem międzynarodowym [3].

Model matematyczny będący podstawą niniejszej pracy, umożliwia uwzględnienie złożoności konfliktów i identyfikację kluczowych czynników wpływających na ich przebieg. Celem tego podejścia jest zrozumienie, w jaki sposób różne zmienne, takie jak rozkład zdolności narodowych i ich zmiany w czasie, mogą być uwzględnione w modelu w celu prognozowania przypadków wojny. W szczególności model można dostosować do oceny skutków tych zmiennych predykcyjnych albo sekwencyjnie (gdzie jedna zmienna prowadzi do drugiej), albo jednocześnie. Ten aspekt chronologiczny jest krytyczny, ponieważ pozwala badaczom uchwycić, w jaki sposób zdolności narodowe wpływają na prawdopodobieństwo wojny w kolejnych okresach — zasadniczo łącząc przeszłe warunki z przyszłymi wydarzeniami [10].

Rozkład zdolności można mierzyć w określonych punktach w czasie, podczas gdy zmiany w tym rozkładzie i ruch między państwami są odnotowywane w odstępach poprzedzających wystąpienie wojny. Integracja tych perspektyw pozwala na solidniejsze zrozumienie dynamiki międzynarodowej i zwiększa dokładność predykcyjną dotyczącą tendencji konfliktowych [10].

1.2 Matematyczny opis modelu Singera

Przedstawiony model został skonstruowany w celu odpowiedzi na pytanie, w jaki sposób dystrybucja i redystrybucja mocy między państwami wpływa na prawdopodobieństwo wystąpienia wojny. Istnieją dwa odrębne i niekompatybilne poglądy na ten temat: jeden przewiduje, że będzie mniej wojen, gdy będzie istniał przybliżony parytet (i zmiana w jego kierunku) między państwami i stosunkowo płynna hierarchia władzy. Drugi przewiduje, że będzie mniej wojen, gdy będzie przeważająca władza skoncentrowana w rękach bardzo niewielu państw i stosunkowo stabilna kolejność rang wśród głównych mocarstw [10].

Te dwa punkty widzenia zostały skonsolidowane w pojedynczym podstawowym modelu regresji wielowymiarowej obejmującym trzy zmienne predykcyjne (koncentrację mocy, tempo i kierunek zmian koncentracji oraz ruch mocy między mocarstwami) i zmienną zależną (intensywność wojen międzynarodowych).

1.2.1 Charakterystyka zmiennych modelu i metody ich pomiaru

Zmienna zależna: intensywność wojen

W ramach analizy rozróżniamy trzy główne typy konfliktów zbrojnych: wojny międzynarodowe – konflikty, w których głównymi stronami są suwerenne państwa; wojny poza-państwowe – konflikty między uznanym państwem a podmiotem niebędącym państwem; wojny domowe – konflikty pomiędzy zorganizowanymi grupami w obrębie tego samego państwa [5]. W niniejszej pracy skupiamy się wyłącznie na wojnach międzynarodowych, które spełniają określone kryteria: przynajmniej jedno z głównych mocarstw musi być aktywnym uczestnikiem konfliktu, a każda ze stron poniosła w bitwach co najmniej 1000 ofiar śmiertelnych.

Zmienna wykorzystana w modelu odzwierciedla intensywność prowadzenia wojny (1.1), mierzona jako średni roczny czas trwania wojen prowadzonych w tym okresie [10]. To znaczy, że dla każdego państwa, jakie uczestniczyło w wojnach w danym okresie t (lata, w jakich chcemy policzyć średnią liczbę miesięcy trwania wojen), liczne są miesiące uczestnictwa w wojnie, dalej są sumowane i dzielone na t dla uśrednienia wyniku:

$$WAR_{t_1 \rightarrow t_2} = \frac{1}{t} \sum_w \sum_p m_{w,p} \quad (1.1)$$

gdzie:

w – liczba wojen w okresie $t = t_2 - t_1$,

p – liczba uczestników wojen,

$m_{w,p}$ – liczba miesięcy udziału uczestnika p w wojnie w .

Moc państwa w systemie

W analizie mocy państw przeprowadzanej przez Davida Singera zastosowano trzy podstawowe elementy zdolności: demograficzną, przemysłową i militarną. Decyzja ta wynikała z ich uniwersalności, możliwości porównywania w różnych okresach historycznych oraz dostępności danych [8]. Poniżej przedstawiono szczegółowe uzasadnienie wyboru tych elementów oraz wyjaśnienie, dlaczego inne potencjalne wskaźniki zostały odrzucone.

1. *Zdolność demograficzna.* Zdolność demograficzna odzwierciedla potencjał ludnościowy państwa, który wpływa na jego zdolności produkcyjne i wojskowe. Singer zaproponował mierzenie tej zdolności za pomocą dwóch kluczowych subelementów:

- Całkowita populacja państwa – liczba ludności stanowi podstawę mobilizacji zasobów, zarówno w gospodarce, jak i w działaniach wojennych. Im większa populacja, tym większy potencjał państwa.
- Populacja miejska ("urban agglomerations") – wskaźnik liczby ludzi zamieszkujących obszary miejskie, które są bardziej produktywne i łatwiejsze do zmobilizowania w sytuacjach kryzysowych.

Te subelementy są szczególnie użyteczne, ponieważ wartości całkowite (np. całkowita populacja) są bardziej uniwersalne i łatwiejsze do porównania między różnymi epokami i państwami. Wskaźniki te zostały wybrane zamiast bardziej specyficznych, takich jak wskaźnik urbanizacji, który lepiej opisuje rozwój gospodarczy, ale nie jest kluczowy dla pomiaru materialnych zdolności państwa.

2. *Zdolność przemysłowa.* Zdolność przemysłowa mierzy zdolność państwa do produkcji zasobów materialnych, które są kluczowe dla gospodarki i obronności. Singer wybrał dwa elementy:

- Konsumpcja energii przemysłowej – przeliczana na ekwiwalenty ton węgla, obejmuje różne źródła energii, takie jak węgiel, hydroenergia czy energia jądrowa. Ten element odzwierciedla ogólną moc przemysłową państwa.
- Produkcja żelaza i stali – kluczowe wskaźniki materialnej produkcji, zwłaszcza w kontekście budowy infrastruktury wojskowej, takiej jak broń, czołgi czy statki.

Uznano, że te wskaźniki najlepiej nadają się do porównań w długim okresie historycznym. Alternatywne wskaźniki, takie jak produkcja elektroniki czy chemikaliów, zostały odrzucone ze względu na trudności w porównaniach między państwami i epokami.

3. *Zdolność militarna.* Zdolność militarna opisuje możliwości wojskowe państwa i jest mierzona za pomocą:

- Liczby personelu wojskowego – obejmuje liczbę aktywnych żołnierzy w siłach zbrojnych. Choć wskaźnik ten nie uwzględnia rezerw ani paramilitarnych jednostek, odzwierciedla bezpośredni potencjał obronny państwa.
- Wydatków wojskowych – mierzone jako skumulowane wartości z ostatnich pięciu lat. Wskaźnik ten ilustruje zaangażowanie państwa w utrzymanie i modernizację sił zbrojnych.

Singer zdecydował się wykluczyć inne potencjalne elementy zdolności, takie jak geografia, zasoby naturalne, instytucje polityczne, kultura czy wskaźniki ekonomiczne.

Geografia, choć istotna w specyficznych przypadkach (np. dostęp do morza, teren górzysty), jest zbyt kontekstowa i zmieniona w zależności od epoki i technologii. Uniemożliwia to porównania w czasie i między państwami.

Zasoby naturalne, takie jak ropa naftowa, mają znaczenie zależne od kontekstu historycznego. Ponadto ich wpływ jest częściowo odzwierciedlony w zdolnościach przemysłowych.

Chociaż instytucje polityczne wpływają na efektywność wykorzystania zasobów, ich pomiar jest subiektywny i trudny do porównań. Nie są one bezpośrednim elementem materialnych zdolności państwa.

Wpływ kultury czy ideologii jest trudny do zmierzenia w sposób obiektywny i jednolity. Są one bardziej kontekstowe niż uniwersalne.

Produkt krajowy brutto, choć często stosowany w analizach międzynarodowych, nie odzwierciedla bezpośrednio zdolności wojskowych ani mobilizacyjnych. Singer uznał, że konsumpcja energii i produkcja stali są lepszymi wskaźnikami zdolności gospodarczych.

Technologia zmienia się dynamicznie, co czyni ją trudną do porównań historycznych. Jej wpływ jest jednak częściowo uwzględniony w zdolnościach przemysłowych i militarnych.

Wybór elementów przez Singera opiera się na ich uniwersalności, możliwości pomiaru oraz zdolności do porównań w czasie i przestrzeni. Zdolności demograficzne, przemysłowe i militarne są centralnymi elementami materialnej siły państwa, co czyni je kluczowymi w analizach porównawczych i długookresowych. Dzięki odrzuceniu alternatywnych wskaźników Singer skupił się na tych aspektach, które najlepiej oddają istotę mocy państw w kontekście ich zdolności materialnych.

Proces obliczania mocy państwa w systemie międzynarodowym, oparty na sześciu elementach zdolności (całkowita populacja państwa, populacja miejska, konsumpcja energii przemysłowej, produkcja żelaza i stali, liczba personelu wojskowego, wydatki wojskowe), obejmuje następujące kroki [10]:

1. Obliczenie całkowitych wartości systemowych dla każdego z elementów zdolności. W każdym roku wartości każdego państwa w całym systemie międzynarodowym są sumowane dla każdego z elementów zdolności, a w przypadku braku danych dla danego państwa, nie wnosi ono nic do sumy. W ten sposób powstają całkowite wartości systemowe dla każdego komponentu na dany rok.
2. Wyznaczenie udziału każdego państwa w systemie. Dla każdego państwa obliczane są jego udziały w systemie, dzieląc wartość danego elementu przez całkowitą wartość systemową tego elementu w danym roku. Jeśli państwo nie ma wartości dla danego komponentu, jego udział jest kodowany jako brakujący. Dzięki temu każde państwo otrzymuje udział w systemie dla każdego z sześciu komponentów zdolności.
3. Obliczenie mocy państwa. Wskaźnik mocy dla każdego państwa w danym roku jest średnią arytmetyczną niebrakujących wartości udziałów tego państwa we wszystkich dostępnych elementach.

Ostateczna wartość mocy dla państwa i oznaczana jest jako S_i oraz przyjmuje wartości od 0 do 1.

Zmienna predykcyjna: koncentracja mocy

Zmienna CON (Concentration of Power Index) (1.2), jest kluczowym narzędziem do analizy koncentracji mocy w systemie międzynarodowym. Jego głównym celem jest ilościowe określenie, w jakim stopniu siła w systemie jest skoncentrowana w rękach jednego lub kilku państw, czy też rozproszona między wieloma państwami [7].

Proces obliczania wskaźnika koncentracji (CON) obejmuje dwa kluczowe kroki. Najpierw obliczane jest odchylenie standardowe mocy głównych mocarstw w systemie. Następnie ta wartość jest normalizowana przez dzielenie jej przez maksymalne możliwe odchylenie standardowe dla danego systemu, które występowałoby w sytuacji, gdy jedno państwo posiada 100% mocy, a pozostałe nie mają jej wcale:

$$CON_{t_0} = \sqrt{\frac{\sum_{N_{t_0}} S_{it_0}^2 - \frac{1}{N_{t_0}}}{1 - \frac{1}{N_{t_0}}}} \quad (1.2)$$

gdzie:

S_{it_0} – moc państwa i w czasie t_0 ,

N_{t_0} – liczba państw w systemie w czasie t_0 .

Wskaźnik przyjmuje wartości w przedziale od 0 do 1. Wartość 0 oznacza idealną równość w systemie, co wskazuje, że wszystkie państwa mają identyczną moc. Natomiast wartość 1 wskazuje na pełną koncentrację władzy w systemie, gdzie jedno państwo kontroluje całość zdolności.

Koncepcja wskaźnika opiera się na założeniu, że rozmieszczenie władzy wpływa na prawdopodobieństwo wystąpienia konfliktów. Obliczanie wskaźnika CON odzwierciedla metodologię J. Davida Singera, który dążył do precyzji i porównywalności między różnymi okresami historycznymi i kontekstami geopolitycznymi. W przypadku analizy koncentracji mocy w systemie międzynarodowym, wskaźnik CON spełnia kluczowe wymagania:

- Uwzględnia dostępność danych historycznych.
- Koncentruje się na obiektywnych wskaźnikach, takich jak liczba ludności, siła militarna i zdolności przemysłowe, unikając subiektywnych ocen.
- Umożliwia śledzenie zmian w układzie sił w czasie oraz ich wpływu na ryzyko konfliktów zbrojnych.
- Uwzględnia wszystkie jednostki.
- Jest prosty w interpretacji i odporny na problemy wynikające ze zmian liczby państw w systemie w różnych okresach czasowych.

Taki sposób obliczeń pozwala precyzyjnie określić poziom koncentracji mocy w systemach międzynarodowych oraz śledzić ich zmiany w czasie.

Zmienna predykcyjna: tempo i kierunek zmian koncentracji

Zmienna ΔCON (1.3) jest miarą ilościową służącą do analizy zmian w koncentracji mocy w systemie międzynarodowym w określonym przedziale czasowym. Jego głównym celem jest odzwierciedlenie stopnia, w jakim wartość koncentracji (CON) wzrosła lub spadła w analizowanym okresie t:

$$\Delta CON_{t_0 \rightarrow t_1} = \frac{CON_{t_1} - CON_{t_0}}{t_1 - t_0} \quad (1.3)$$

gdzie:

CON_{t_0}, CON_{t_1} - to koncentracja mocy w czasach t_0, t_1 odpowiednio, oraz $t_1 - t_0 = t$.

Wartość ΔCON pozwala precyzyjnie określić kierunek oraz intensywność tych zmian, co czyni go istotnym narzędziem w badaniach dynamiki układu sił w systemie międzynarodowym.

Zmiana koncentracji, może przyjąć zarówno wartości dodatnie, jak i ujemne. Dodatnia wartość wskazuje na wzrost koncentracji mocy w systemie. Z kolei wartość ujemna oznacza spadek koncentracji, co odzwierciedla bardziej zrównoważony rozkład władzy pomiędzy państwami.

Dzięki wskaźnikowi ΔCON możliwa jest analiza długofalowych trendów w systemie międzynarodowym, co wspiera lepsze zrozumienie mechanizmów zmieniającej się równowagi sił oraz ich wpływu na stabilność i dynamikę konfliktów zbrojnych.

Zmienna predykcyjna: ruch mocy między mocarstwami

Wskaźnik $MOVE$ (1.4) jest bardziej złożoną miarą redystrybucji mocy w systemie międzynarodowym, odzwierciedlającą liczbę mocy, które zostały przesunięte między głównymi mocarstwami w danym okresie, niezależnie od tego, czy prowadzi to do zmiany ich całkowitej mocy. $MOVE$ dostarcza informacji o intensywności redystrybucji władzy, umożliwiając analizę dynamiki układu sił w poszczególnych okresach [10].

Konstrukcja wskaźnika rozpoczyna się od porównania udziałów posiadanych przez każde państwo na początku i końcu analizowanego okresu t . Aby wskaźnik był porównywalny w różnych okresach, uwzględniających zmianę liczbę członków systemu międzynarodowego, konieczna jest normalizacja. Proces ten polega na podzieleniu wartości $MOVE$ przez maksymalny możliwy poziom redystrybucji mocy. Maksimum to występuje w hipotetycznym przypadku, gdy państwo o najniższej początkowej mocy przejęłoby wszystką moc w systemie, kończąc z 100%. W takim scenariuszu mianownik jest obliczany jako różnica między 100% a mocą najniżej sklasyfikowanego państwa, pomnożona przez 2, ponieważ każda zdobytą część mocy musi zostać utracona przez inne państwa:

$$MOVE_{t_0 \rightarrow t_1} = \frac{\sum_{N_t} |S_{it_1} - S_{it_0}|}{2(1 - S_{mt})} \quad (1.4)$$

gdzie:

S_{it_0} – moc państwa i w czasie t_0 ,

S_{it_1} – moc państwa i w czasie t_1 ,

N_t – liczba państw w systemie w okresie t .

S_{mt} – państwo z najmniejszą mocą w czasie $t = t_1 - t_0$.

Przy obliczaniu wskaźnika $MOVE$ konieczne jest uwzględnienie potencjalnego problemu. Nieprawidłowość polega na tym, że system międzynarodowy zmienia swój skład w czasie, zyskując i tracąc członków. Taka zmienność wymaga normalizacji rozmiaru systemu, aby wyeliminować niedogodności wynikające z różnic w liczbie członków w różnych punktach obserwacji. Dla zapewnienia spójności, wskaźnik $MOVE$ uwzględnia jedynie ruch mocy między państwami, które były członkami systemu zarówno na początku, jak i na końcu analizowanego okresu t . Wyklucza to zniekształcenia wynikające z różnic w liczbie członków systemu w poszczególnych punktach obserwacji.

Dzięki wskaźnikowi ruchu mocy możliwe jest nie tylko badanie dynamiki układu sił, ale również identyfikacja intensywności redystrybucji władzy w systemie międzynarodowym, co stanowi istotny wkład w analizę stabilności i zmian w globalnym porządku politycznym.

1.2.2 Konstrukcja i działanie modelu Singera

Podstawowy model matematyczny (1.5), który opisuje zależność między konfiguracją zdolności w systemie międzynarodowym a występowaniem wojen, można przedstawić

w postaci równania regresji wielowymiarowej:

$$WAR_{t_1 \rightarrow t_2} = \alpha + \beta_1 CON_{t_0} + \beta_2 \Delta CON_{t_0 \rightarrow t_1} + \beta_3 MOVE_{t_0 \rightarrow t_1} + \epsilon \quad (1.5)$$

gdzie:

$WAR_{t_1 \rightarrow t_2}$ – zmienna zależna, reprezentująca wystąpienie wojny w przedziale czasu pomiędzy t_1 a t_2 ;

CON_{t_0} – poziom koncentracji mocy w czasie t_0 ;

$\Delta CON_{t_0 \rightarrow t_1}$ – zmiana koncentracji mocy między t_0 a t_1 ;

$MOVE_{t_0 \rightarrow t_1}$ – ilość przesuniętej mocy między t_0 a t_1 ;

α - stała;

β_i - współczynnik regresji, odzwierciedlający wpływ poszczególnych zmiennych niezależnych na wystąpienie wojny;

ϵ - składnik losowy.

Model ten umożliwia badanie wpływu trzech kluczowych zmiennych niezależnych: koncentracji mocy (CON), jej zmiany (ΔCON) oraz redystrybucji ($MOVE$), na prawdopodobieństwo wystąpienia wojny (WAR).

Interpretacja parametrów czasowych

Wybrany okres analizy jest podzielony na interwały o stałej długości:

$$t_1 - t_0 = t_2 - t_1 = \dots = t_n - t_{n-1} = t \quad (1.6)$$

Dla przykładu, w analizie obejmującej lata 1900 – 1950 z $t = 5$, pierwszy okres pięcioletni obejmuje dane od 1 stycznia 1900 roku do 31 grudnia 1904 roku. W tym okresie:

- CON_{t_0} jest obliczane na podstawie danych od 1 stycznia 1900 roku,
- $\Delta CON_{t_0 \rightarrow t_1}$, $MOVE_{t_0 \rightarrow t_1}$ są obliczane na podstawie danych od 1 stycznia 1900 roku do 31 grudnia 1904 roku,
- $WAR_{t_1 \rightarrow t_2}$ reprezentuje występowanie wojny w kolejnym okresie, od 1 stycznia 1905 roku do 31 grudnia 1909 roku.

Taka konstrukcja modelu pozwala na ocenę wpływu wskaźników koncentracji mocy na prawdopodobieństwo wystąpienia konfliktu zbrojnego w przeszłości.

Warto zauważyć, że długość interwałów czasowych t w modelu może być dostosowywana w zależności od potrzeb analizy. Dla krótszych przedziałów czasowych ($t = 1$) analiza będzie bardziej szczegółowa, natomiast dla dłuższych okresów ($t > 5$) umożliwia uchwycenie bardziej ogólnych trendów. W oryginalnym modelu Singera przyjęto wartość $t = 5$, co oznacza podział analizy na pięcioletnie okresy.

W niniejszej pracy zakłada się możliwość dostosowywania wartości t w celu przeprowadzenia analizy w różnych skalach czasowych. Takie podejście pozwala na dokładne określenie, jak zmienne dotyczące mocy w systemie międzynarodowym wpływają na ryzyko wystąpienia konfliktu zbrojnego w perspektywie krótkoterminowej i długoterminowej.

Wersje modelu Singera

Oprócz podstawowego modelu istnieją trzy różne jego wersje, które uwzględniają zarówno charakter wpływów zmiennych (addytywny lub multiplikatywny), jak i chronologiczną kolejność łączenia zmiennych predykcyjnych [10].

$$WAR_{t_1 \rightarrow t_2} = \alpha + \beta_1 CON_{t_0} + \beta_2 \Delta CON_{t_0 \rightarrow t_1} + \beta_3 MOVE_{t_0 \rightarrow t_1} + \epsilon \quad (1.7)$$

$$WAR_{t_1 \rightarrow t_2} = \alpha + \beta_1 CON_{t_1} + \beta_2 \Delta CON_{t_0 \rightarrow t_1} + \beta_3 MOVE_{t_0 \rightarrow t_1} + \epsilon \quad (1.8)$$

$$WAR_{t_1 \rightarrow t_2} = \alpha \cdot \beta_1 CON_{t_0} \cdot \beta_2 \Delta CON_{t_0 \rightarrow t_1} \cdot \beta_3 MOVE_{t_0 \rightarrow t_1} \cdot \epsilon \quad (1.9)$$

$$WAR_{t_1 \rightarrow t_2} = \alpha \cdot \beta_1 CON_{t_1} \cdot \beta_2 \Delta CON_{t_0 \rightarrow t_1} \cdot \beta_3 MOVE_{t_0 \rightarrow t_1} \cdot \epsilon \quad (1.10)$$

Rozróżnienie między wersjami addytywną (1.7) (1.8) a multiplikatywną (1.9) (1.10) dotyczy sposobu, w jaki zmienne predykcyjne oddziałują na prawdopodobieństwo wystąpienia wojny. W wersji addytywnej efekty poszczególnych zmiennych sumują się, co oznacza, że wysoka wartość dowolnej zmiennej może prowadzić do wzrostu prawdopodobieństwa wystąpienia konfliktu. W przeciwnieństwie do tego, w wersji multiplikatywnej wszystkie zmienne muszą osiągnąć wysoką wartość, aby mogły sygnalizować o wojnach, ponieważ niska wartość którejkolwiek z nich skutkuje całkowitym zanegowaniem wpływu pozostałych.

Oprócz charakteru wpływów zmiennych, istotna jest także chronologiczna kolejność, w której zmienne są mierzone i łączone w celu wyjaśnienia występowania wojen. W tym kontekście rozróżnia się dwie główne wersje modelu. W pierwszej wersji CON LEADS (1.7) (1.9) poziom koncentracji mocy (*CON*) jest mierzony na początku okresu t . Taka sekwencja zakłada, że poziom koncentracji mocy sygnalizuje o późniejszych zmianach i redystrybucję mocy w tym okresie. W przeciwnieństwie do tego w wersji CON LAGS (1.8) (1.10) poziom koncentracji mocy (*CON*) jest mierzony na końcu okresu t . Taka sekwencja zakłada, że zmiana i redystrybucja mocy przez cały okres t wskazuje na późniejszy poziom koncentracji, co z kolei determinuje prawdopodobieństwo wojny.

Uwzględnienie obu wersji umożliwia analizę współzależności między zmiennymi predykcyjnymi oraz pozwala lepiej zrozumieć dynamikę relacji między koncentracją mocy, jej zmianami i redystrybucją a występowaniem wojen.

Rozdział 2

Empiryczna analiza modelu Singera

Analiza konfliktów zbrojnych stanowi ważny element badań nad międzynarodowymi relacjami i mechanizmami powstawania wojen. W tym rozdziale skupimy się na zastosowaniu modelu Singera, który umożliwia systematyczne badanie konfliktów w oparciu o określone dane i wskaźniki. Inspiracją dla tych badań jest podejście J. D. Singera, który opracował jedną z najbardziej wpływowych metod analizy konfliktów – model oparty na projekcie Correlates of War. Model ten pozwala na identyfikację kluczowych czynników określających prawdopodobieństwo wybuchu konfliktów.

Celem niniejszego rozdziału jest przeprowadzenie empirycznej analizy modeli konfliktów zbrojnych zgodnie z założeniami metodologicznymi ich autora oraz rozszerzenie jego podejścia o nowe aspekty badawcze. Rozpoczniemy od omówienia danych, które stanowią podstawę analizy, przechodząc następnie do zastosowania kluczowych metod oraz interpretacji wyników w kontekście teorii Singera. Następnie zaproponowana zostanie własna analiza przy uwzględnieniu różnych okresów czasowych t , oraz próba rozszerzania badania Singera o przewidywanie wojen dla okresów późniejszych niż pierwotnie analizowane.

Wnioski wynikające z tych badań posługują jako podstawa do oceny skuteczności metod ilościowych w analizie konfliktów oraz ich potencjalnego zastosowania w praktyce politycznej i badawczej.

Już na wstępie warto zaznaczyć, że w naukach społecznych interpretacja wyników modelowania zależy różni się od podejścia charakterystycznego dla nauk ścisłych. Wynika to z dużej zmienności parametrów i mniejszej dokładności w badaniach społecznych. Odczytywanie wyników modelowania w tej dziedzinie jest bardziej protekcyjonalne, gdyż modele rzadko osiągają wysoki stopień dopasowania (np. w przypadku wskaźnika R^2), ale ich celem jest uchwycenie trendów, a nie precyzyjne przewidywanie. Jak pokażą późniejsze wykresy, choć współczynniki mogą być nieznaczące, model potrafi uchwycić ogólne trendy, nawet w perspektywie kilkuletniej. Kluczowym celem tych modeli nie jest dokładne przewidzenie daty konfliktu, lecz zrozumienie wpływu różnych wskaźników na prawdopodobieństwo wystąpienia wojen.

Dane

Do przeprowadzenia analizy wykorzystano dane pochodzące z projektu Correlates of War (COW), który został zainicjowany przez J. D. Singera w latach 60. XX wieku [1]. Projekt ten zajmuje się gromadzeniem, analizą oraz systematyzacją danych dotyczących konfliktów zbrojnych. W jego ramach znajdują się różnorodne zestawy danych obejmujące takie aspekty, jak terytoria, państwa, religie oraz inne zmienne istotne dla analizy międzynarodowych konfliktów. Dzięki swojemu szerokiemu zakresowi i uporządkowanej

strukturze, projekt COW stał się jednym z najważniejszych źródeł danych w badaniach nad konfliktami zbrojnymi.

Pierwszym wykorzystanym zbiorem danych jest **National Material Capabilities (v6.0)** (Zdolności Materiałne Państw), który zawiera informacje o zdolnościach państw w latach 1816 – 2016 [10, 8]. Dane te dotyczą państw suwerennych i odnoszą się do aspektów takich jak potencjał demograficzny, gospodarczy i militarny, co zostało szczegółowo omówione w rozdziale 1.2.1 „Moc państwa w systemie”. Zbiór ten jest szczególnie istotny w analizie, ponieważ umożliwia ocenę relatywnej siły państw w danym okresie, co ma kluczowe znaczenie dla zrozumienia dynamiki międzynarodowych konfliktów.

Ważne jest także podkreślenie specyficznej systematyki dotyczącej uznania państw w ramach projektu COW. Kryteria, według których podmioty są uwzględniane jako państwa w systemie międzynarodowym, zależą od okresu historycznego [1]:

- Przed 1920 rokiem: podmiot musiał mieć populację powyżej 500 000 oraz utrzymywać misje dyplomatyczne na poziomie co najmniej chargé d'affaires z Wielką Brytanią i Francją.
- Po 1920 roku: podmiot musiał być członkiem Ligi Narodów lub Organizacji Narodów Zjednoczonych albo spełniać kryteria populacyjne (powyżej 500 000 mieszkańców) i być uznawanym przez dwa główne mocarstwa.

Taka standaryzacja pozwala na uzyskanie bardziej obiektywnego obrazu badanych zjawisk.

Drugim kluczowym zbiorem danych wykorzystanym w niniejszej analizie jest **Inter-State War Data (v4.0)**, który zawiera informacje o różnych rodzajach wojen [5]. Dane obejmują konflikty zarówno wewnętrzne, jak i międzynarodowe. Jednak w tej analizie, zgodnie z omówieniem w rozdziale 1.2.1 „Zmienna zależna WAR”, skupiono się wyłącznie na wojnach międzynarodowych. Zbiór danych obejmuje okres od 1816 do 2003 roku i dostarcza szczegółowych informacji na temat konfliktów, ich intensywności oraz stron zaangażowanych w działania wojenne.

Dane wykorzystane w niniejszej analizie różnią się od tych, które były dostępne J. D. Singerowi w latach 70. XX wieku, kiedy projekt Correlates of War (COW) dopiero się rozwijał. Singer pracował na pierwotnych wersjach zbiorów danych. Od tego czasu projekt przeszedł wiele modyfikacji i aktualizacji, co znaczco wpłynęło na jego precyzję, kompleksowość oraz zakres czasowy.

Przykładem tego jest zestaw danych National Material Capabilities, który w niniejszej pracy wykorzystano w wersji szóstej (NMC v6). Zestaw ten zawiera dane od roku 1816 do 2016, obejmujące szereg wskaźników takich jak potencjał demograficzny, gospodarczy i militarny. Jednak w czasach Singera, kiedy projekt COW dopiero się rozwijał, wykorzystywana była pierwsza wersja tego zbioru danych, znacznie mniej rozbudowana zarówno pod względem zakresu czasowego, jak i szczegółowości zmiennych. W wersji pierwszej niektórych państw oraz zmiennych nie było jeszcze uwzględnionych, a metodologia gromadzenia danych nie była tak precyzyjna jak obecnie.

Warto podkreślić, że różnice między wersjami danych nie oznaczają, że analizy Singera były mniej wartościowe. Wręcz przeciwnie, jego prace stworzyły podstawy do rozwoju projektu i umożliwiły kolejnym pokoleniom badaczy udoskonalanie metodologii oraz rozszerzanie zbiorów danych. Wersje współczesne, takie jak NMC v6, są dowodem ewolucji projektu COW i jego zdolności do adaptacji wobec nowych wyzwań badawczych oraz dostępnych zasobów danych. Wykorzystanie tych najnowszych wersji w niniejszej analizie

pozwala na uzyskanie bardziej szczegółowych i aktualnych wyników, które są jednocześnie zgodne z założeniami modelu Singera.

2.1 Przeprowadzenie analizy zgodnie z założeniami modelu Singera

W niniejszym podrozdziale zostanie zaprezentowany proces analizy zgodny z założeniami modelu Singera. Celem tej części jest odtworzenie podejścia Singera w oparciu o jego model i zastosowanie go do nowszych danych. Dzięki temu możliwe będzie sprawdzenie, czy wnioski wyciągnięte przez Singera pozostają aktualne i jak model działa w zmieniających się realiach międzynarodowych.

Analiza Singera została przeprowadzona dla lat 1820 – 1965 i obejmowała dwa podokresy: lata 1820 – 1890 (identyfikuje wiek XIX) oraz lata 1890 – 1965 (identyfikuje wiek XX). Podział ten umożliwił zbadanie, jak zmienne w modelu wpływają na występowanie konfliktów w różnych epokach historycznych, uwzględniając dynamiczne zmiany w systemie międzynarodowym, takie jak industrializacja, rozwój technologiczny czy zmieniające się struktury sojuszy.

W swojej analizie Singer liczył wszystkie wskaźniki co pięć lat ($t = 5$). Oznacza to, że wszystkie zmienne predyktory były obliczane dla okresu 1820 – 1960, podczas gdy zmienna zależna WAR była liczona dla okresu 1825 – 1965. Jak wskazano w sekcji 1.2.2 „Interpretacja parametrów czasowych”, zmienna zależna WAR odnosi się do okresu t po okresie, w którym obliczane były zmienne niezależne. W związku z tym podział okresów dla zmiennych niezależnych wynosi 1820 – 1890 oraz 1890 – 1960, a dla zmiennej zależnej 1825 – 1895 oraz 1895 – 1965.

Przy przedstawieniu wyników w niniejszej pracy będą zapisywane okresy obliczania zmiennych niezależnych dla uproszczenia opisu, co oznacza, że zmienna zależna WAR jest liczona dla okresu o $t = 5$ lat późniejszego.

Statystyki opisowe zmiennych modelu

Tabele 2.1, 2.2 i 2.3 prezentują statystyki opisowe dla zmiennych modelowych (*WAR*, *CON*, ΔCON , *MOVE*) w różnych przedziałach czasowych: 1820 – 1960, 1820 – 1890 oraz 1890 – 1960. Analiza tych tabel pozwala zidentyfikować różnice w zmiennych w zależności od okresu.

Tabela 2.1: Statystyki opisowe dla zmiennych w latach 1820 – 1960

Zmienna	Wartość oczekiwana	Odchylenie standardowe	Max	Min	Medianą	Skośność	Kurtoza
<i>WAR</i>	22.4214	36.0272	137.2	0	9.3	2.4047	4.9228
<i>CON</i>	0.2483	0.0712	0.342	0.0589	0.2618	-1.0416	0.6373
ΔCON	0.0034	0.0145	0.0628	-0.0254	0.0022	2.6150	10.9765
<i>MOVE</i>	0.0088	0.0089	0.038	0.0012	0.0059	2.2293	4.8356

Źródło: opracowanie własne

Tabela 2.2: Statystyki opisowe dla zmiennych w latach 1820 – 1890

Zmienna	Wartość oczekiwana	Odchylenie standardowe	Max	Min	Medianą	Skośność	Kurtoza
<i>WAR</i>	10.7857	12.7977	44.2	0	6.8	1.6081	2.6471
<i>CON</i>	0.2740	0.0300	0.3183	0.2085	0.2720	-0.4240	0.3039
ΔCON	0.0016	0.0048	0.0098	-0.0085	0.0020	-0.8924	1.3336
<i>MOVE</i>	0.0044	0.0022	0.0093	0.0012	0.0044	0.7064	0.4306

Źródło: opracowanie własne

Tabela 2.3: Statystyki opisowe dla zmiennych w latach 1890 – 1960

Zmienna	Wartość oczekiwana	Odchylenie standardowe	Max	Min	Medianą	Skośność	Kurtoza
<i>WAR</i>	34.0571	47.3326	137.2	0.8	14.3	1.5566	0.8056
<i>CON</i>	0.2227	0.0907	0.342	0.0589	0.2363	-0.2389	-1.0739
ΔCON	0.0053	0.0201	0.0628	-0.0254	0.0024	1.9018	5.2699
<i>MOVE</i>	0.0133	0.0108	0.038	0.0025	0.0092	1.4103	1.1667

Źródło: opracowanie własne

Zmienna *WAR* wykazuje wysoką wartość oczekiwana oraz duże odchylenie standarde w tabeli dla okresu 1820 – 1960 (Tabela 2.1), co wskazuje na znaczne wahania w intensywności konfliktów na przestrzeni całego okresu. Jednocześnie dodatnia skośność tej zmiennej sugeruje obecność rzadkich, ale znaczących konfliktów o dużej intensywności. W porównaniu, analiza podokresów wskazuje na znaczące różnice między XIX a XX wiekiem. W latach 1820 – 1890 (Tabela 2.2) średnia wartość *WAR* była stosunkowo niska, co może wskazywać na względną stabilność systemu międzynarodowego w tym czasie. Natomiast w okresie 1890 – 1960 (Tabela 2.3) zaobserwowało gwałtowny wzrost intensywności konfliktów, prawdopodobnie związany z dwiema wojnami światowymi oraz ogólnym wzrostem napięć geopolitycznych.

Zmienna *CON*, opisująca koncentrację mocy, wykazuje wyraźną różnicę między podokresami. W latach 1820 – 1890 jej wartość oczekiwana była wyższa, co wskazuje na większą centralizację mocy w XIX wieku. Można to wiązać z dominacją kilku głównych mocarstw oraz ograniczoną liczbą aktorów państwowych. W XX wieku (1890 – 1960) obserwujemy spadek wartości średniej *CON*, co może być wynikiem procesów dekolonizacji i większego rozproszenia mocy w międzynarodowym systemie politycznym. Wzrost zmienności tej zmiennej w tym okresie może również wskazywać na większą dynamikę w przepływie i wykorzystaniu zasobów.

Ciekawym elementem jest analiza zmiennej *MOVE*, reprezentującej ruch mocy. W XIX wieku ruch mocy był jeszcze niższy, co można tłumaczyć ograniczeniami technologicznymi oraz mniejszą integracją międzynarodową. W XX wieku zaobserwowało wzrost wartości *MOVE*, co można przypisać rozwojowi transportu i technologii, choć wartości te nadal pozostają umiarkowane, co wskazuje na istnienie barier strukturalnych w przepływie zasobów.

Analizując statystyki opisowe w kontekście ich rozkładu, należy zwrócić uwagę na wysoką kurtozę dla zmiennych ΔCON i *MOVE*, szczególnie w całym okresie 1820–1960. Wskazuje to na koncentrację większości wartości wokół średniej przy jednoczesnym występowaniu wartości odstających. Wartości te podkreślają znaczenie dokładnej analizy rozkładów w celu zrozumienia mechanizmów napędzających zmiany w systemie międzynarodowym.

Porównując te wyniki z analizami J. D. Singera (Dodatek: Tabela 2.25), można zauważyc zgodność w ogólnych trendach, takich jak wzrost intensywności konfliktów i zmniejszanie się koncentracji zasobów w XX wieku. Różnice w wartościach średnich mogą jednak wynikać z różnic w metodologii, np. w sposobie klasyfikacji konfliktów.

Podsumowując, wyniki analizy wskazują na znaczące zmiany w charakterze systemu międzynarodowego, szczególnie w kontekście wzrostu liczby konfliktów oraz przekształceń w strukturze koncentracji i ruchu mocy. Obserwowane zmiany odzwierciedlają ewolucję międzynarodowych stosunków politycznych i gospodarczych oraz adaptację do dynamicznie zmieniających się warunków technologicznych i społecznych. Wnioski te mają kluczowe znaczenie dla zrozumienia historycznych procesów w systemie międzynarodowym i stanowią podstawę do dalszych analiz matematycznych i modelowania tych procesów.

Analiza dwuwymiarowa

J. D. Singer uważa, że wpływ wskaźników (zmiennych niezależnych) na prawdopodobieństwo wystąpienia wojny należy analizować zarówno oddzielnie, jak i łącznie, aby zrozumieć ich indywidualny i wspólny wpływ na badane zjawisko. Z tego powodu poniżej przedstawiona została Tabela 2.4 z wynikami korelacji każdego ze wskaźników z prawdopodobieństwem wystąpienia wojny, uwzględniając trzy różne okresy czasowe. Wartość współczynnika korelacji R pozwala ocenić, na ile model jest w stanie uchwycić ogólny charakter zależności między zmiennymi. Następnie wyznaczono współczynnik determinacji R^2 , który określa proporcję wariancji zmiennej zależnej wyjaśnianej przez zmienne niezależne. Wyższe wartości R^2 wskazują na lepsze dopasowanie [4].

Tabela 2.4: Korelacja zmiennych niezależnych z prawdopodobieństwem wystąpienia wojny

Wskaźnik	1820 – 1960		1820 – 1890		1890 – 1960	
	R	R^2	R	R^2	R	R^2
CON	-0.42	0.17	0.11	0.01	-0.38	0.14
ΔCON	0.33	0.11	0.29	0.09	0.31	0.10
$MOVE$	0.40	0.16	0.54	0.29	0.27	0.07

Źródło: opracowanie własne

Dla całego okresu (1820 – 1960) zauważalna jest istotna negatywna korelacja ($R = -0.42$) dla wskaźnika CON , co sugeruje, że większa koncentracja mocy w systemie międzynarodowym zmniejsza prawdopodobieństwo konfliktu. Wskaźniki ΔCON ($R = 0.33$) i $MOVE$ ($R = 0.40$) wykazują natomiast pozytywną korelację, co może oznaczać, że zmiana koncentracji mocy oraz ruch mocy sprzyjają zwiększonemu ryzyku konfliktu.

Wartości R^2 dla całego okresu wskazują, że wskaźniki te w umiarkowanym stopniu przewidują wystąpienie konfliktu. Najlepsze dopasowanie obserwujemy dla CON ($R^2 = 0.17$), co sugeruje, że ruch mocy jest stosunkowo dobrym predyktorem konfliktów w długim okresie. Wskaźnik $MOVE$ ($R^2 = 0.16$) również wykazuje pewien wpływ, natomiast ΔCON ma niższą wartość ($R^2 = 0.11$).

W podokresie 1820 – 1890 koreacje zmieniają swoje charakterystyki. Wskaźnik $MOVE$ odnotowuje najwyższą korelację dodatnią ($R = 0.54$, $R^2 = 0.29$), co oznacza, że ruch mocy był kluczowym czynnikiem sprzyjającym konfliktom w XIX wieku. Wskaźnik ΔCON także wykazuje pozytywną korelację ($R = 0.29$), ale jej siła jest umiarkowana. Warto zauważyć,

że wskaźnik *CON* traci na znaczeniu w tym okresie ($R = 0.11$, $R^2 = 0.01$), co wskazuje, że koncentracja zasobów miała minimalny wpływ na wystąpienie konfliktów w XIX wieku.

W okresie 1890 – 1960 sytuacja ulega zmianie. Korelacja wskaźnika *CON* jest bardziej negatywna ($R = -0.38$, $R^2 = 0.14$), co ponownie potwierdza, że większa koncentracja mocy redukowała prawdopodobieństwo konfliktów w XX wieku. Wskaźniki ΔCON ($R = 0.31$, $R^2 = 0.10$) oraz *MOVE* ($R = 0.27$, $R^2 = 0.07$) zachowują dodatnią korelację, choć ich siła jest mniejsza w porównaniu do XIX wieku. Oznacza to, że w XX wieku ruch i zmiany koncentracji mocy miały mniej bezpośredni wpływ na wystąpienie konfliktów niż w poprzednim stuleciu.

Porównując te wyniki z analizami Singera (Dodatek: Tabela 2.26), można zauważyć podobieństwa w ogólnych trendach. Jednak wskaźnik ΔCON w modelu Singera jest ujemny dla całego okresu oraz XX wieku, co wskazuje na różnice w metodologii lub interpretacji wyników. Z kolei wskaźnik *MOVE* w obu analizach pokazuje zmienność w zależności od okresu, ale zachowuje dodatnią korelację.

Podsumowując, analiza korelacji wskazuje, że wskaźniki te w różnym stopniu przyczyniają się do wyjaśnienia dynamiki konfliktów w różnych okresach historycznych. Ruch mocy (*MOVE*) był kluczowym predyktorem konfliktów w XIX wieku, natomiast koncentracja zasobów (*CON*) miała większe znaczenie w XX wieku, przy jednoczesnym mniejszym wpływie zmian w koncentracji (ΔCON). Wyniki te podkreślają złożoność dynamiki systemu międzynarodowego i konieczność uwzględnienia różnych czynników w zależności od okresu historycznego.

Analiza wielowymiarowa

Rozdział ten jest poświęcony matematycznej analizie modeli konfliktów zbrojnych opracowanych przez J. Davida Singera, z uwzględnieniem specyfiki ich zastosowania w różnych okresach historycznych. W szczególności, badane są cztery modele: ADD/CON LEADS (1.7), ADD/CON LAGS (1.8), MULT/CON LEADS (1.9) oraz MULT/CON LAGS (1.10), które stanowią narzędzia do opisu i analizy dynamiki konfliktów międzynarodowych. Celem rozdziału jest ocena dopasowania tych modeli do danych empirycznych oraz identyfikacja okresów, w których poszczególne podejścia wykazują największą adekwatność.

W ramach rozdziału przeprowadzono: estymację parametrów modeli, ewaluację modeli, analizę reszt. Rozdział koncentruje się na odpowiedzi na pytanie: które z modeli Singera najlepiej opisują konflikty w określonych przedziałach czasowych? Wyniki te mają istotne znaczenie dla zrozumienia dynamicznej natury konfliktów międzynarodowych oraz możliwości zastosowania metod analizy wielowymiarowej w naukach społecznych.

Estymacja parametrów

Poniższe tabele przedstawiają wyniki estymacji parametrów dla czterech modeli regresji liniowej, analizujących wpływ koncentracji mocy (*CON*), zmian koncentracji (ΔCON) oraz ruchu mocy (*MOVE*) na zmienną zależną. Estymacje zostały przeprowadzone dla trzech różnych okresów: całego badanego zakresu lat 1820 – 1960 (Tabela 2.5), podokresu 1820 – 1890 (Tabela 2.6) oraz podokresu 1890 – 1960 (Tabela 2.7). Modele uwzględniają zarówno podejście addytywne (ADD), jak i multiplikatywne (MULT), a także różne warianty liczenia zmiennej *CON*: na początku okresu t (LEADS) oraz na końcu (LAGS).

Celem analizy jest zbadanie, w jakim stopniu wymienione wskaźniki wpływają na zmienną zależną w różnych okresach oraz które z nich są istotne statystycznie. Natomiast

wartości p-wartości pozwalają określić, czy dany współczynnik jest istotny przy założonym poziomie istotności ($\alpha = 0.05$), a same współczynniki wskazują na kierunek i siłę zależności.

Tabela 2.5: Estymowane parametry dla lat 1820 – 1960

Model	Const		CON		ΔCON		MOVE	
	α	p-wartość	β_1	p-wartość	β_2	p-wartość	β_3	p-wartość
ADD / CON LEADS	43.52	0.266	-116.20	0.373	302.07	0.584	759.93	0.449
ADD / CON LAGS	43.52	0.266	-116.20	0.373	883.08	0.212	759.93	0.449
MULT / CON LEADS	3.711	0.022	-7.594	0.149	-0.874	0.968	35.40	0.376
MULT / CON LAGS	3.711	0.022	-7.594	0.149	37.09	0.188	35.40	0.376

Źródło: opracowanie własne

Dla pełnego zakresu lat 1820 – 1960 wartość stałej (α) jest istotna statystycznie jedynie w modelach multiplikatywnych (MULT), gdzie $p = 0.022$. W modelach addytywnych (ADD) stała jest wyższa ($\alpha = 43.52$), ale nie jest istotna ($p = 0.266$).

Współczynnik dla koncentracji zasobów (β_1) jest ujemny we wszystkich modelach, co sugeruje, że większa koncentracja zasobów obniża prawdopodobieństwo wystąpienia konfliktów. Jednak w żadnym z modeli wartość p nie wskazuje istotności statystycznej ($p > 0.05$).

Zmiana koncentracji (ΔCON) ma dodatni współczynnik (β_2) w modelach addytywnych, co może sugerować, że większe zmiany koncentracji zwiększą prawdopodobieństwo konfliktów. W modelach multiplikatywnych efekt ten nie jest znaczący ($\beta_2 = -0.874$, $p = 0.968$).

Ruch mocy (MOVE) wykazuje najwyższe współczynniki ($\beta_3 = 759.93$ w ADD oraz $\beta_3 = 35.40$ w MULT). Pomimo relatywnie wysokich wartości, MOVE nie jest istotny statystycznie w żadnym z modeli ($p > 0.05$).

Tabela 2.6: Estymowane parametry dla lat 1820 – 1890

Model	Const		CON		ΔCON		MOVE	
	α	p-wartość	β_1	p-wartość	β_2	p-wartość	β_3	p-wartość
ADD / CON LEADS	0.045	0.999	-8.598	0.943	295.08	0.705	2874.89	0.119
ADD / CON LAGS	0.045	0.999	-8.5976	0.943	338.07	0.732	2874.89	0.119
MULT / CON LEADS	0.576	0.866	-1.773	0.889	-48.38	0.562	379.59	0.061
MULT / CON LAGS	0.576	0.866	-1.773	0.889	-39.52	0.707	379.59	0.061

Źródło: opracowanie własne

W okresie 1820 – 1890 wartość stałej (α) nie jest istotna we wszystkich modelach, gdzie $p >> 0.05$, choć sama wartość współczynnika ($\alpha = 0.576$) jest stosunkowo niska.

Dla wskaźnika koncentracji zasobów (CON) współczynnik jest ujemny we wszystkich modelach, co potwierdza obserwację z pełnego okresu, że większa koncentracja zmniejsza ryzyko konfliktów. Jednak współczynnik jest również nieistotny ($p >> 0.05$).

Zmiana koncentracji (ΔCON) wykazuje wartości ujemne w modelach multiplikatywnych ($\beta_2 = -39.52$, $p = 0.707$), co może sugerować odwrotną zależność, jednak brak istotności statystycznej uniemożliwia jednoznaczne wnioski. Modele addytywne wskazują na umiarkowanie dodatni efekt, również bez statystycznej istotności ($\beta_2 = 295.08$, $p = 0.705$).

Mobilność mocy (*MOVE*) ma dodatni współczynnik w modelach ADD ($\beta_3 = 2874.89$, $p = 0.119$) i MULT ($\beta_3 = 379.59$, $p = 0.061$). Chociaż nie osiąga istotności, relatywnie wysokie wartości współczynnika mogą wskazywać na potencjalny wpływ mobilności mocy na konflikty.

Tabela 2.7: Estymowane parametry dla lat 1890 – 1960

Model	Const		<i>CON</i>		ΔCON		<i>MOVE</i>	
	α	p-wartość	β_1	p-wartość	β_2	p-wartość	β_3	p-wartość
ADD / CON LEADS	64.93	0.339	-150.34	0.500	323.77	0.712	67.49	0.969
ADD / CON LAGS	64.93	0.339	-150.34	0.500	1075.49	0.340	67.49	0.969
MULT / CON LEADS	5.232	0.012	-11.43	0.072	-1.756	0.939	-6.579	0.885
MULT / CON LAGS	5.232	0.012	-11.43	0.072	55.37	0.080	-6.579	0.885

Źródło: opracowanie własne

W analizie lat 1890 – 1960 wartość stałej (α) jest wyraźnie wyższa w modelach ADD ($\alpha = 64.92$), ale nieistotna statystycznie ($p = 0.339$). W modelach MULT wartość α jest istotna ($p = 0.012$) i wynosi 5.232, co wskazuje na znaczącą podstawę modelu.

Koncentracja zasobów (*CON*) ma współczynniki ujemne we wszystkich modelach, a w modelach MULT ($\beta_1 = -11.43$, $p = 0.072$) zbliża się do istotności. Sugeruje to, że w XX wieku większa koncentracja zasobów mogła zmniejszać prawdopodobieństwo konfliktów.

Zmiana koncentracji (ΔCON) wykazuje dodatnie współczynniki w modelu MULT/CON LAGS ($\beta_2 = 55.37$, $p = 0.080$), co sugeruje, że nagłe zmiany w koncentracji mogły zwiększać ryzyko konfliktów w XX wieku, choć efekt ten nie jest statystycznie istotny.

Ruch mocy (*MOVE*) w modelach ADD i MULT ma ujemne współczynniki, co różni się od wcześniejszych okresów. Współczynnik ($\beta_3 = -6.579$, $p = 0.885$) nie wykazuje istotności, ale sugeruje zmniejszenie wpływu mobilności na konflikty w tym okresie.

Porównanie okresów. Współczynnik dla *CON* jest ujemny we wszystkich okresach i modelach, co może wskazywać na ogólną tendencję, że większa koncentracja zasobów zmniejsza prawdopodobieństwo konfliktów. W okresie 1890–1960 efekt ten jest bardziej wyraźny, choć nadal nieistotny.

Zmienna ΔCON wykazuje różne kierunki w poszczególnych okresach. W latach 1820–1890 efekt jest bardziej zmienny i umiarkowanie dodatni, natomiast w latach 1890–1960 zyskuje na znaczeniu w modelach MULT, co może wynikać z dynamicznych przemian w systemie międzynarodowym w XX wieku.

Ruch mocy (*MOVE*) wykazuje najwyższe współczynniki w okresie 1820 – 1890, co może wskazywać na jego istotne znaczenie w XIX wieku, szczególnie w modelach ADD. W XX wieku efekt mobilności słabnie.

Model MULT LAGS jest najlepszy dla całego okresu ze względu na stabilność i istotność statystyczną stałej. Model ADD LEADS dla okresu 1820 – 1890 jest najlepszy, ponieważ podkreśla istotny potencjał mobilności mocy (*MOVE*) jako kluczowego czynnika konfliktów w XIX wieku. Model MULT LAGS najlepiej opisuje okres 1890 – 1960, uwzględniając zarówno zmiany w koncentracji zasobów (ΔCON), jak i ich ogólny poziom (*CON*).

Analiza wyników dla różnych okresów wskazuje, że dynamika wskaźników *CON*, ΔCON i *MOVE* zmienia się w czasie, a ich wpływ na zmienną zależną różni się w zależności od modelu i okresu. Żaden ze wskaźników nie jest jednoznacznie istotny statystycznie, co

sugeruje konieczność dalszej analizy i weryfikacji wyników, np. poprzez zwiększenie liczby obserwacji.

Ewaluacja modeli

W ramach analizy regresji liniowej, następnym etapem była ewaluacja modelu, która obejmuje zarówno przygotowanie danych, jak i ocenę jakości dopasowania modelu do zmiennych wyjaśniających i zależnej. Proces ten rozpoczął się od standaryzacji zmiennych, która jest istotnym krokiem w przypadku analizy wielowymiarowej. Standaryzacja polega na przekształceniu zmiennych, tak aby miały średnią równą zero i odchylenie standardowe równe jeden. Ponadto standaryzacja poprawia stabilność obliczeń i eliminuje problemy związane z różnicami w skalach zmiennych.

Kolejnym krokiem było obliczenie współczynnika korelacji wielokrotnej R , oraz R^2 . Jednakże, aby uwzględnić liczbę zmiennych i obserwacji w modelu, obliczono również skorygowany współczynnik determinacji \bar{R}^2 . Jest to bardziej precyzyjna miara, która karze model za nadmierną liczbę predyktorów, chroniąc przed problemem przeuczenia.

Istotnym elementem analizy były standaryzowane współczynniki regresji (b). Dzięki nim można określić, które zmienne niezależne mają największy wpływ na zmienną zależną, przy założeniu stałości pozostałych zmiennych.

Aby dokładniej zbadać wpływ każdej zmiennej niezależnej na zmienną zależną, obliczono współczynniki korelacji cząstkowej (r^2). Korelacje cząstkowe umożliwiają ocenę, które zmienne mają największe znaczenie w wyjaśnianiu zmiennej zależnej po uwzględnieniu zależności między zmiennymi niezależnymi.

Wyniki przedstawione w Tabelach 2.8, 2.9 i 2.10 pokazują dopasowanie standaryzowanych modeli regresji liniowej dla trzech różnych okresów: 1820 – 1960, 1820 – 1890 oraz 1890 – 1960.

Tabela 2.8: Dopasowanie standaryzowanych modeli dla lat 1820 – 1960

Model				CON		ΔCON		MOVE	
	R	R^2	\bar{R}^2	b	r^2	b	r^2	b	r^2
ADD / CON LEADS	0.459	0.210	0.112	-0.230	0.033	0.122	0.013	0.188	0.024
ADD / CON LAGS	0.459	0.210	0.112	-0.224	0.033	0.355	0.064	0.188	0.024
MULT / CON LEADS	0.520	0.271	0.180	-0.363	0.085	-0.008	0.000	0.211	0.033
MULT / CON LAGS	0.520	0.271	0.180	-0.354	0.085	0.360	0.071	0.211	0.033

Źródło: opracowanie własne

W Tabeli 2.8 najwyższą wartość współczynnika korelacji R osiągnęły modele MULT ($R = 0.520$), co wskazuje na lepsze dopasowanie tych modeli w porównaniu do modeli ADD. Podobnie, współczynnik determinacji R^2 oraz jego skorygowana wartość \bar{R}^2 dla tych modeli są najwyższe ($R^2 = 0.271$, $\bar{R}^2 = 0.180$). Modele ADD charakteryzują się niższymi wartościami R i R^2 , co sugeruje słabsze dopasowanie.

W analizie zmiennych niezależnych zmienna MOVE ma najwyższe wartości współczynnika regresji ($b = 0.211$) i kwadratowego współczynnika korelacji cząstkowej ($r^2 = 0.033$), co oznacza, że jest najważniejszym predyktorem w wyjaśnianiu zmiennej zależnej w tym okresie. Z kolei zmienne CON i ΔCON mają niższe wartości b i r^2 , wskazując na mniejszy wpływ na zmienność zmiennej zależnej.

Tabela 2.9: Dopasowanie standaryzowanych modeli dla lat 1820 – 1890

Model				CON		ΔCON		MOVE	
	R	R^2	\bar{R}^2	b	r^2	b	r^2	b	r^2
ADD / CON LEADS	0.546	0.298	0.087	-0.020	0.001	0.111	0.015	0.499	0.225
ADD / CON LAGS	0.546	0.298	0.087	-0.027	0.001	0.127	0.012	0.499	0.225
MULT / CON LEADS	0.562	0.316	0.111	-0.039	0.002	-0.169	0.035	0.611	0.309
MULT / CON LAGS	0.562	0.316	0.111	-0.052	0.002	-0.138	0.015	0.611	0.309

Źródło: opracowanie własne

Wyniki dla okresu 1820 – 1890 przedstawiono w Tabeli 2.9. Wartości współczynnika korelacji R i determinacji R^2 są wyższe w porównaniu do wyników dla całego okresu 1820 – 1960. Najlepsze dopasowanie obserwuje się dla modeli MULT ($R = 0.562$, $R^2 = 0.316$, $\bar{R}^2 = 0.111$), co oznacza, że w tym podokresie te modele lepiej wyjaśniają zmienność zmiennej zależnej.

Wśród zmiennych niezależnych zmienna MOVE ponownie wykazuje najwyższe wartości b ($b = 0.611$) i r^2 ($r^2 = 0.309$), potwierdzając jej kluczową rolę w modelu. Zmienna CON ma ujemny współczynnik regresji w modelach MULT ($b = -0.039$ i $b = -0.052$), co sugeruje, że jej wpływ na zmienną zależną jest odwrotny, ale mało istotny ($r^2 = 0.002$). Zmienna ΔCON również ma mniejsze znaczenie ($b = 0.015$ i $r^2 = 0.035$).

Tabela 2.10: Dopasowanie standaryzowanych modeli dla lat 1890 – 1960

Model				CON		ΔCON		MOVE	
	R	R^2	\bar{R}^2	b	r^2	b	r^2	b	r^2
ADD / CON LEADS	0.395	0.156	-0.097	-0.288	0.047	0.138	0.014	0.015	0.000
ADD / CON LAGS	0.395	0.156	-0.097	-0.281	0.047	0.458	0.091	0.015	0.000
MULT / CON LEADS	0.646	0.417	0.242	-0.688	0.288	-0.023	0.001	-0.047	0.002
MULT / CON LAGS	0.646	0.417	0.242	-0.670	0.288	0.740	0.275	-0.047	0.002

Źródło: opracowanie własne

Tabela 2.10 zawiera wyniki dla okresu 1890 – 1960. W porównaniu do wcześniejszego okresu 1820 – 1890, współczynnik korelacji R oraz determinacji R^2 są znacznie wyższe dla modeli MULT ($R = 0.646$, $R^2 = 0.417$, $\bar{R}^2 = 0.242$), co wskazuje na wyraźne zwiększenie dopasowania modelu w tym okresie. Modele ADD mają znacznie niższe wartości R i R^2 ($R = 0.395$, $R^2 = 0.156$), co sugeruje ich słabszą zdolność do wyjaśniania zmienności zmiennej zależnej.

W tym okresie zmienna CON w modelach MULT osiąga stosunkowo wysokie bezwzględne wartości b ($b = -0.670$ i $b = -0.688$) oraz r^2 ($r^2 = 0.288$), co wskazuje na jej wpływ na zmienność zmiennej zależnej. Zmienna MOVE również pozostaje istotnym predyktorem ($b = -0.047$, $r^2 = 0.002$), jednak jej znaczenie jest mniejsze w porównaniu do wcześniej analizowanych okresów. Zmienna ΔCON w modelu MULT / CON LAGS odnotowuje najwyższe wartości współczynnika regresji ($b = 0.740$) i kwadratowego współczynnika korelacji cząstkowej ($r^2 = 0.275$), co sugeruje, że jej rola w wyjaśnianiu zmienności zmiennej zależnej rośnie w późniejszym okresie.

Przy porównywaniu wyników przeprowadzonej analizy z wynikami J. D. Singera (Dodatek: Tabela 2.27) istnieją istotne różnice w ocenie dopasowania modeli. Dla całego

okresu 1820 – 1960 Singer uznał modele ADD za lepiej dopasowane ($R = 0.56$, $R^2 = 0.31$) w porównaniu do modeli MULT, które uzyskują niższe wartości ($R = 0.43$, $R^2 = 0.19$). W niniejszych analizach wyniki sugerują przewagę modeli MULT ($R = 0.520$, $R^2 = 0.271$) nad modelami ADD, co może być efektem różnic w wersji wykorzystywanej zbioru danych.

Podsumowując, wyniki wskazują, że modele MULT lepiej wyjaśniają zmienność zmiennej zależnej niż modele ADD w każdym z analizowanych okresów. Rola zmiennej *MOVE* jest istotna w całym analizowanym przedziale czasowym, szczególnie w okresie 1820 – 1890. W późniejszym okresie (1890 – 1960) wzrasta znaczenie zmiennych *CON* i ΔCON , co może odzwierciedlać zmieniającą się dynamikę systemu międzynarodowego oraz wzrost znaczenia koncentracji i ruchu mocy w kontekście konfliktów zbrojnych. Wyniki sugerują, że modele MULT są bardziej adekwatne do analizy zależności w systemie międzynarodowym, szczególnie w okresie XX wieku.

Wykresy ilustrujące dopasowanie modeli

W rozdziale tym przedstawione zostały wyniki modelowania dla różnych wersji modeli ADD i MULT, obrazujące dopasowanie prognozowanych wartości liczby konfliktów (*WAR*) do rzeczywistych danych historycznych. Wykresy umożliwiają ocenę jakości przewidywań każdego modelu w analizowanych okresach (1820 – 1960, 1820 – 1890, 1890 – 1960) oraz porównanie ich efektywności. Dodatkowo, analiza obejmuje średnie błędy kwadratowe (MSE) i bezwzględne (MAE). Wskaźniki te stanowią kluczowe narzędzia w ocenie dokładności modeli, pozwalając na obiektywne porównanie ich skuteczności w przewidywaniu liczby konfliktów.

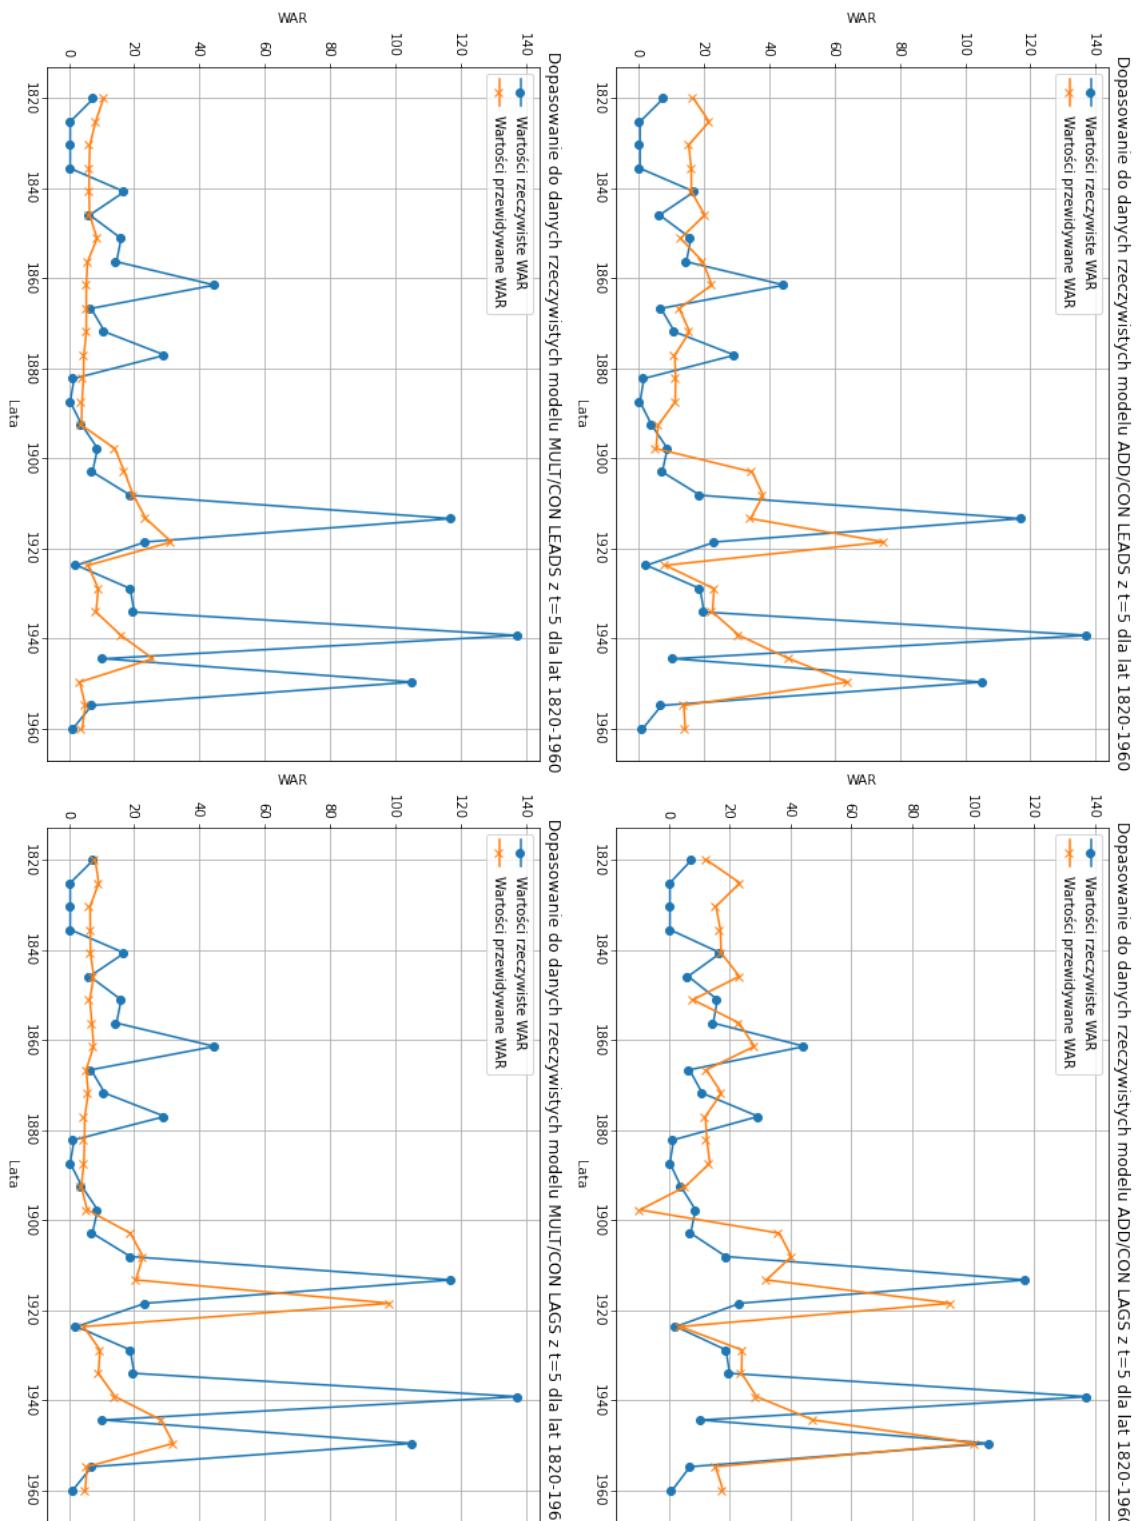
Średni błąd kwadratowy (MSE) mierzy średnią różnicę między prognozowanymi a rzeczywistymi wartościami, podnosząc tę różnicę do kwadratu, co podkreśla większe odchylenia i penalizuje znaczące błędy. Z kolei średni błąd bezwzględny (MAE) przedstawia średnią wartość odchyleń bezwzględnych, co pozwala lepiej uchwycić typowy poziom błędów bez ich kwadratowania [4]. Dzięki temu MSE dostarcza informacji o ekstremach, natomiast MAE lepiej obrazuje ogólną trafność prognoz. Wyniki tych obliczeń zostały przedstawione poniżej w Tabeli 2.11.

Tabela 2.11: Średni błąd bezwzględny (MAE) oraz kwadratowy (MSE) dla modeli w trzech okresach czasowych

Model	1820 – 1960		1820 – 1890		1890 – 1960	
	MAE	MSE	MAE	MSE	MAE	MSE
ADD/ CON LEADS	19.93	988.23	8.52	106.83	31.26	1756.20
ADD/ CON LAGS	20.48	1060.59	8.56	106.87	32.88	1984.84
MULT/ CON LEADS	18.35	1330.60	6.36	108.02	28.19	2382.69
MULT/ CON LAGS	19.94	1383.13	6.20	102.14	28.35	2220.72

Źródło: opracowanie własne

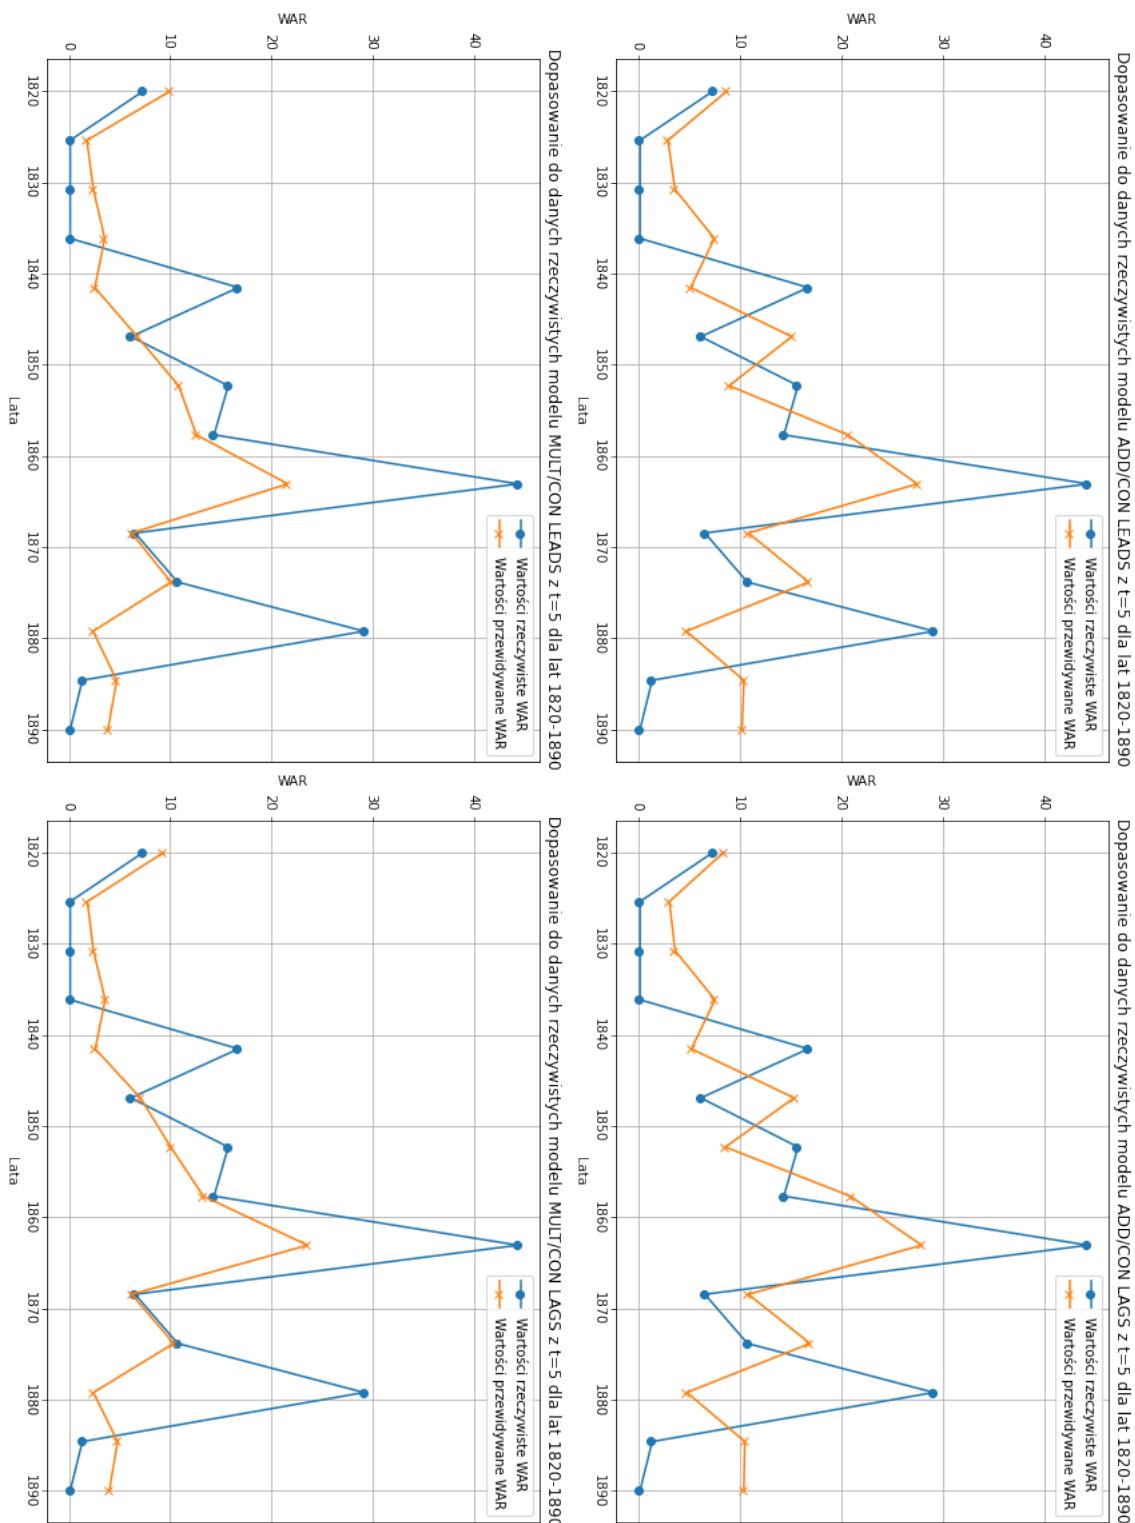
Na Rysunku 2.1 przedstawiono wykresy dopasowania czterech rozpatrywanych modeli dla całego okresu (1820 – 1960). Modele ADD wykazują zauważalne wahania w prognozach w porównaniu do rzeczywistych wartości. Wyniki wskazują, że wartości przewidywane przez te modele często odbiegają od rzeczywistej liczby konfliktów, co prowadzi do umiarkowanego



Rysunek 2.1: Dopasowanie modeli dla lat 1820 – 1960

dopasowania. Średni błąd kwadratowy (MSE) dla modeli ADD wynosi odpowiednio 988.23 (LEADS) i 1060.59 (LAGS), a średni błąd bezwzględny (MAE) to 19.93 i 20.48. Z kolei modele MULT charakteryzuje się nieco wyższym MSE (1330.60 i 1383.13), co świadczy o ich większej zmienności, ale także lepszym odwzorowaniu wysokich wartości WAR . MAE dla modeli MULT wynosi odpowiednio 18.35 (LEADS) i 19.94 (LAGS), co wskazuje na

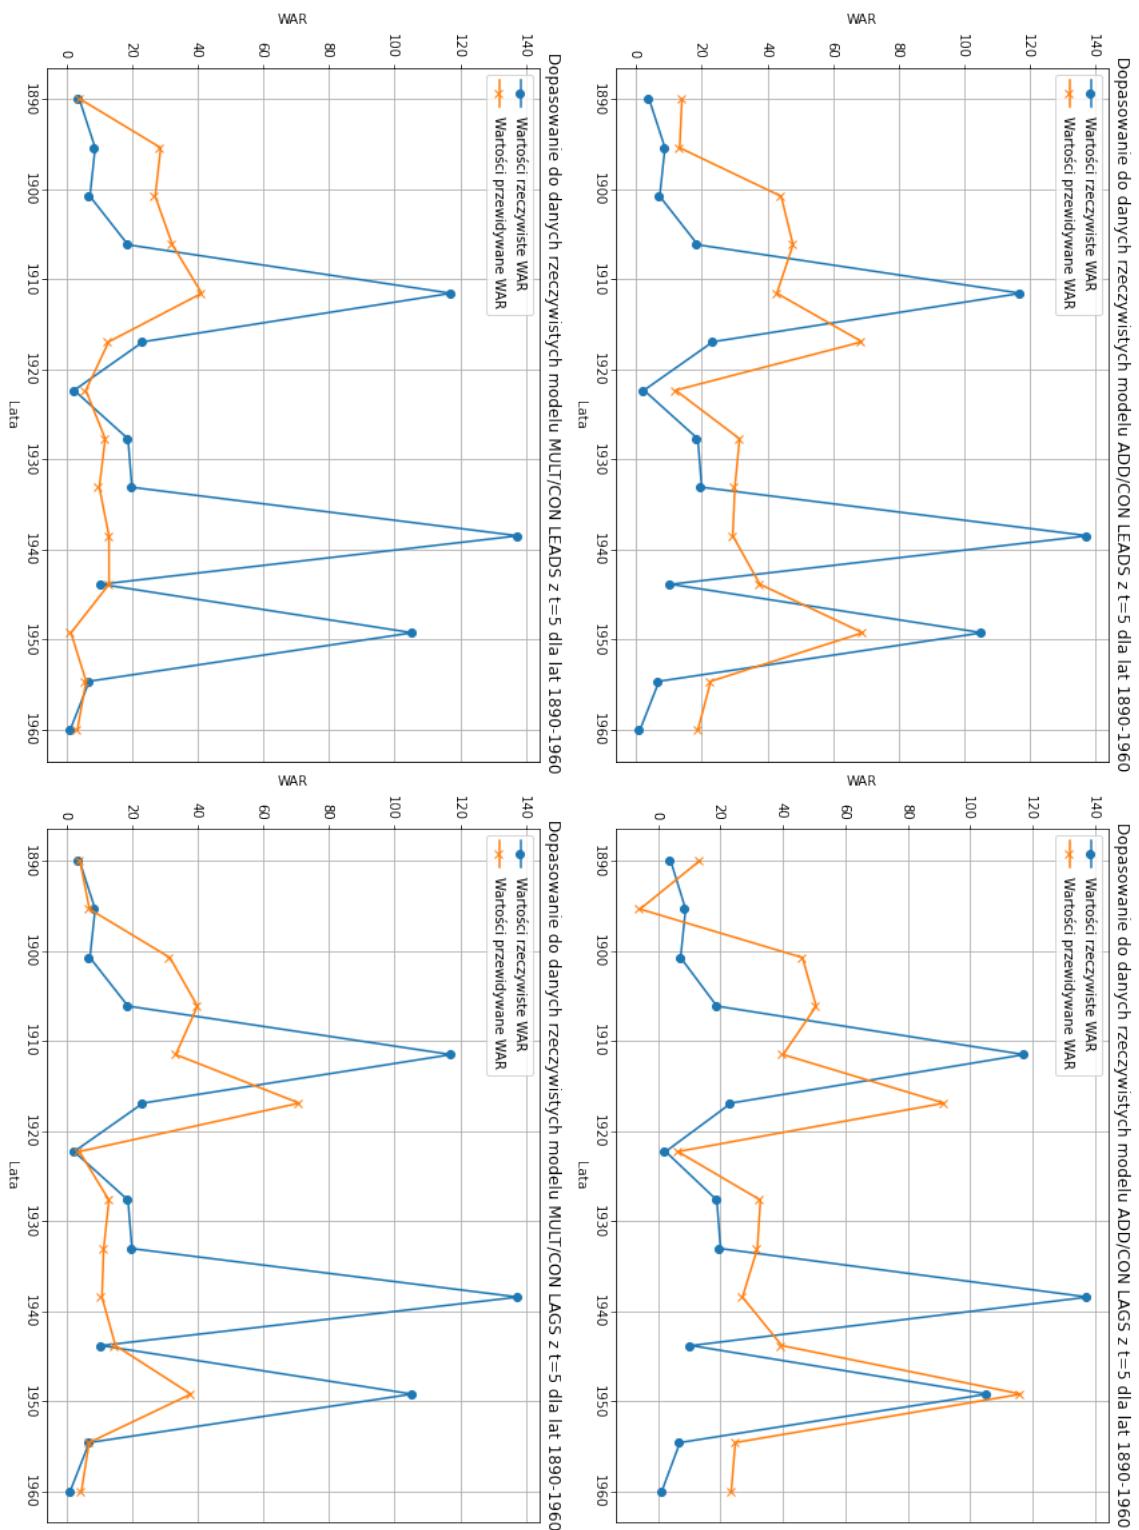
ich większą trafność w prognozowaniu wartości o większej dynamice.



Rysunek 2.2: Dopasowanie modeli dla lat 1820 – 1890

Na Rysunku 2.2 zaprezentowane są wyniki dla XIX wieku (1820 – 1890). W tym okresie modele MULT, zarówno w wersji LEADS, jak i LAGS, wykazują lepsze dopasowanie do rzeczywistych danych niż w poprzednim rozpatrywanym okresie. Średni błąd kwadratowy (MSE) dla tych modeli wynosi 106.83 i 106.87, a średni błąd bezwzględny (MAE) to

odpowiednio 8.52 i 8.56. Modele MULT w tym okresie mają nieco wyższe wartości MSE: 108.02 (LEADS) i 102.14 (LAGS). Niemniej jednak, MAE dla modeli MULT, wynoszące 6.36 i 6.20, wskazuje na ich większą dokładność w prognozowaniu. Analiza wykresów sugeruje, że modele MULT/CON LAGS najlepiej reagują na dynamiczne zmiany w danych, co czyni je skuteczniejszymi w uchwyceniu lokalnych fluktuacji.



Rysunek 2.3: Dopasowanie modeli dla lat 1890 – 1960

Na Rysunku 2.3 przedstawiono dopasowanie modeli dla XX wieku (1890–1960). W tym okresie modele MULT osiągają lepsze wyniki niż modele ADD, co znajduje odzwierciedlenie w niższych wartościach MAE. Średni błąd kwadratowy (MSE) dla modeli MULT wynosi 2382.69 (LEADS) i 2220.72 (LAGS), co jest wyższe niż w przypadku ADD. Jednakże wartości MAE, odpowiednio 28.19 i 28.35, wskazują na ich większą zdolność odwzorowywania zmienności w danych rzeczywistych. Modele ADD mają znacznie wyższe wartości MSE (1756.20 i 1984.84) oraz MAE (31.26 i 32.88), co świadczy o ich trudności w uchwyceniu bardziej dynamicznych zmian w systemie międzynarodowym XX wieku.

Przedstawione wyniki pokazują, że modele ADD lepiej sprawdzają się w XIX wieku, gdzie dynamika geopolityczna była relatywnie niższa, co skutkowało mniejszymi błędami predykcji. Z kolei w XX wieku, charakteryzującym się większymi zmianami i wyższą dynamiką konfliktów, lepsze dopasowanie uzyskują modele MULT, zwłaszcza MULT/CON LAGS. Wskazuje to na ich większą zdolność do reagowania na zmienność danych i wychwytywania istotnych zmian. Warto podkreślić, że modele LAGS w obu grupach (ADD i MULT) mają większą wrażliwość na nagłe skoki w danych, co czyni je bardziej efektywnymi w analizach dynamicznych okresów historycznych.

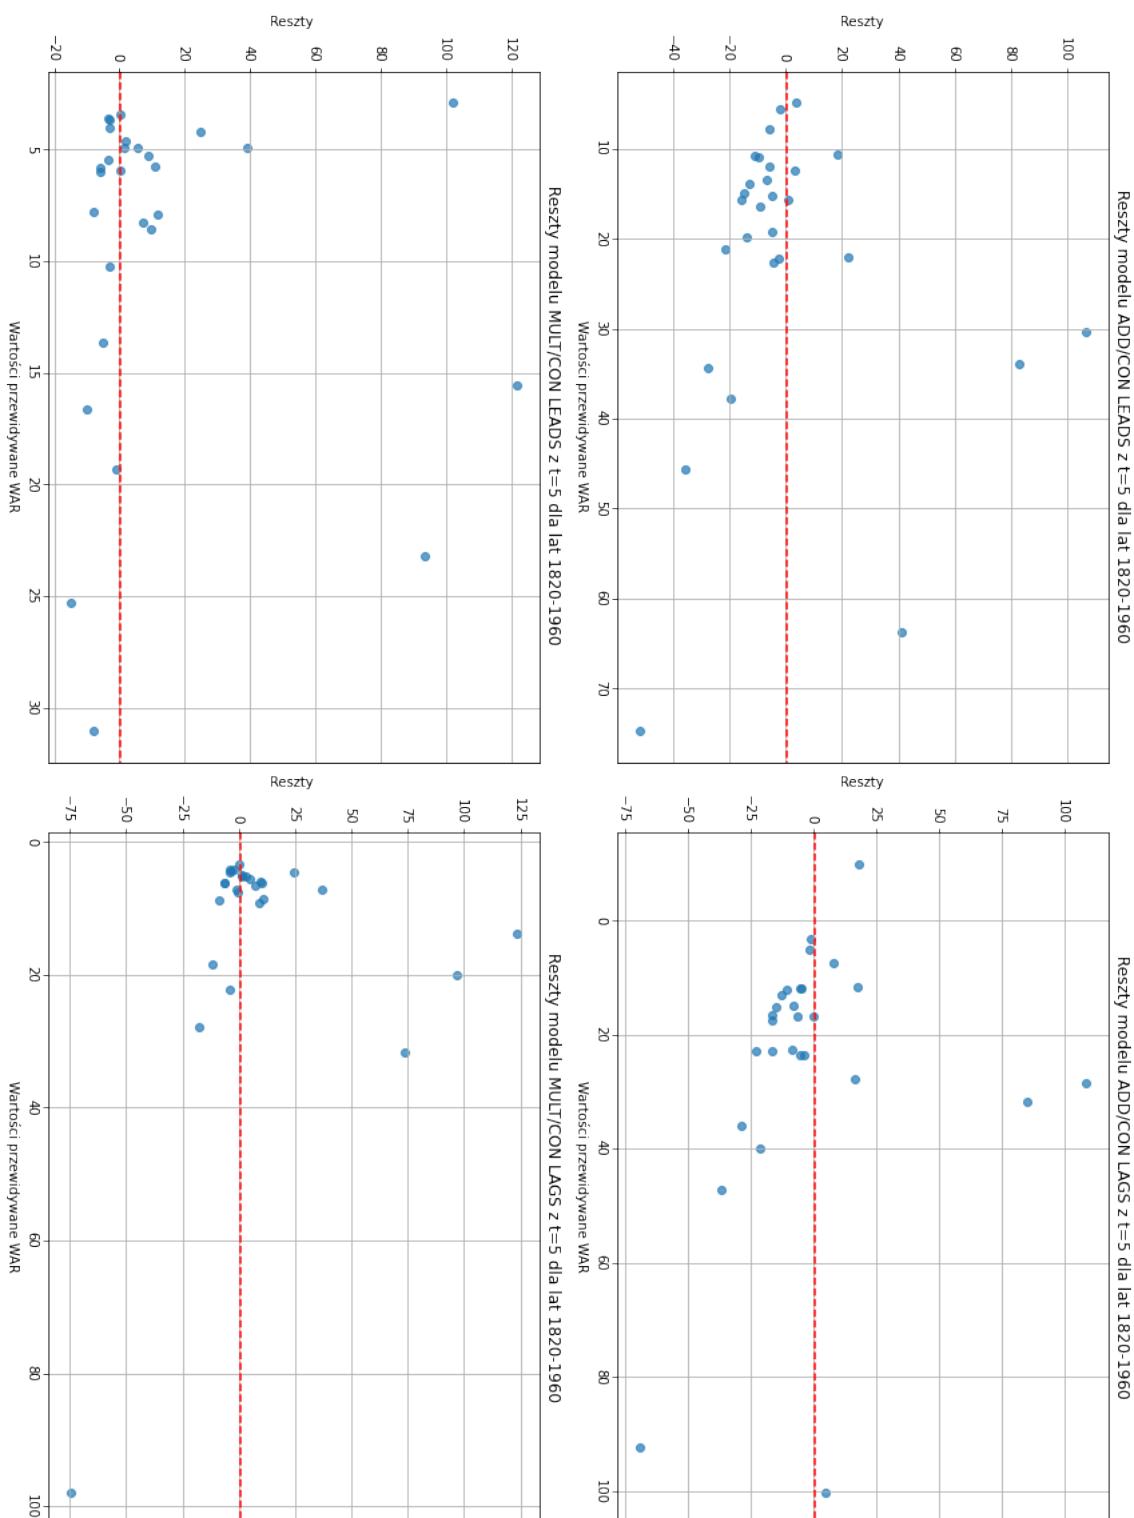
Analiza reszt

W rozdziale tym zaprezentowano graficzną analizę reszt, czyli różnic pomiędzy wartościami rzeczywistymi (*WAR*) a wartościami przewidywanymi przez modele regresyjne. Reszty są kluczowym elementem oceny jakości modelu, gdyż pozwalają zidentyfikować potencjalne problemy z dopasowaniem modelu do danych. Przedstawione wykresy umożliwiają wizualizację rozkładu reszt w zależności od wartości przewidywanych dla różnych modeli (ADD/CON LEADS, ADD/CON LAGS, MULT/CON LEADS, MULT/CON LAGS) i okresów czasowych (1820 – 1960, 1820 – 1890, 1890 – 1960). Celem analizy jest ocena, czy reszty są losowo rozproszone wokół osi poziomej (wartości przewidywane), co świadczyłoby o poprawności założeń modelu, w tym liniowości, homoskedastyczności i normalności błędów.

Na Rysunku 2.4, przedstawiającym wyniki dla okresu 1820 – 1960, modele ADD wykazują bardziej skoncentrowane rozproszenie reszt wokół wartości przewidywanych. Jednakże widoczne są pewne punkty odstające, co świadczy o niedopasowaniu modeli w przypadku ekstremalnych wartości *WAR*. Modele MULT cechują się większym zakresem reszt, co oznacza, że mają trudności w przewidywaniu wartości rzeczywistych w tak szerokim okresie. Model MULT/CON LAGS lepiej reaguje na skoki w danych, co czyni go bardziej przydatnym w analizach obejmujących dynamiczne zmiany w liczbie konfliktów.

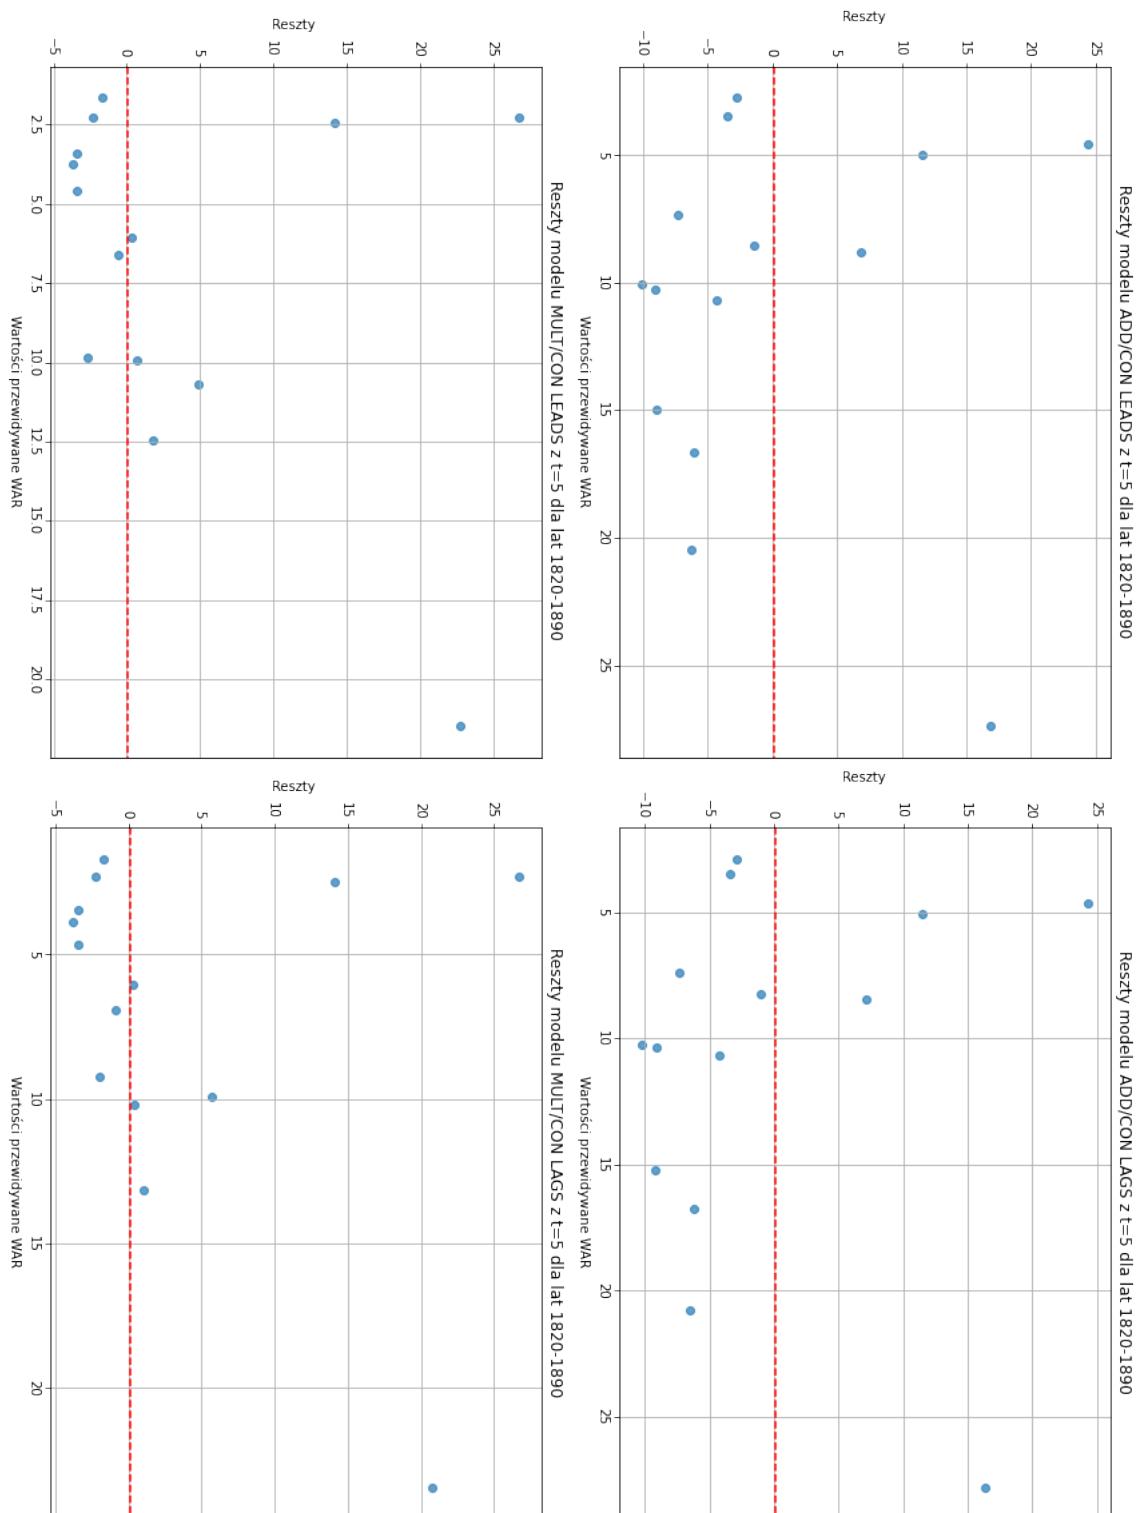
Na Rysunku 2.5 dla XIX wieku (1820 – 1890) modele ADD, a zwłaszcza ADD/CON LAGS, charakteryzują się bardziej równomiernym rozmieszczeniem reszt oraz mniejszym zakresem błędów. Wskazuje to na ich lepsze dopasowanie do danych w okresie historycznym o względnie niskiej dynamice. Modele MULT, choć cechują się większą zmiennością reszt, dobrze radzą sobie z prognozowaniem wartości odstających, co czyni je bardziej odpowiednimi do analizy nagłych zdarzeń.

Na Rysunku 2.6 dla lat 1890 – 1960 modele MULT wykazują lepsze dopasowanie niż modele ADD. Reszty dla modelu MULT/CON LAGS są bardziej skoncentrowane wokół zera, co wskazuje na mniejsze błędy prognoz w tym dynamicznym okresie. W modelach ADD, szczególnie ADD/CON LEADS, obserwuje się większe rozproszenie reszt, co sugeruje trudności w przewidywaniu wartości rzeczywistych w czasach intensywnych zmian geopolitycznych.

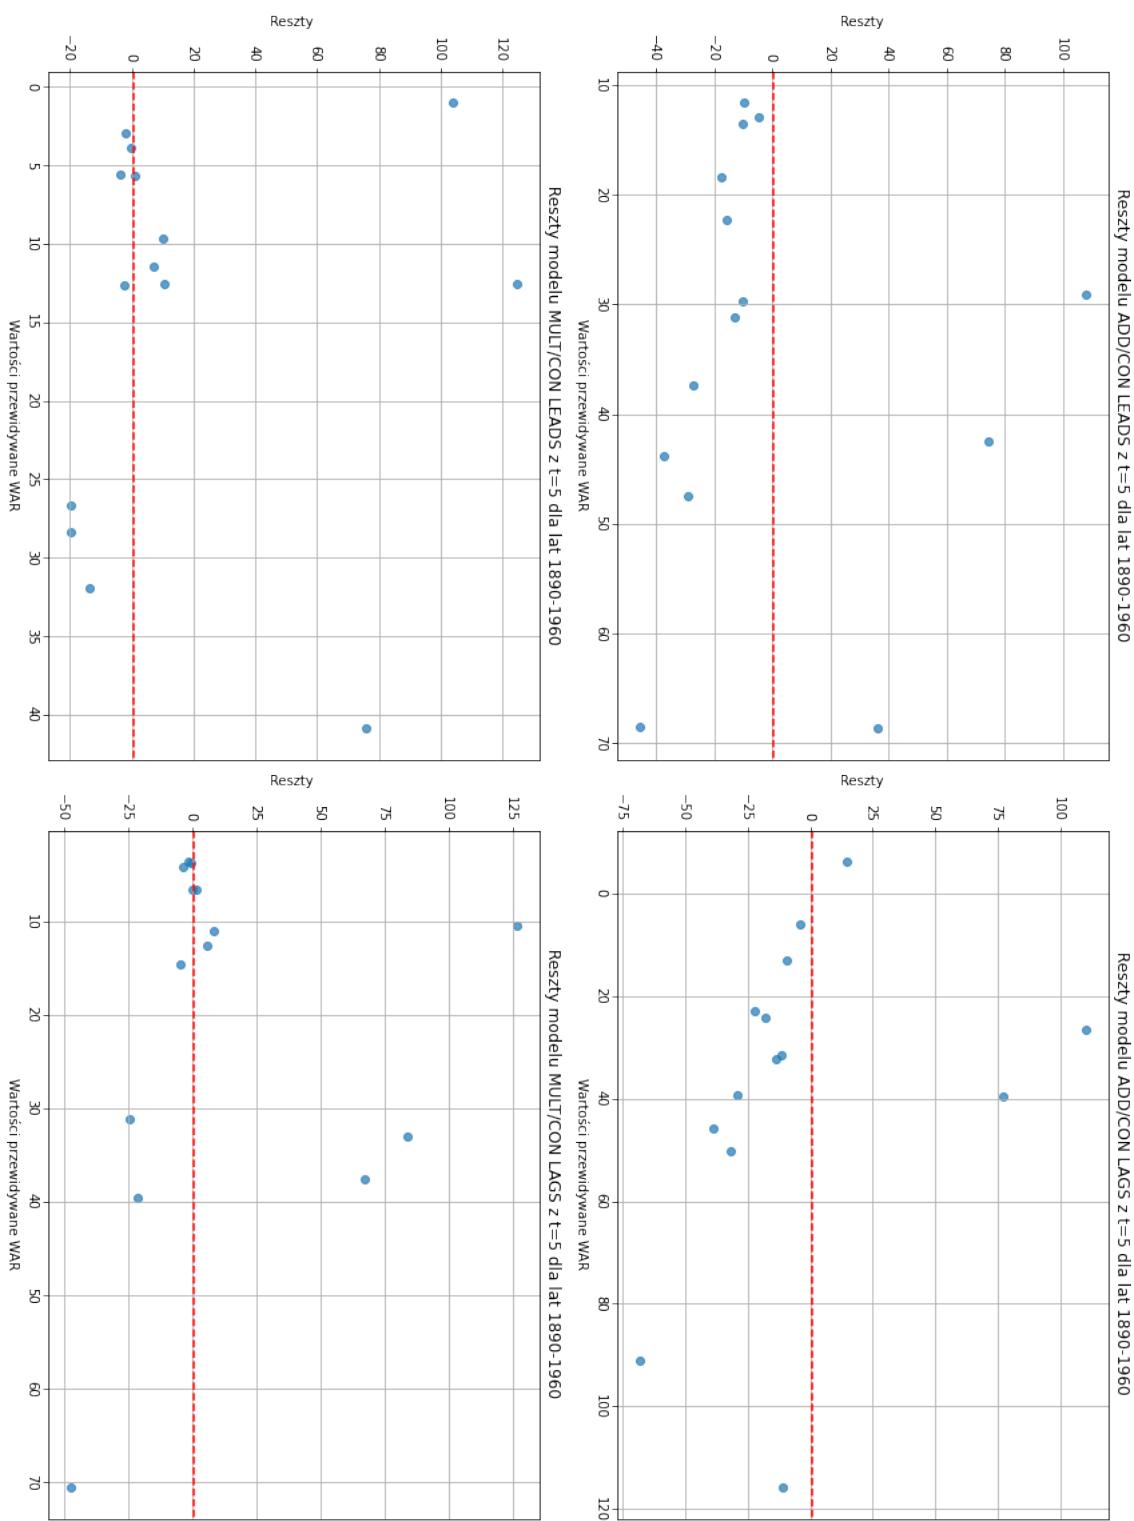
Rysunek 2.4: Reszty (ϵ) dla lat 1820 – 1960

Przeprowadzone testy Shapiro-Wilka dla wszystkich modeli i okresów wykazały, że reszty nie mają rozkładu normalnego. Może to wskazywać na niezgodność z założeniami modeli lub na konieczność ich dalszej optymalizacji.

Analizując wszystkie trzy rysunki, można zauważyc, że modele ADD/CON LAGS najlepiej sprawdzają się w stabilnych okresach, takich jak 1820 – 1890, gdzie reszty

Rysunek 2.5: Reszty (ϵ) dla lat 1820 – 1890

są najmniej rozproszone. Z kolei w dynamicznych okresach, takich jak 1890 – 1960, modele MULT/CON LAGS osiągają lepsze dopasowanie, co widać w mniejszych błędach reszt. Modele LEADS w obu grupach (ADD i MULT) mają trudności z przewidywaniem ekstremalnych wartości WAR , co świadczy o ich ograniczeniach w reagowaniu na nagłe zmiany.

Rysunek 2.6: Reszty (ϵ) dla lat 1890 – 1960

Analiza reszt pokazuje, że LAGS są bardziej skuteczne w przewidywaniu dynamicznych zmian, szczególnie w okresach intensywnych transformacji historycznych, takich jak XX wiek. Modele ADD wykazują lepsze dopasowanie w okresach o mniejszej dynamice, takich jak XIX wiek. Wyniki te podkreślają znaczenie doboru odpowiedniego modelu w zależności od specyfiki analizowanego okresu historycznego. Brak normalności reszt jest wskazaniem

do dalszych analiz w celu poprawy jakości predykcji modeli.

Podsumowanie

Przeprowadzona analiza modelu Singera pozwoliła na szczegółową ocenę czterech wersji modelu Singera (CON , ΔCON , $MOVE$) w trzech różnych okresach: 1820 – 1960, 1820 – 1890 oraz 1890 – 1960. Wyniki wskazują, że wybór najlepszego modelu zależy od dynamiki badanego okresu. W XIX wieku, charakteryzującym się większą stabilnością międzynarodową, lepsze dopasowanie uzyskały modele ADD, zwłaszcza ADD/CON LEADS, które osiągały niższe wartości błędów predykcji (MSE i MAE) oraz wyższe R^2 . Wartości przewidywane przez te modele były bliższe rzeczywistym danym, co świadczy o ich trafności w mniej dynamicznych warunkach.

W XX wieku, który charakteryzował się większą zmiennością i dynamiką geopolityczną, wyższą skutecznością wykazały się modele MULT, a zwłaszcza MULT/CON LAGS. Te modele lepiej odwzorowywały nagłe zmiany w danych, co potwierdzają zarówno wyniki błędów predykcji, jak i analiza reszt. Modele MULT okazały się bardziej elastyczne i zdolne do uchwycenia złożoności systemu międzynarodowego w tym okresie.

Podsumowując, modele ADD sprawdzają się lepiej w okresach stabilnych, natomiast modele MULT, szczególnie z opóźnieniami (LAGS), lepiej radzą sobie w bardziej dynamicznych warunkach. Ostateczny wybór modelu powinien być dostosowany do specyfiki badanego okresu oraz celów analizy, z uwzględnieniem różnic w dynamice systemu międzynarodowego. Modele MULT/CON LAGS można uznać za bardziej wszechstronne w badaniach dotyczących XX wieku, natomiast ADD/CON LEADS pozostają skuteczne w analizie stabilniejszych okresów historycznych.

2.2 Własna analiza modelu Singera ze zmianą parametru t

W tej części pracy zostanie przeprowadzona własna analiza modelu Singera, uwzględniająca modyfikację kluczowego parametru czasowego t . Dotychczasowe badania Singera opierały się na założeniu, że zmienne predyktry są obliczane dla okresów pięcioletnich ($t = 5$), co pozwalało na uwzględnienie pewnych zmian w dynamice systemu międzynarodowego. Celem niniejszego rozdziału jest zbadanie, w jaki sposób zmiana wartości parametru t wpływa na skuteczność modelu w przewidywaniu wojen.

Statystyki opisowe

Tabele 2.12 i 2.13 prezentują statystyki opisowe dla zmiennych liczonych z $t = 1$ oraz $t = 10$ w różnych przedziałach czasowych: 1820 – 1960, 1820 – 1890 oraz 1890 – 1960. Analiza tych tabel pozwala zidentyfikować różnice w zmiennych modelowych w zależności od okresu.

Tabela 2.12: Statystyki opisowe dla zmiennych liczonych dla $t = 1$ we wszystkich okresach

1820 – 1960							
Zmienna	Wartość oczekiwana	Odchylenie standardowe	Max	Min	Medianą	Skośność	Kurtoza
WAR	8.6214	14.4931	71	0	0	2.1154	4.2456
CON	0.2592	0.0722	0.4335	0.0394	0.2719	-0.6882	0.5447
ΔCON	0.0009	0.0416	0.2231	-0.1434	0.0017	1.0144	10.6564
$MOVE$	0.0211	0.0186	0.133	0.003	0.0149	2.6987	10.5432
1820 – 1890							
Zmienna	Wartość oczekiwana	Odchylenie standardowe	Max	Min	Medianą	Skośność	Kurtoza
WAR	5.1286	9.4684	35	0	0	1.9679	2.7709
CON	0.2816	0.0330	0.3381	0.2045	0.2844	-0.5248	-0.368
ΔCON	0.0014	0.0147	0.0384	-0.065	0.0022	-0.8967	6.2015
$MOVE$	0.0145	0.0098	0.0542	0.0034	0.0115	1.956	4.5694
1890 – 1960							
Zmienna	Wartość oczekiwana	Odchylenie standardowe	Max	Min	Medianą	Skośność	Kurtoza
WAR	12.1143	17.571	71	0	5	1.683	1.994
CON	0.2368	0.0916	0.4335	0.0394	0.2425	-0.007	-0.6832
ΔCON	0.0004	0.0572	0.2231	-0.1434	0.0015	0.8394	4.9419
$MOVE$	0.0276	0.0227	0.133	0.003	0.0206	2.1666	6.4702

Źródło: opracowanie własne

Tabela 2.13: Statystyki opisowe dla zmiennych liczonych dla $t = 10$ we wszystkich okresach

1820 – 1960							
Zmienna	Wartość oczekiwana	Odchylenie standardowe	Max	Min	Medianą	Skośność	Kurtoza
WAR	27.9286	28.0239	91	0	16.95	1.2859	0.7024
CON	0.2596	0.0603	0.342	0.1462	0.2656	-0.6512	0.0189
ΔCON	0.0012	0.0089	0.023	-0.0174	0.0019	0.3144	3.1663
$MOVE$	0.0057	0.0039	0.0153	0.0019	0.004	1.488	1.6884
1820 – 1890							
Zmienna	Wartość oczekiwana	Odchylenie standardowe	Max	Min	Medianą	Skośność	Kurtoza
WAR	12.6429	11.3995	34.2	0	8.5	1.1447	1.4965
CON	0.2737	0.0237	0.314	0.2431	0.2717	0.6547	0.1679
ΔCON	0.0016	0.0016	0.0029	-0.0019	0.002	-2.05	4.5655
$MOVE$	0.0031	0.0008	0.0042	0.0019	0.0031	-0.1886	-1.2623
1890 – 1960							
Zmienna	Wartość oczekiwana	Odchylenie standardowe	Max	Min	Medianą	Skośność	Kurtoza
WAR	43.2143	32.0379	91	8.4	37.2	0.4359	-1.4821
CON	0.2454	0.0827	0.342	0.1462	0.2429	-0.0086	-1.8607
ΔCON	0.0009	0.0130	0.023	-0.0174	-0.0003	0.3758	0.5561
$MOVE$	0.0083	0.0041	0.0153	0.0038	0.0071	0.8151	-0.1072

Źródło: opracowanie własne

W analizie statystycznej zmiennych opisujących konflikty zbrojne, takich jak WAR , CON , ΔCON i $MOVE$, przeprowadzono porównanie wyników dla podziałów czasowych, kiedy $t = 1$ oraz $t = 10$ (Tabele 2.12, 2.13) z wynikami dla $t = 5$ w rozdziale 2.1 „Statystyki opisowe zmiennych modelu”. Poniżej przedstawiono kluczowe obserwacje i wnioski wynikające z analizy tabel.

Wartość oczekiwana dla zmiennej WAR wyraźnie rośnie wraz z wydłużaniem przedziału czasowego t . Wyniki dla $t = 10$ pokazują wyższą wartość oczekiwana liczby konfliktów zbrojnych w porównaniu do $t = 5$ i $t = 1$, co wynika z kumulacji konfliktów w dłuższym okresie. Tendencje rozkładu liczby konfliktów pozostają jednak spójne – w XIX wieku liczba wojen była zauważalnie mniejsza niż w XX wieku, co odzwierciedla zmiany w dynamice geopolitycznej i intensyfikację konfliktów w okresach późniejszych.

Dla zmiennych CON i $MOVE$ tendencje są stabilne niezależnie od wartości t . Wartości oczekiwane dla tych zmiennych wskazują na podobne zależności w różnych okresach czasowych. Jednocześnie dla $MOVE$ można zauważać, że wartość ta jest większa dla $t = 1$ niż dla $t = 5$ i $t = 10$, co sugeruje większe fluktuacje ruchów w krótszych przedziałach czasowych.

Analiza ΔCON pokazuje podobne tendencje w różnych okresach czasowych dla $t = 1$ i $t = 10$. Wartości te odzwierciedlają stabilność zmian w zmiennej CON , ale dla $t = 5$ zachowanie tej zmiennej różni się, co może wskazywać na inne dynamiki w średnich przedziałach czasowych. Mimo to, średnie wartości CON i ΔCON są zbliżone dla wszystkich analizowanych t , co świadczy o ich stabilności jako wskaźników w badaniu dynamiki konfliktów.

Rozkłady zmiennych WAR , CON , ΔCON , i $MOVE$ w analizowanych okresach wskazują na asymetrię, szczególnie dla WAR i $MOVE$, gdzie dominują wartości dodatnie. Wyniki dla CON są bardziej symetryczne, a kurtoza zmiennych takich jak ΔCON wskazuje na obecność wartości odstających, co wymaga uwzględnienia w dalszej interpretacji wyników.

Podsumowując, analiza wyników statystycznych dla różnych t pokazuje zgodność kluczowych trendów, przy jednoczesnym ujawnieniu różnic w zachowaniu zmiennych takich jak $MOVE$ i ΔCON w zależności od długości analizowanego przedziału czasowego. Te różnice oraz spójności potwierdzają, że modele są wrażliwe na długość okresów czasowych.

Analiza dwuwymiarowa

Celem tego rozdziału jest zbadanie zależności między wybranymi zmiennymi niezależnymi a prawdopodobieństwem wystąpienia konfliktów zbrojnych w różnych przedziałach czasowych. Analiza opiera się na obliczeniu współczynnika korelacji (R) oraz współczynnika determinacji (R^2) dla zmiennych CON , ΔCON , $MOVE$. Wyniki zostały przedstawione dla dwóch różnych wartości $t = 1$ i $t = 10$ w Tabeli 2.14 i porównane z wynikami obliczeń korelacji dla zmiennych liczonych co 5 lat przedstawionych w sekcji 2.1 „Analiza dwuwymiarowa”. Badanie obejmuje zarówno cały analizowany okres 1820–1960, jak i jego podokresy: XIX wiek (1820–1890) oraz wiek XX (1890–1960). Analiza ta pozwala na identyfikację zmiennych, które wykazują stabilne zależności z występowaniem konfliktów w różnych kontekstach historycznych, oraz na ocenę optymalnej długości przedziału czasowego t do modelowania tych zależności.

Tabela 2.14: Korelacja zmiennych niezależnych z prawdopodobieństwem wystąpienia wojny dla różnych okresów czasowych z podziałami $t = 1$ oraz $t = 10$

Wskaźnik	1820 – 1960		1820 – 1890		1890 – 1960	
	R	R^2	R	R^2	R	R^2
$t = 1$						
<i>CON</i>	-0.34	0.11	0.18	0.03	-0.38	0.14
ΔCON	0.04	0.00	0.06	0.00	0.05	0.00
<i>MOVE</i>	0.43	0.19	0.00	0.00	0.47	0.22
$t = 10$						
<i>CON</i>	-0.42	0.18	-0.11	0.01	-0.40	0.16
ΔCON	0.25	0.06	0.52	0.27	0.33	0.11
<i>MOVE</i>	0.47	0.22	0.17	0.03	0.13	0.02

Źródło: opracowanie własne

Wyniki analizy korelacji dla różnych wartości t wskazują na istotne różnice w skuteczności modeli w zależności od przyjętego przedziału czasowego. Dla $t = 10$ i $t = 5$ uzyskano stosunkowo dobre dopasowanie dla różnych zmiennych, natomiast wyniki dla $t = 1$ wykazują najgorsze wartości współczynnika determinacji (R^2). Dla $t = 1$ jedynie zmienne *CON* i *MOVE* cechują się stabilnością, szczególnie w analizie całego okresu (1820 – 1960) oraz wieku XX (1890 – 1960).

Warto zauważyć, że zmienna *CON* jest zawsze ujemnie skorelowana z prawdopodobieństwem wystąpienia wojny, z wyjątkiem $t = 1$ w wieku XIX (1820 – 1890), gdzie przyjmuje wartość dodatnią. Jest to zgodne z teoretycznymi założeniami, które sugerują, że wyższe wartości *CON* (koncentracji mocy) powinny obniżać ryzyko konfliktu. Z kolei ΔCON i *MOVE* są zawsze pozytywnie skorelowane, niezależnie od wartości t , co wskazuje na ich stały związek z prawdopodobieństwem wystąpienia konfliktów, szczególnie w krótszych okresach czasowych.

Dla całego analizowanego okresu (1820 – 1960) najlepiej działają zmienne policzone dla $t = 5$, co można przypisać zrównoważonemu podejściu między krótkoterminowymi fluktuacjami a długoterminowymi trendami. Wartości R^2 są dla nich wyższe w porównaniu do $t = 1$ i porównywalne z $t = 10$, co wskazuje, że zmienne te najlepiej uchwytują dynamikę badanych procesów.

Współczynnik determinacji (R^2) w przypadku $t = 1$ jest ogólnie niski, co sugeruje, że modele nie są w stanie dostatecznie dobrze uchwycić zmienności danych w krótkich okresach czasowych. Wynika to prawdopodobnie z większej losowości i mniejszej stabilności danych w krótszych przedziałach czasowych.

Optymalny przedział czasowy. Wyniki sugerują, że $t = 5$ stanowi optymalny przedział czasowy do analizy korelacji, łącząc stabilność modeli (R^2) z możliwością uchwycenia długoterminowych trendów i zmian. Wartość $t = 10$ jest również użyteczna, szczególnie dla analizy długookresowej, ale może prowadzić do utraty szczegółów dotyczących krótkoterminowych zmian.

Wyniki analizy korelacji podkreślają znaczenie odpowiedniego doboru przedziału czasowego t w badaniu dynamiki konfliktów zbrojnych. Podczas gdy $t = 5$ zapewnia najlepsze ogólne dopasowanie dla różnych zmiennych, $t = 10$ pozwala na analizę długookresowych zależności. Wyniki dla $t = 1$ wskazują na ograniczoną użyteczność tego przedziału, szcze-

górnio w kontekście niskich wartości R^2 . Jednak stabilność zmiennych CON i $MOVE$ w krótkich okresach sugeruje, że mogą być one przydatne w analizach specyficznych dla wieku XX.

Analiza wielowymiarowa

Estymacja parametrów

Poniższe tabele przedstawiają wyniki estymacji parametrów dla różnych modeli regresji liniowej, analizujących wpływ koncentracji mocy (CON), zmian koncentracji (ΔCON) oraz ruchu mocy ($MOVE$) na zmienną zależną. Estymacje zostały przeprowadzone dla trzech różnych okresów: całego badanego zakresu lat 1820–1960, podokresu 1820 – 1890 oraz podokresu 1890 – 1960. Modele uwzględniają zarówno podejście addytywne (ADD), jak i multiplikatywne (MULT), a także różne warianty liczenia zmiennej CON : na początku okresu t (LEADS) oraz na końcu (LAGS). Poniżej przedstawione są wyniki dla różnych podziałów $t = 1$ (Tabela 2.15) oraz $t = 10$ (Tabela 2.16)

Tabela 2.15: Estymowane parametry dla $t = 1$ dla wszystkich okresów

Model	Const		CON		ΔCON		$MOVE$	
	α	p-wartość	β_1	p-wartość	β_2	p-wartość	β_3	p-wartość
1820 – 1960								
ADD / CON LEADS	13.89	0.008	-42.85	0.013	-18.68	0.496	277.88	0.000
ADD / CON LAGS	13.89	0.008	-42.86	0.013	24.17	0.395	277.88	0.000
MULT / CON LEADS	1.44	0.007	-3.12	0.074	-3.66	0.192	25.19	0.000
MULT / CON LAGS	1.43	0.007	-3.12	0.074	-0.535	0.853	25.19	0.000
1820 – 1890								
ADD / CON LEADS	-11.56	0.269	57.67	0.108	64.33	0.420	24.76	0.833
ADD / CON LAGS	-11.56	0.269	57.67	0.108	6.67	0.934	24.76	0.833
MULT / CON LEADS	-0.994	0.472	5.85	0.216	7.35	0.486	9.71	0.531
MULT / CON LAGS	-0.994	0.472	5.85	0.216	1.50	0.888	9.71	0.531
1890 – 1960								
ADD / CON LEADS	15.88	0.020	-51.34	0.024	-26.69	0.430	304.87	0.001
ADD / CON LAGS	15.88	0.020	-51.34	0.024	24.64	0.481	304.87	0.001
MULT / CON LEADS	1.70	0.006	-3.77	0.060	-4.41	0.146	25.22	0.002
MULT / CON LAGS	1.70	0.006	-3.77	0.060	-0.642	0.836	25.22	0.002

Źródło: opracowanie własne

Na podstawie przedstawionych wyników dla $t = 1$ w Tabeli 2.15, można zauważyć, że większość współczynników regresji w analizowanych modelach osiąga niezły poziom istotności w porównaniu z innymi podziałami, co sugeruje, że zmienne niezależne dobrze tłumaczą zmienność zmiennej zależnej WAR .

Modele ADD wykazują szczególnie dobrze dopasowanie w okresach 1820 – 1960 oraz 1890 – 1960. Wartości współczynników dla $MOVE$ (np. $\beta_3 = 277.88$, $p \leq 0.001$ w okresie 1820–1960) wskazują na istotny dodatni wpływ ruchu mocy na WAR . Podobna sytuacja występuje w okresie 1890 – 1960 ($\beta_3 = 265.22$, $p = 0.002$). Może to wynikać z dynamicznego wzrostu znaczenia przepływów mocy w kontekście industrializacji i wzrostu napięć politycznych w XIX wieku, gdzie wzrost zdolności militarno-ekonomicznych mógł bezpośrednio przekładać się na prawdopodobieństwo wystąpienia konfliktów zbrojnych.

Wartość ΔCON we wszystkich okresach charakteryzuje się wysoką p-wartością ($p \geq 0.3$), co sugeruje, że zmienność koncentracji CON nie jest wystarczająco uchwycona przez

modele dla $t = 1$. Może to oznaczać, że przyjęty okres opóźnienia nie odzwierciedla pełnej dynamiki zmian koncentracji w systemie międzynarodowym. Z kolei zmienna CON w XIX wieku ($\beta_1 = 57.67, p = 0.016$) ma pozytywny wpływ na WAR , co może wynikać z tego, że większa koncentracja mocy sprzyjała dominacji kilku głównych państw, które częściej inicjowały konflikty w celu umocnienia swojej pozycji. Zmienne ΔCON i $MOVE$ wykazują pozytywny wpływ we wszystkich okresach.

Modele dla XIX wieku (1820–1890) charakteryzują się gorszymi wynikami dopasowania w porównaniu z innymi okresami, jest to widoczne w wyższych p-wartościach (np. dla $MOVE, p = 0.833$). XIX wiek był okresem szybkich zmian technologicznych i społecznych, które mogły zakłócać zależności między zmiennymi.

Modele MULT również pokazują znaczącą istotność współczynników, szczególnie dla $MOVE$. Na przykład w okresie 1890 – 1960 współczynnik $\beta_3 = 25.19 (p = 0.000)$ wskazuje na istotny wpływ tej zmiennej. Dla okresu 1890 – 1960 MULT/CON LEADS jest lepszym wyborem, ponieważ oferuje bardziej zrównoważone współczynniki i istotność zmiennych ($\beta_1 = -3.77, p = 0.060; \beta_3 = 25.19, p = 0.000$), co może lepiej oddawać złożoność systemu międzynarodowego w tym czasie.

Tabela 2.16: Estymowane parametry dla $t = 10$ dla wszystkich okresów

Model	Const		CON		ΔCON		$MOVE$	
	α	p-wartość	β_1	p-wartość	β_2	p-wartość	β_3	p-wartość
1820 – 1960								
ADD / CON LEADS	38.18	0.50	-93.95	0.60	178.69	0.86	2448.81	0.32
ADD / CON LAGS	38.18	0.50	-93.95	0.60	1118.17	0.48	2448.81	0.32
MULT / CON LEADS	1.60	0.52	1.40	0.86	13.75	0.84	138.55	0.21
MULT / CON LAGS	38.35	0.63	-42.34	0.90	7864.46	0.29	-8333.94	0.52
1820 – 1890								
ADD / CON LEADS	38.35	0.63	-42.34	0.90	7441.10	0.24	-8333.94	0.52
ADD / CON LAGS	38.35	0.63	-42.34	0.90	7864.46	0.29	-8333.94	0.52
MULT / CON LEADS	5.19	0.38	-8.35	0.74	914.21	0.08	-722.75	0.44
MULT / CON LAGS	5.19	0.38	-8.35	0.74	997.67	0.10	-722.75	0.44
1890 – 1960								
ADD / CON LEADS	97.07	0.42	-169.95	0.61	334.78	0.85	-1506.63	0.79
ADD / CON LAGS	97.07	0.42	-169.95	0.61	2034.32	0.49	-1506.63	0.79
MULT / CON LEADS	4.80	0.19	-3.57	0.69	26.52	0.58	-59.63	0.70
MULT / CON LAGS	4.80	0.19	-3.57	0.69	62.24	0.43	-59.63	0.70

Źródło: opracowanie własne

Porównanie wyników dla $t = 1$ (Tabela 2.15) z wynikami dla $t = 10$ (Tabela 2.16) wskazuje istotne różnice zarówno w wartościach współczynników regresji, jak i w poziomie istotności statystycznej (p-wartości).

Na podstawie wyników estymacji parametrów przedstawionych w Tabeli 2.16 dla $t = 10$ można zauważyć, że poziom istotności statystycznej jest ogólnie niski. P-wartości dla większości zmiennych są wysokie, co sugeruje brak istotnego wpływu tych zmiennych na prognozowanie konfliktów zbrojnych. Wyjątkiem są jednak niektóre współczynniki w modelach MULT, które osiągają umiarkowaną istotność. W okresie 1890 – 1960 w modelu współczynniki β_2 odpowiadające zmiennej ΔCON mają umiarkowaną istotność ($p = 0.24, p = 0.29, p = 0.08, p = 0.10$). Wskazuje to na możliwy, choć słaby, wpływ zmian w koncentracji siły na przewidywanie konfliktów w tym okresie.

Zmienne $MOVE$ w obu podokresach wykazują negatywny wpływ na występowanie konfliktów, co jest nietypowe w porównaniu do przeszłych wyników. Warto również

zauważać, że zmienna CON nie wykazuje istotnego wpływu na prognozowanie konfliktów w żadnym z badanych okresów. Wysokie p-wartości dla współczynnika β_1 w przypadku tej zmiennej sugerują brak wyraźnego związku między koncentracją mocy a konfliktami.

Najlepszym modelem dla okresu 1820 – 1960 jest ADD/CON LAGS, ponieważ zmienne osiągają umiarkowaną istotność. Podobnie dla okresu 1820 – 1890 najlepszy model to MULT/CON LEADS, z uwagi na istotność zmiennej ΔCON . Natomiast w okresie 1890 – 1960 za najlepszy można uznać model MULT/CON LAGS, ponieważ zmienna CON wykazuje największą istotność statystyczną, co sugeruje jej rolę w przewidywaniu konfliktów w tym okresie. Modele MULT generalnie charakteryzują się lepszymi wynikami pod względem poziomu istotności w porównaniu do modeli ADD.

Porównanie obu wartości t wyraźnie pokazuje, że zmienne w modelach są bardziej istotne przy mniejszym interwale czasowym ($t = 1$), co może sugerować większą dynamikę zmian w systemie międzynarodowym w krótkich okresach. Z kolei dla większego interwału czasowego ($t = 10$) modele tracą istotność i precyzję w odzwierciedlaniu rzeczywistych konfliktów, co może wynikać z małej liczby obserwacji (14 dla okresu 1820 – 1960, 7 dla podokresów).

Ewaluacja modeli

Wyniki analizy modeli regresji wielowymiarowej dla zmiennych w różnych okresach historycznych dostarczają interesujących spostrzeżeń dotyczących dynamiki konfliktów zbrojnych oraz znaczenia poszczególnych zmiennych w wyjaśnianiu zmiennej zależnej. W niniejszym rozdziale zostały policzone: standaryzowane współczynniki korelacji wielokrotnej (R) i (R^2), skorygowany współczynnik determinacji (\bar{R}^2), oraz dla każdej zmiennej były policzone współczynniki korelacji cząstkowej (r^2) i standaryzowane współczynniki regresji (b). Obliczenia były przeprowadzone dla wszystkich okresów czasowych oraz dla różnych t ($t = 1, t = 10$) i są przedstawione w poniższych Tabelach (2.17, 2.18)

Analizując wyniki podziałów $t = 1$ (Tabela 2.17) dla pełnego zakresu lat 1820 – 1960, zauważamy umiarkowaną siłę związku między zmiennymi objaśniającymi a konfliktem ($R = 0.473$ dla modeli ADD i $R = 0.409$ dla MULT). Szczególnie interesująca jest dominująca rola zmiennej MOVE (ruch mocy), której standaryzowany współczynnik regresji ($b = 0.356$ oraz $b = 0.328$) oraz częściowy współczynnik determinacji ($r^2 = 0.122$ oraz $r^2 = 0.099$) wskazują na jej wkład w wyjaśnianie zmienności konfliktów. Wyniki sugerują, że ruch mocy był głównym czynnikiem eskalacji konfliktów w badanym okresie.

Z kolei zmienne CON oraz ΔCON miały relatywnie niski wpływ na wyjaśnianie konfliktów. Ujemne współczynniki dla CON ($b = -0.213$) mogą oznaczać, że stabilność w systemie międzynarodowym działała hamującą na eskalację konfliktów, jednak nie była wystarczająco silnym czynnikiem determinującym. Zmiana koncentracji (ΔCON) wykazywała jeszcze mniejszy wpływ ($b = -0.053$ oraz $b = 0.069$), co wskazuje, że zmienność ta nie odgrywała istotnej roli w długim okresie.

Tabela 2.17: Dopasowanie standaryzowanych modeli dla $t = 1$ dla wszystkich okresów

Model				<i>CON</i>		ΔCON		<i>MOVE</i>	
	<i>R</i>	R^2	\bar{R}^2	<i>b</i>	r^2	<i>b</i>	r^2	<i>b</i>	r^2
1820 – 1960									
ADD/CON LEADS	0.473	0.223	0.206	-0.213	0.045	-0.054	0.003	0.356	0.122
ADD/CON LAGS	0.473	0.223	0.206	-0.215	0.045	0.069	0.005	0.356	0.122
MULT/CON LEADS	0.409	0.167	0.149	-0.158	0.023	-0.107	0.012	0.328	0.099
MULT/CON LAGS	0.409	0.167	0.149	-0.159	0.023	-0.016	0.000	0.328	0.099
1820 – 1890									
ADD/CON LEADS	0.205	0.042	-0.001	0.201	0.039	0.100	0.010	0.026	0.001
ADD/CON LAGS	0.205	0.042	-0.001	0.204	0.039	0.010	0.000	0.026	0.001
MULT/CON LEADS	0.172	0.030	-0.014	0.155	0.023	0.087	0.007	0.077	0.006
MULT/CON LAGS	0.172	0.030	-0.014	0.157	0.023	0.018	0.000	0.077	0.006
1890 – 1960									
ADD/CON LEADS	0.531	0.282	0.250	-0.268	0.075	-0.087	0.009	0.393	0.159
ADD/CON LAGS	0.531	0.282	0.250	-0.269	0.075	0.080	0.008	0.393	0.159
MULT/CON LEADS	0.489	0.239	0.205	-0.227	0.052	-0.166	0.032	0.376	0.141
MULT/CON LAGS	0.489	0.239	0.205	-0.228	0.052	-0.024	0.001	0.376	0.141

Źródło: opracowanie własne

Wyniki dla okresu 1820 – 1890 pokazują, że modele miały ograniczoną zdolność wyjaśniania konfliktów ($R = 0.172$, $R = 0.205$), a ujemne wartości \bar{R}^2 wskazują na możliwe niedopasowanie modeli do danych. Wartości te sugerują, że dynamika konfliktów w pierwszej połowie XIX wieku była bardziej skomplikowana i mogła zależeć od innych, niewiązanych do modeli czynników, takich jak struktury kolonialne czy lokalne napięcia geopolityczne.

Warto zauważyć, że zmienna *CON* nadal wykazywała pewien pozytywny wpływ, co sugeruje, że koncentracja mocy była istotnym czynnikiem, choć jej znaczenie było mniej wyraźne niż w późniejszych okresach. ΔCON *MOVE* wykazały niewielki lub zerowy wkład w wyjaśnianie konfliktów, co może wynikać z relatywnej stabilności systemu międzynarodowego w tej epoce oraz ograniczonej liczby dużych konfliktów międzynarodowych.

Najwyższe wartości uzyskano dla okresu 1890 – 1960 modelem ADD ($R = 0.531$, $\bar{R} = 0.250$). Wskazuje to na silniejszy związek między zmiennymi objaśniającymi a konfliktami zbrojnymi w tej epoce. Można to interpretować jako wynik wzrostu intensywności globalnych konfliktów (dwie wojny światowe) oraz lepszej dostępności danych i większej stabilności międzynarodowych struktur geopolitycznych.

MOVE okazało się dominującą zmienną w tym okresie. Wysokie wartości $b = 0.393$ oraz $r^2 = 0.159$ sugerują, że ruch mocy był kluczowym predyktorem eskalacji konfliktów, co jest zgodne z historycznymi realiami wzrostu zbrojeń i agresji. Z kolei zmienna *CON* miała umiarkowany wpływ, z ujemnymi współczynnikami ($b = -0.268$), co potwierdza, że stabilność koncentracji mocy mogła redukować ryzyko konfliktów, ale jej działanie było ograniczone przez inne czynniki, takie jak ekspansjonistyczne cele niektórych państw.

Zmiana koncentracji (ΔCON) wykazała niejednoznaczne efekty ($b = -0.087$ dla ADD/CON LEADS i $b = 0.080$ dla ADD/CON LAGS), co może odzwierciedlać różnorodność reakcji państw na zmieniające się warunki międzynarodowe. Wyniki te podkreślają potrzebę głębszej analizy kontekstów politycznych i ich interakcji z dynamiką konfliktów.

Analiza wykazała, że zmienna *MOVE* była konsekwentnie najważniejszym predyktorem konfliktów zbrojnych, niezależnie od okresu. Sugeruje to, że intensywność ruchu mocy

odgrywa kluczową rolę w eskalacji konfliktów, szczególnie w bardziej złożonych systemach międzynarodowych.

Analizując wyniki dla $t = 10$ (Tabela 2.18), można zauważyc, że dla całego okresu 1820 – 1960 modele wykazują umiarkowaną zdolność wyjaśniania zmienności konfliktów, z wartościami R w zakresie od 0.486 (MULT/CON LEADS) do 0.509 (ADD/CON LEADS). Współczynnik determinacji R^2 sugeruje, że modele tłumaczą około 23 – 26 % całkowitej wariancji. Wyniki dla zmiennej CON wskazują na jej negatywny wpływ na eskalację konfliktów w modelach ADD. Z kolei zmienna ΔCON odgrywała istotną rolę, szczególnie w modelu ADD/CON LAGS, gdzie współczynnik regresji wynosił 0.356, co sugeruje, że powolne zmiany systemowe mogły prowadzić do konfliktów. Największe znaczenie w tym okresie miała jednak zmienna $MOVE$ (ruchy mocy), która wykazywała najwyższe wartości współczynników regresji (od 0.341 do 0.441) oraz częściowego współczynnika determinacji (od 0.098 do 0.150), co podkreśla kluczową rolę działań militarnych w eskalacji konfliktów.

Tabela 2.18: Dopasowanie standaryzowanych modeli dla $t = 10$

Model				CON		ΔCON		$MOVE$	
	R	R^2	R^2	b	r^2	b	r^2	b	r^2
1820 – 1960									
ADD / CON LEADS	0.509	0.259	0.036	-0.202	0.028	0.057	0.003	0.342	0.098
ADD / CON LAGS	0.509	0.259	0.036	-0.258	0.028	0.356	0.051	0.342	0.098
MULT / CON LEADS	0.486	0.236	0.007	0.068	0.003	0.201	0.037	0.441	0.150
MULT / CON LAGS	0.486	0.236	0.007	0.087	0.003	0.100	0.004	0.441	0.150
1820 – 1890									
ADD / CON LEADS	0.663	0.440	-0.121	-0.088	0.006	1.064	0.423	-0.614	0.147
ADD / CON LAGS	0.663	0.440	-0.121	-0.134	0.006	1.124	0.358	-0.614	0.147
MULT / CON LEADS	0.855	0.731	0.462	-0.169	0.044	1.274	0.687	-0.520	0.205
MULT / CON LAGS	0.855	0.731	0.462	-0.258	0.044	1.391	0.640	-0.520	0.205
1890 – 1960									
ADD / CON LEADS	0.442	0.196	-0.609	-0.439	0.097	0.136	0.014	-0.193	0.028
ADD / CON LAGS	0.442	0.196	-0.609	-0.550	0.097	0.827	0.174	-0.193	0.028
MULT / CON LEADS	0.532	0.283	-0.433	-0.323	0.062	0.378	0.112	-0.267	0.058
MULT / CON LAGS	0.532	0.283	-0.433	-0.405	0.062	0.886	0.213	-0.267	0.058

Źródło: opracowanie własne

W okresie 1820 – 1890 wyniki wykazują znacznie większą zmienność. Modele MULT/CON osiągają wyjątkowo wysokie wartości ($R = 0.855$ oraz $R^2 = 0.731$), co oznacza, że tłumaczą ponad 73% wariancji w danych, wskazując na wyjątkową skuteczność tych modeli w wyjaśnianiu dynamiki konfliktów w tej epoce. Zmienna CON miała tu niewielki wpływ, co sugeruje, że stabilność odgrywała marginalną rolę w powstrzymywaniu konfliktów w tym okresie. Natomiast zmienna ΔCON okazała się kluczowa, z bardzo wysokimi wartościami współczynników ($b = 1.391$ w modelu MULT/CON LAGS) i znaczącymi częściowymi współczynnikami determinacji ($r^2 = 0.687$). Wyniki te wskazują, że nagłe zmiany systemowe były głównym czynnikiem prowadzącym do konfliktów. Zmienna $MOVE$ również miała istotny wpływ, choć mniejszy niż ΔCON , co sugeruje, że ruch mocy współdziałał z systemowymi zmianami w przewidywaniu konfliktów w tym okresie.

Okres 1890 – 1960 charakteryzuje się słabszym dopasowaniem modeli do danych, co widoczne jest w ujemnych wartościach skorygowanego współczynnika determinacji (\bar{R}). Wyniki wskazują na potencjalne niedopasowanie modeli do bardziej złożonych konfliktów w tym czasie, które mogły wymagać uwzględnienia dodatkowych zmiennych. Zmienna CON wykazuje negatywny wpływ na konflikty, co może oznaczać, że zakłócenie koncentracji miało destabilizujący efekt. Z kolei ΔCON miała pewne znaczenie, szczególnie w modelu MULT/CON LAGS, gdzie wartość współczynnika wynosiła 0.886, co sugeruje, że zmiany systemowe nadal odgrywały istotną rolę, choć ich wpływ był mniej konsekwentny niż w poprzednich okresach.

Podsumowując, analiza ukazuje, że zmienna $MOVE$ była najważniejszym predyktorem konfliktów w całym analizowanym okresie, podczas gdy ΔCON miała szczególnie silny wpływ w XIX wieku. Z kolei okres 1890 – 1960 sugeruje bardziej złożoną dynamikę konfliktów, co wymaga dalszego uwzględnienia dodatkowych czynników w modelach. Wyniki te potwierdzają ewolucję dynamiki konfliktów zbrojnych oraz podkreślają potrzebę elastycznego podejścia do modelowania tych zjawisk.

Porównanie wyników dla $t = 1$ i $t = 10$ pokazuje, że zmienne mają różną rolę w zależności od horyzontu czasowego. Dla $t = 1$ największy wpływ ma $MOVE$, która konsekwentnie dominuje jako predyktor konfliktów we wszystkich okresach. Z kolei zmienne CON i ΔCON odgrywają mniejszą rolę, co sugeruje, że w krótszej perspektywie czasowej stabilność systemu i zmiany w status quo mają ograniczony wpływ na eskalację konfliktów.

Dla $t = 10$ widoczne są wyższe wartości R i R^2 w XIX wieku, szczególnie dla zmiennej ΔCON , która odgrywa kluczową rolę w wyjaśnianiu konfliktów w tym okresie. Współczynniki regresji wskazują, że zmiany w systemie międzynarodowym miały istotny wpływ na dynamikę konfliktów. W XX wieku dopasowanie modeli spada, co może wynikać z bardziej złożonych uwarunkowań konfliktów, takich jak technologia czy gospodarka. W dłuższej perspektywie czasowej znaczenie $MOVE$ jest nadal istotne, ale ustępuje miejsca ΔCON , podkreślając kluczową rolę systemowych zmian w generowaniu konfliktów.

Wykresy ilustrujące dopasowanie modeli

W rozdziale tym przedstawione zostały wyniki modelowania dla różnych wersji modeli ADD i MULT, obrazujące dopasowanie prognozowanych wartości liczby konfliktów (WAR) do rzeczywistych danych historycznych. Wykresy umożliwiają ocenę jakości przewidywań każdego modelu w analizowanych okresach (1820–1960, 1820–1890, 1890–1960) oraz porównanie ich efektywności w przypadku liczenia zmiennych z podziałami $t = 1$ oraz $t = 10$. Dodatkowo, analiza obejmuje średnie błędy kwadratowe (MSE) i bezwzględne (MAE) przedstawione w Tabeli 2.19.

Na Rysunkach 2.7, 2.8, 2.9 przedstawione są wykresy dla $t = 1$ dla okresów 1820 – 1960, 1820 – 1890, 1890 – 1960 odpowiednio. Dla krótszych podziałów horyzontu czasowego ($t = 1$), wykresy wskazują na ogólnie dobrą zdolność modeli do odtwarzania trendów rzeczywistych konfliktów w badanych okresach historycznych. Modele ADD/CON charakteryzują się bardziej płynnymi przewidywaniami, co skutkuje mniejszą liczbą ekstremalnych wartości w porównaniu do wartości rzeczywistych. Wyniki dla modeli MULT, choć także względnie dokładne, wykazują większą zmienność i silniejsze różnice w dopasowaniu dla najwyższych wartości rzeczywistych.

Tabela 2.19: Średni błąd bezwzględny (MAE) oraz kwadratowy (MSE) dla modeli z $t = 1$ oraz $t = 10$ w trzech okresach czasowych

Model	1820 – 1960		1820 – 1890		1890 – 1960	
	MAE	MSE	MAE	MSE	MAE	MSE
$t = 1$						
ADD/CON LEADS	9.02	161.94	6.82	84.65	10.55	218.44
ADD/CON LAGS	9.12	165.10	6.87	85.36	10.88	226.95
MULT/CON LEADS	8.05	189.96	5.71	94.84	10.05	274.85
MULT/CON LAGS	7.97	187.03	5.70	95.08	9.91	264.29
$t = 10$						
ADD/CON LEADS	17.53	540.56	6.86	62.41	19.27	707.71
ADD/CON LAGS	19.04	607.14	7.22	63.26	28.50	1129.80
MULT/CON LEADS	18.58	788.66	5.61	69.38	24.51	959.58
MULT/CON LAGS	18.85	758.32	5.50	52.19	19.48	827.28

Źródło: opracowanie własne

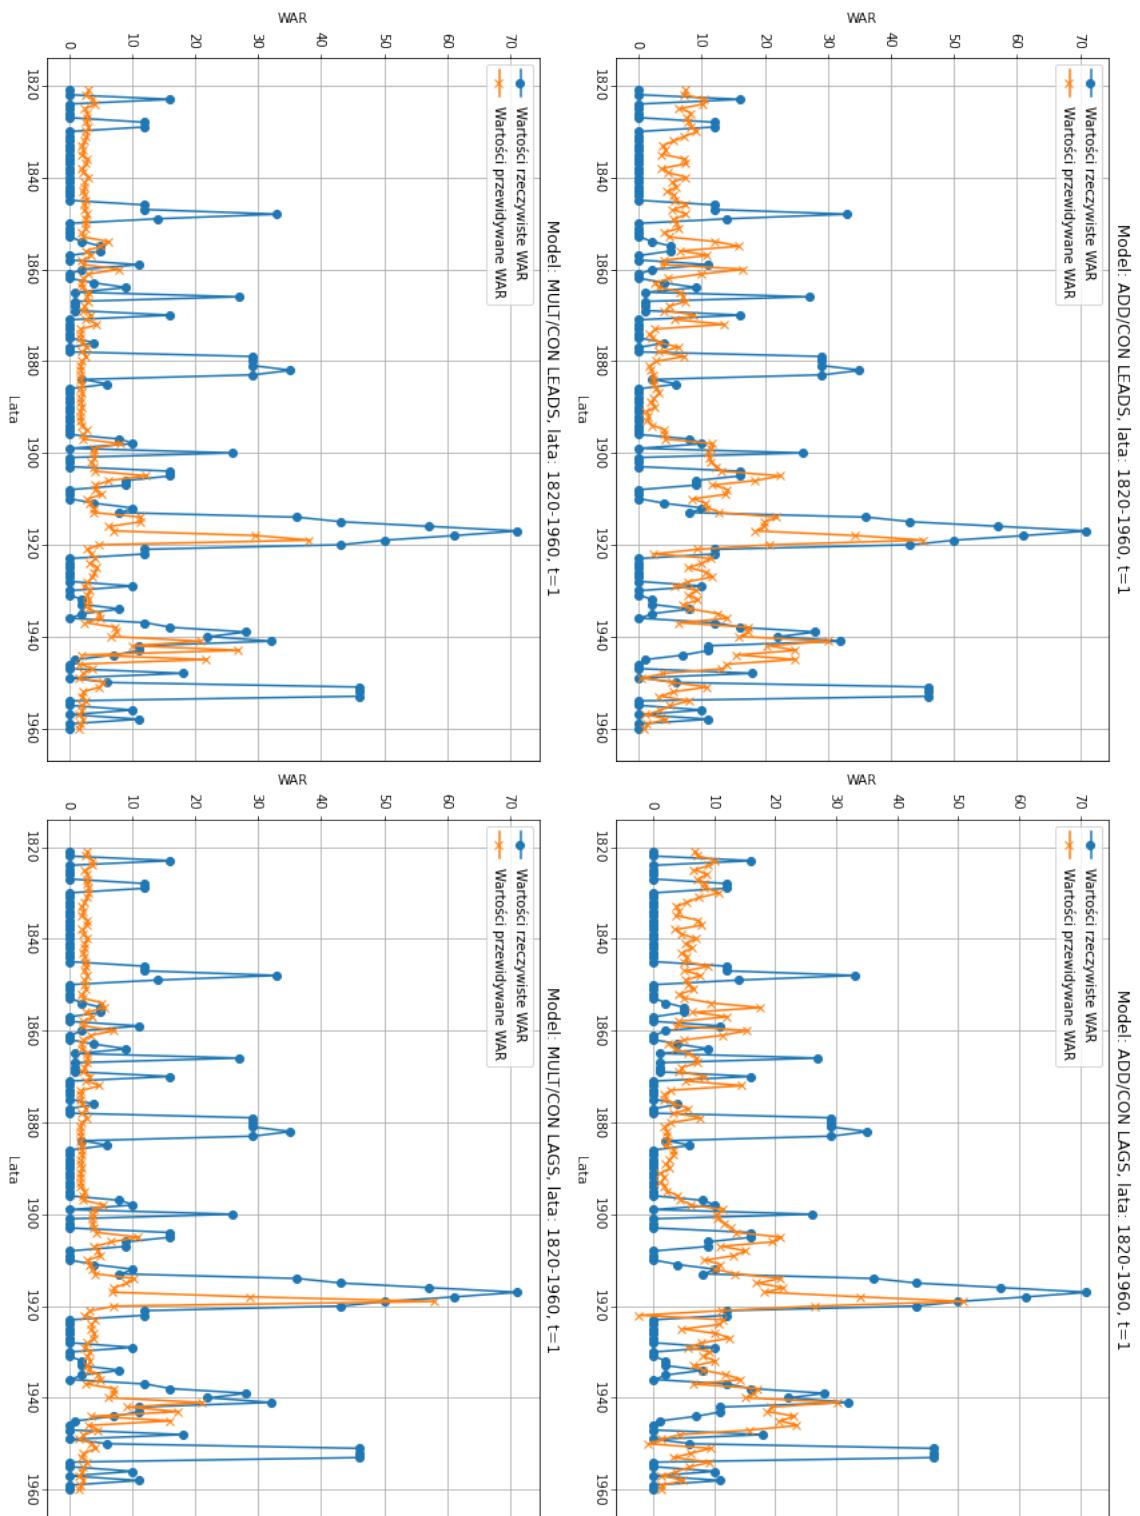
Dla lat 1820 – 1890 różnice między wartościami rzeczywistymi a przewidywanymi są szczególnie zauważalne w przypadkach ekstremalnych konfliktów, gdzie modele nie są w stanie uchwycić pełnej dynamiki gwałtownych skoków. Jednocześnie dla lat 1820 – 1960 oraz 1890 – 1960 modele poprawnie odzwierciedlają długoterminowe zmiany w liczbie konfliktów, choć nadal mają trudności z dokładnym dopasowaniem dla okresów gwałtownej eskalacji, takich jak lata wojen światowych.

Analiza błędów dla ($t = 1$) pokazuje, że model ADD/CON LEADS osiąga niższe błędy niż MULT, co może wskazywać na większą stabilność przewidywań w ramach pierwszej grupy modeli. Wartości MSE mieszczą się w przedziale 84–226 (dla różnych okresów), podczas gdy MAE pozostaje na poziomie od około 5.7 do 10.5.

Na Rysunkach 2.10, 2.11, 2.12 przedstawione są wykresy dla $t = 10$ dla okresów 1820 – 1960, 1820 – 1890, 1890 – 1960 odpowiednio. Dla dłuższego horyzontu czasowego, modele wykazują większe różnice między wartościami przewidywanymi a rzeczywistymi, szczególnie w przypadku lat o wyraźnych zmianach w liczbie konfliktów. Przewidywania dla ADD oraz MULT mają tendencję do zniżania wartości rzeczywistych w okresach gwałtownych wzrostów (np. konflikty w latach 1860 – 1870 lub podczas wojen światowych). Jednocześnie przewidywania dla MULT/CON, mimo większej zmienności, lepiej oddają dynamikę okresów o średniej liczbie konfliktów.

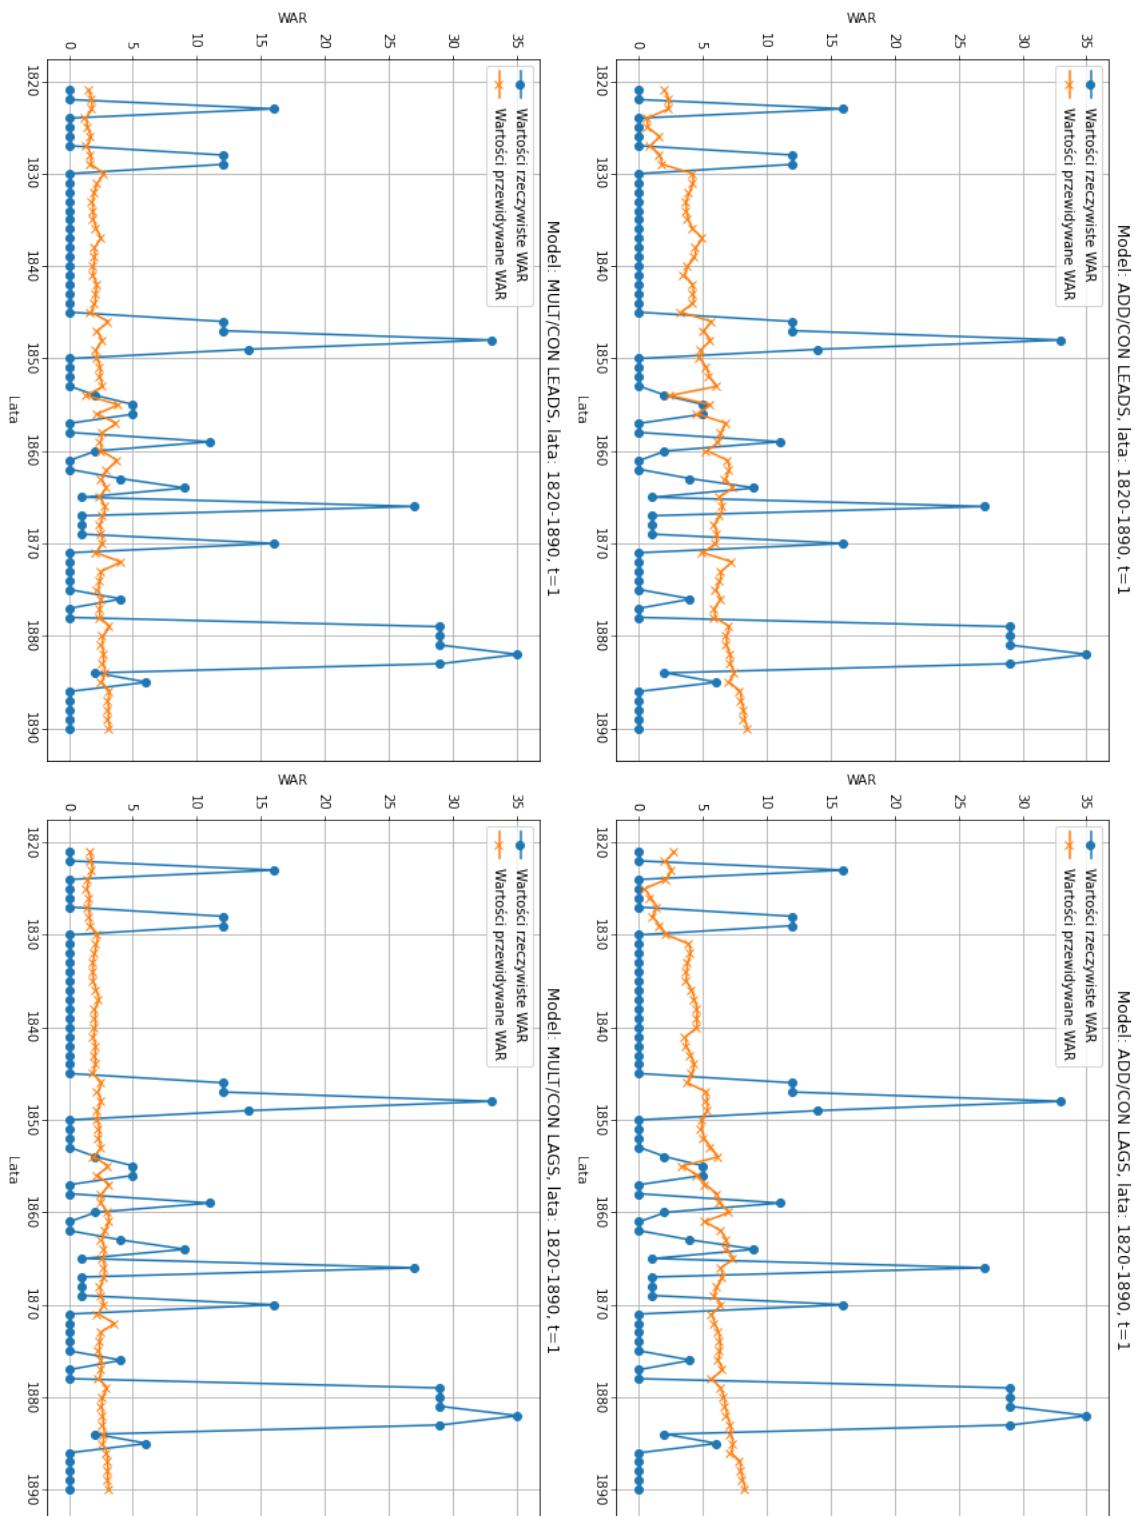
W okresie 1820 – 1890 modele są bardziej stabilne niż w latach 1890 – 1960, co odzwierciedla niższe wartości MSE i MAE. MULT/CON LAGS osiąga najniższe wartości błędów (MSE: 52.19, MAE: 5.50) w tym okresie, co świadczy o lepszym dopasowaniu dla analizowanego przedziału czasowego. Natomiast dla okresu 1890 – 1960 błędy znacząco rosną, osiągając MSE powyżej 800 oraz MAE na poziomie 19–28, co wskazuje na trudności modeli w przewidywaniu konfliktów w bardziej złożonych warunkach XX wieku.

Porównanie wyników dla różnych wartości t ujawnia wyraźne różnice w zdolności modeli do odtwarzania dynamiki konfliktów. Dla $t = 1$ przewidywania są bardziej dokładne, szczególnie w krótszych okresach czasowych. Modele ADD/CON charakteryzują się mniejszymi błędami i bardziej stabilnymi przewidywaniemi, co wskazuje na ich przewagę w krótszych horyzontach czasowych. MULT/CON, choć bardziej zmienne, lepiej radzą sobie z wychwytywaniem długoterminowych trendów.



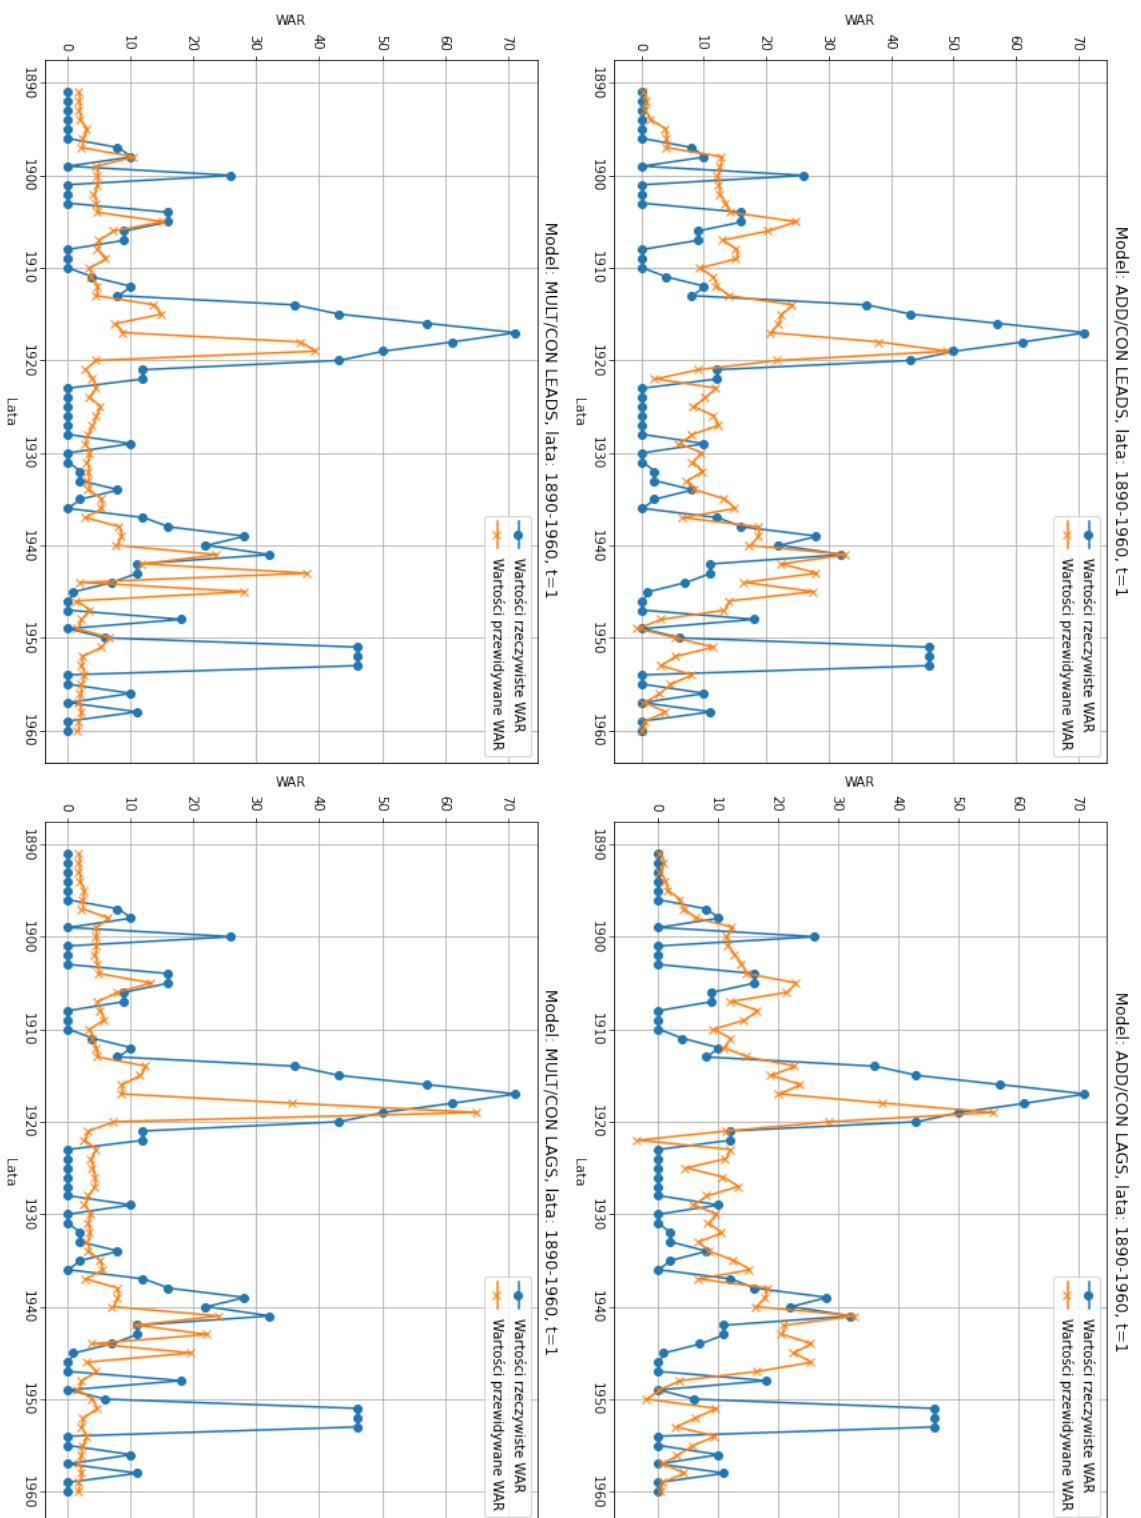
Rysunek 2.7: Dopasowanie modeli dla $t = 1$ dla lat 1820 – 1960

Dla ($t = 10$) modele wykazują większe trudności w dopasowaniu, szczególnie w latach o gwałtownych zmianach liczby konfliktów. MULT/CON LAGS uzyskuje najlepsze wyniki w okresie 1820 – 1890, jednak w XX wieku wszystkie modele zmagają się z wysokimi błędami, co sugeruje, że konflikty w tym okresie wymagają uwzględnienia bardziej złożonych zmiennych. Zwiększenie t skutkuje także wyraźnym wzrostem błędów MSE i MAE, co

Rysunek 2.8: Dopasowanie modeli dla $t = 1$ dla lat 1820 – 1890

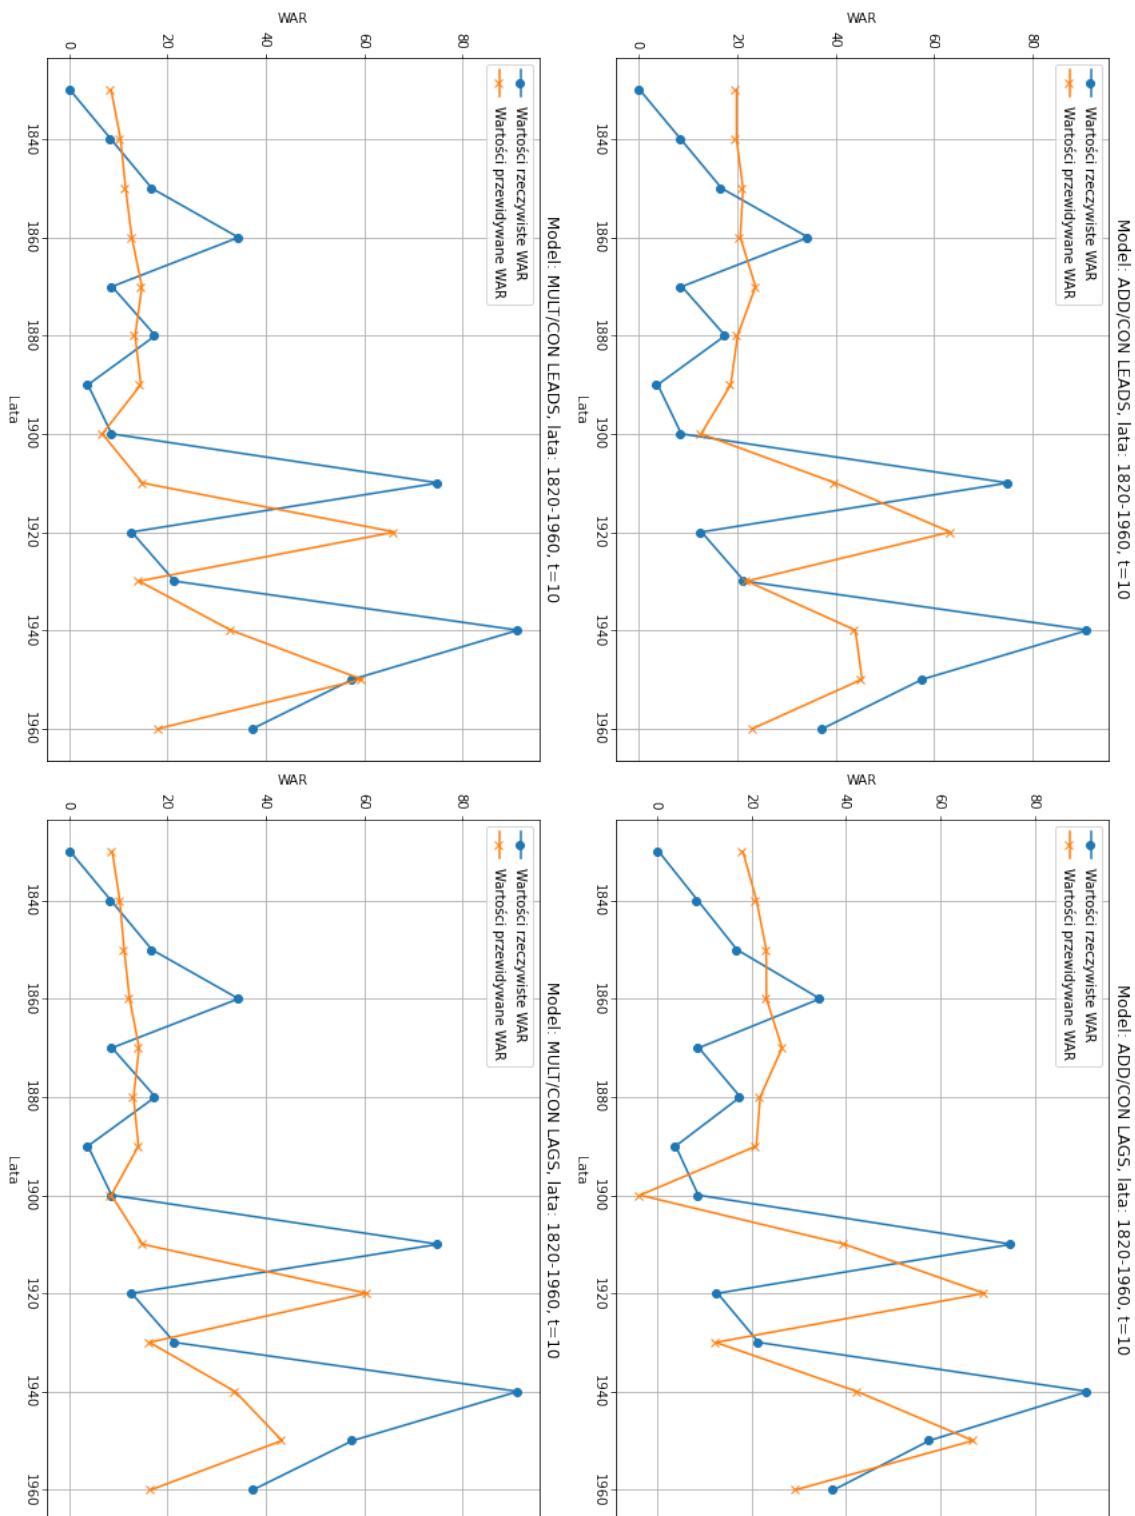
podkreśla trudności w długoterminowej prognozie konfliktów.

Podsumowując, $t = 1$ lepiej nadaje się do krótkoterminowych analiz konfliktów, gdzie modele osiągają niższe błędy i lepiej odzwierciedlają wartości rzeczywiste. Z kolei $t = 10$ wymaga bardziej zaawansowanego podejścia, szczególnie w XX wieku, gdzie złożoność konfliktów wykracza poza obecne możliwości predykcyjne tych modeli.

Rysunek 2.9: Dopasowanie modeli dla $t = 1$ dla lat 1890 – 1960

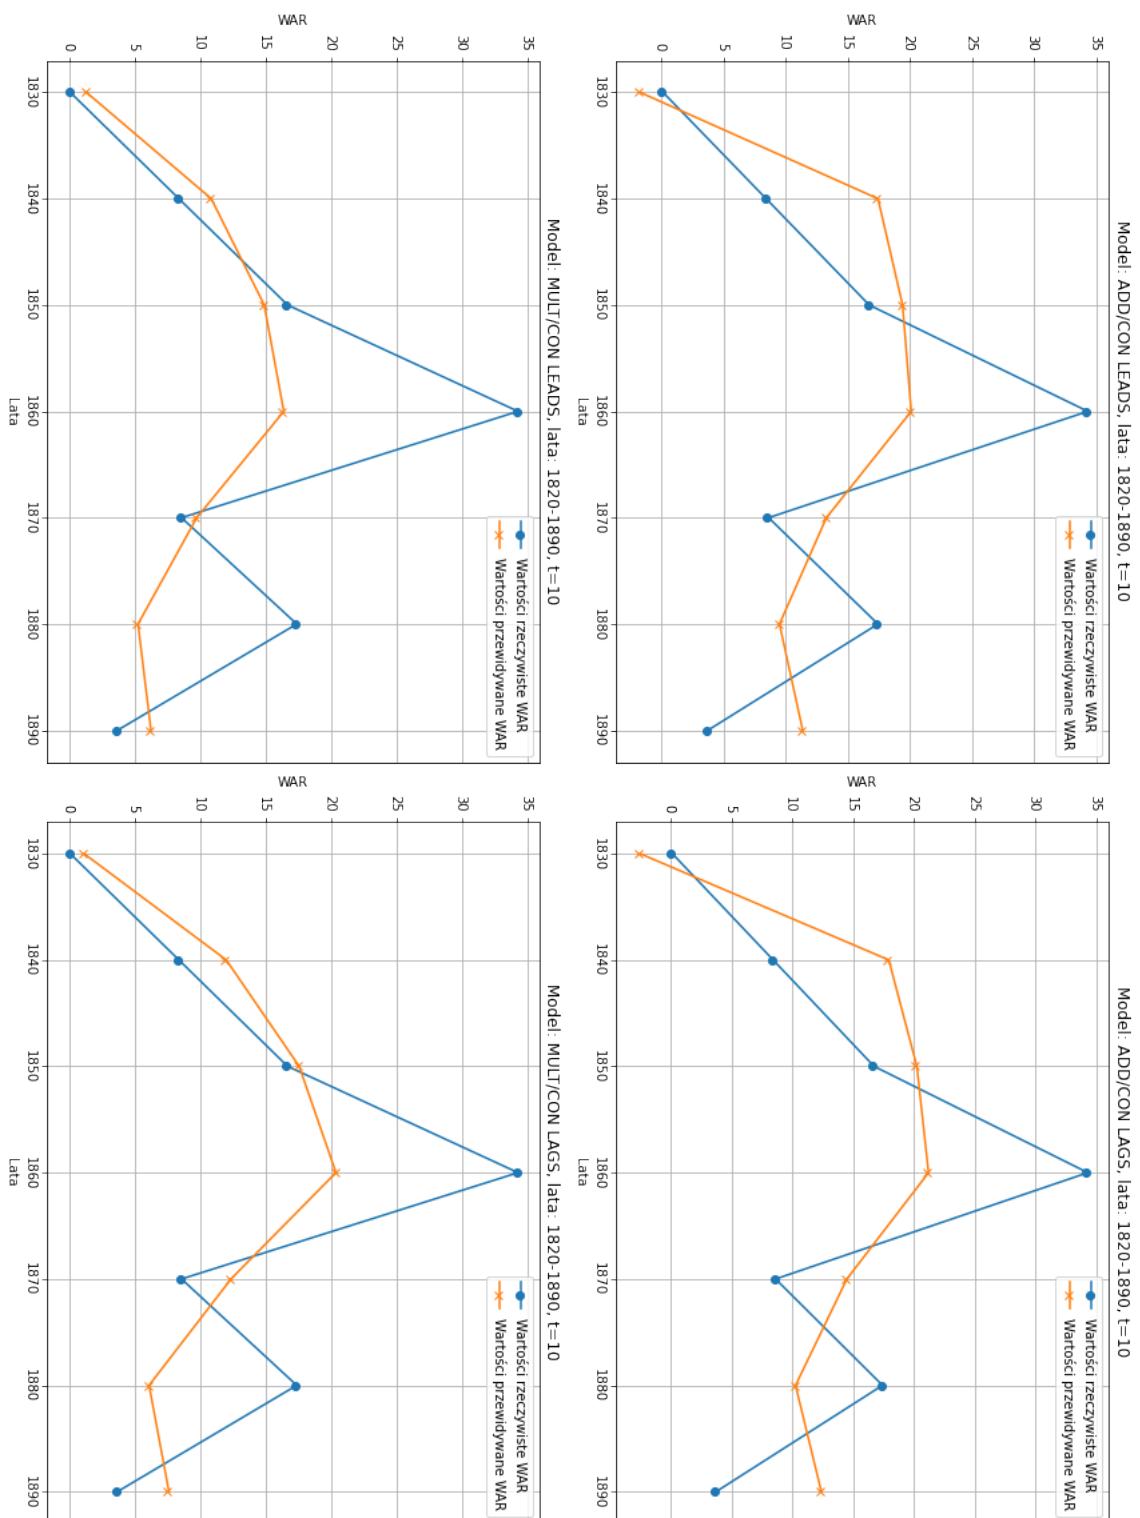
Analiza reszt

W ramach analizy jakości dopasowania modeli przeprowadzono badanie reszt dla różnych horyzontów czasowych ($t = 1$ oraz $t = 10$) oraz okresów historycznych (1820 – 1960, 1820 – 1890, 1890 – 1960). Na Rysunkach 2.13, 2.14, 2.15 przedstawiono wykresy reszt dla $t = 1$, a na Rysunkach 2.16, 2.17, 2.18 wykresy reszt dla $t = 10$. Wykresy te ukazują zależność

Rysunek 2.10: Dopasowanie modeli dla $t = 10$ dla lat 1820 – 1960

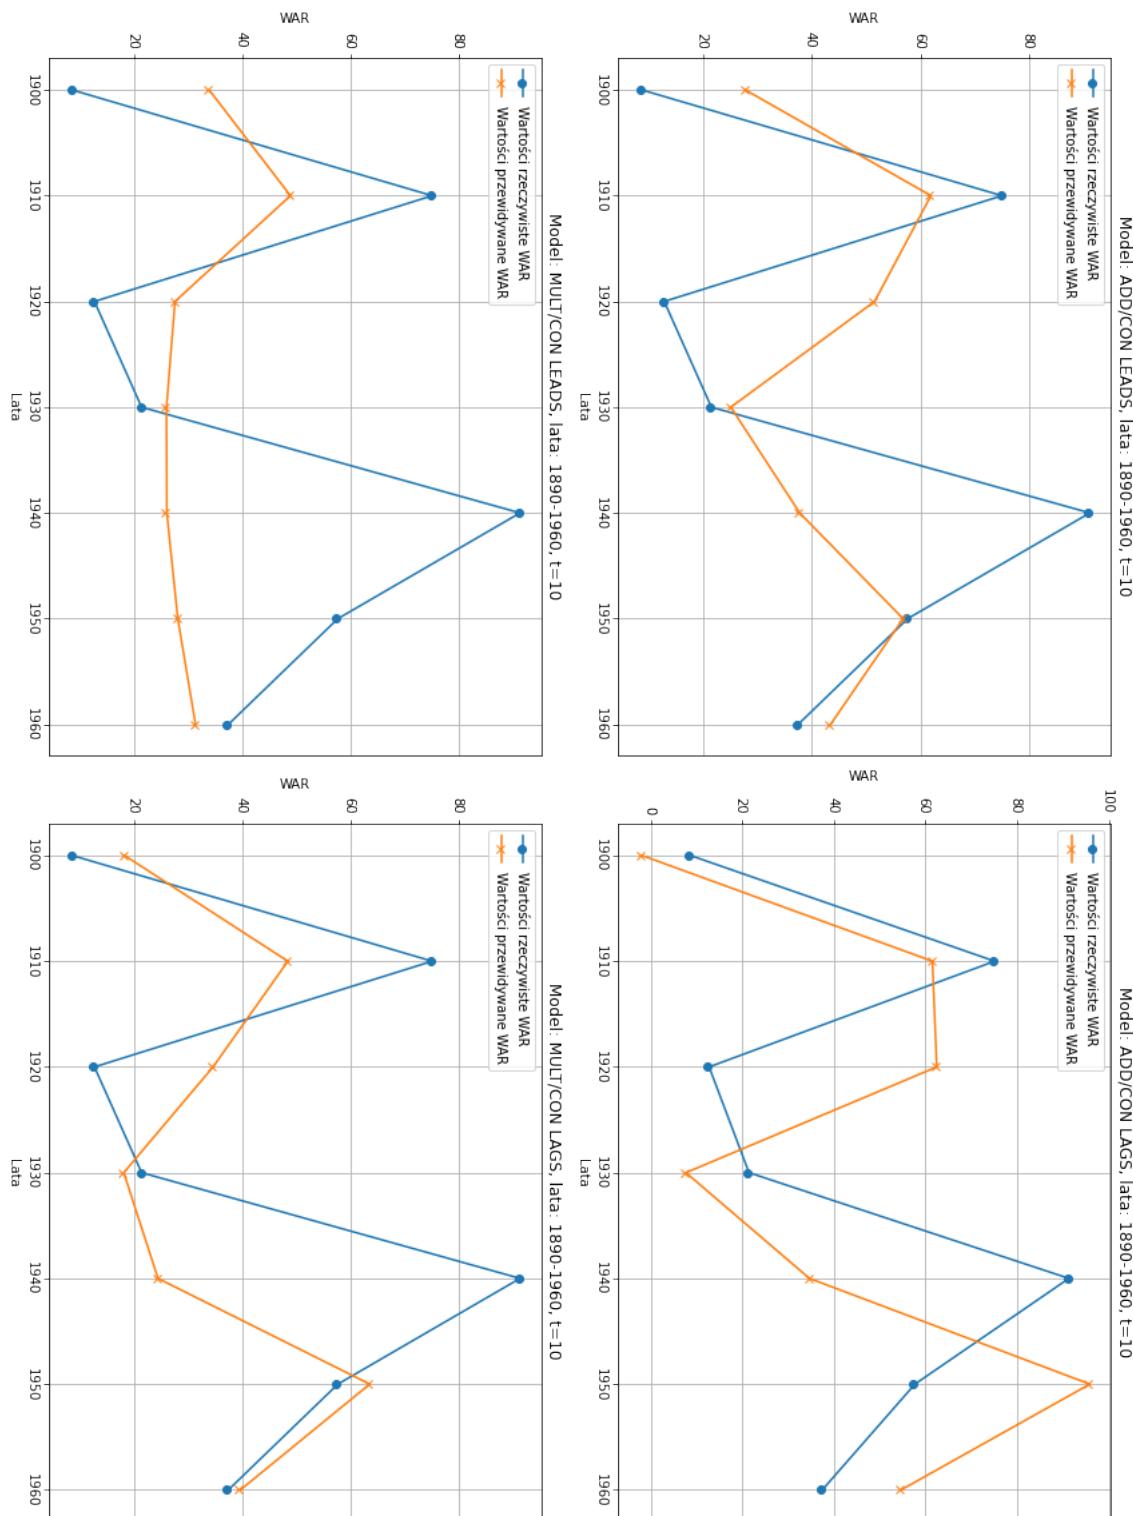
pomiędzy wartościami przewidywanymi a rzeczywistymi liczbą konfliktów zbrojnych. Dodatkowo przeprowadzono test Shapiro-Wilka w celu weryfikacji normalności reszt dla każdego z modeli.

Dla krótkiego horyzontu czasowego ($t = 1$), wykresy reszt pokazują, że modele mają trudności z dokładnym przewidywaniem wartości ekstremalnych, szczególnie w okresach

Rysunek 2.11: Dopasowanie modeli dla $t = 10$ dla lat 1820 – 1890

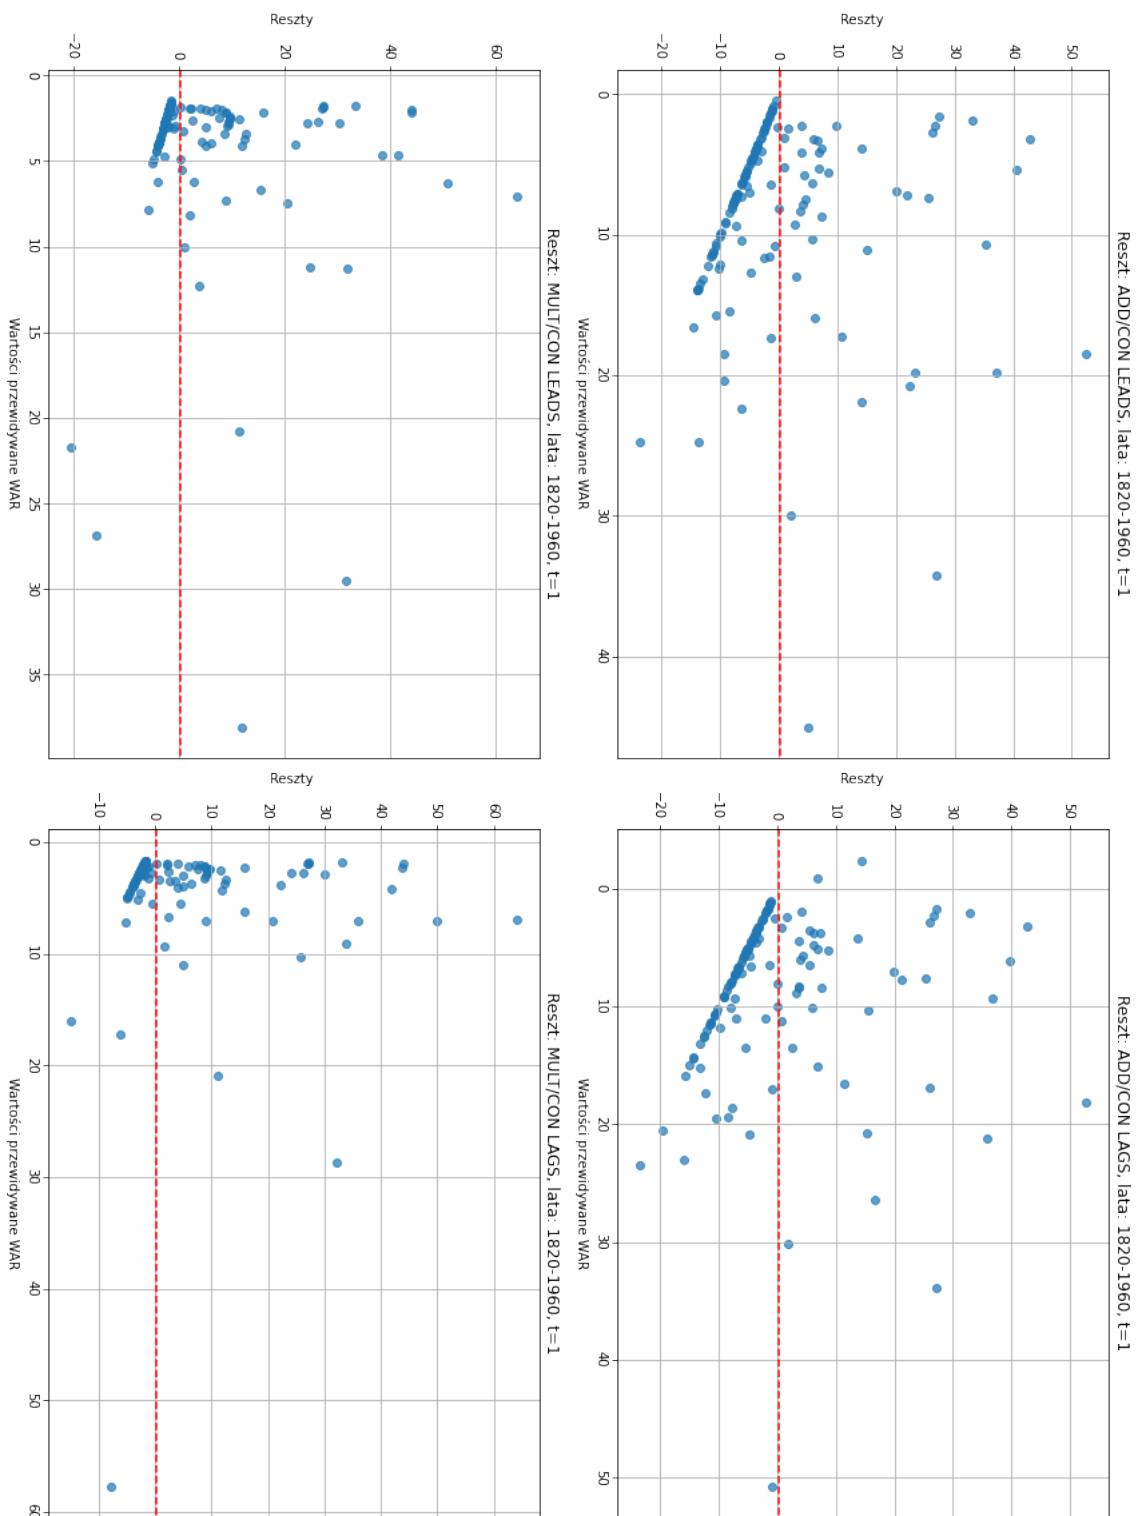
1820 – 1960 oraz 1890 – 1960. Reszty dla modeli ADD wykazują pewną systematyczność – widać tendencję do zaniżania przewidywań przy wyższych wartościach rzeczywistych. W przypadku modeli MULT reszty są bardziej rozproszone, co wskazuje na mniejszą stabilność tych modeli.

Test Shapiro wykazał, że reszty dla wszystkich modeli w $t = 1$ nie mają rozkładu

Rysunek 2.12: Dopasowanie modeli dla $t = 10$ dla lat 1890 – 1960

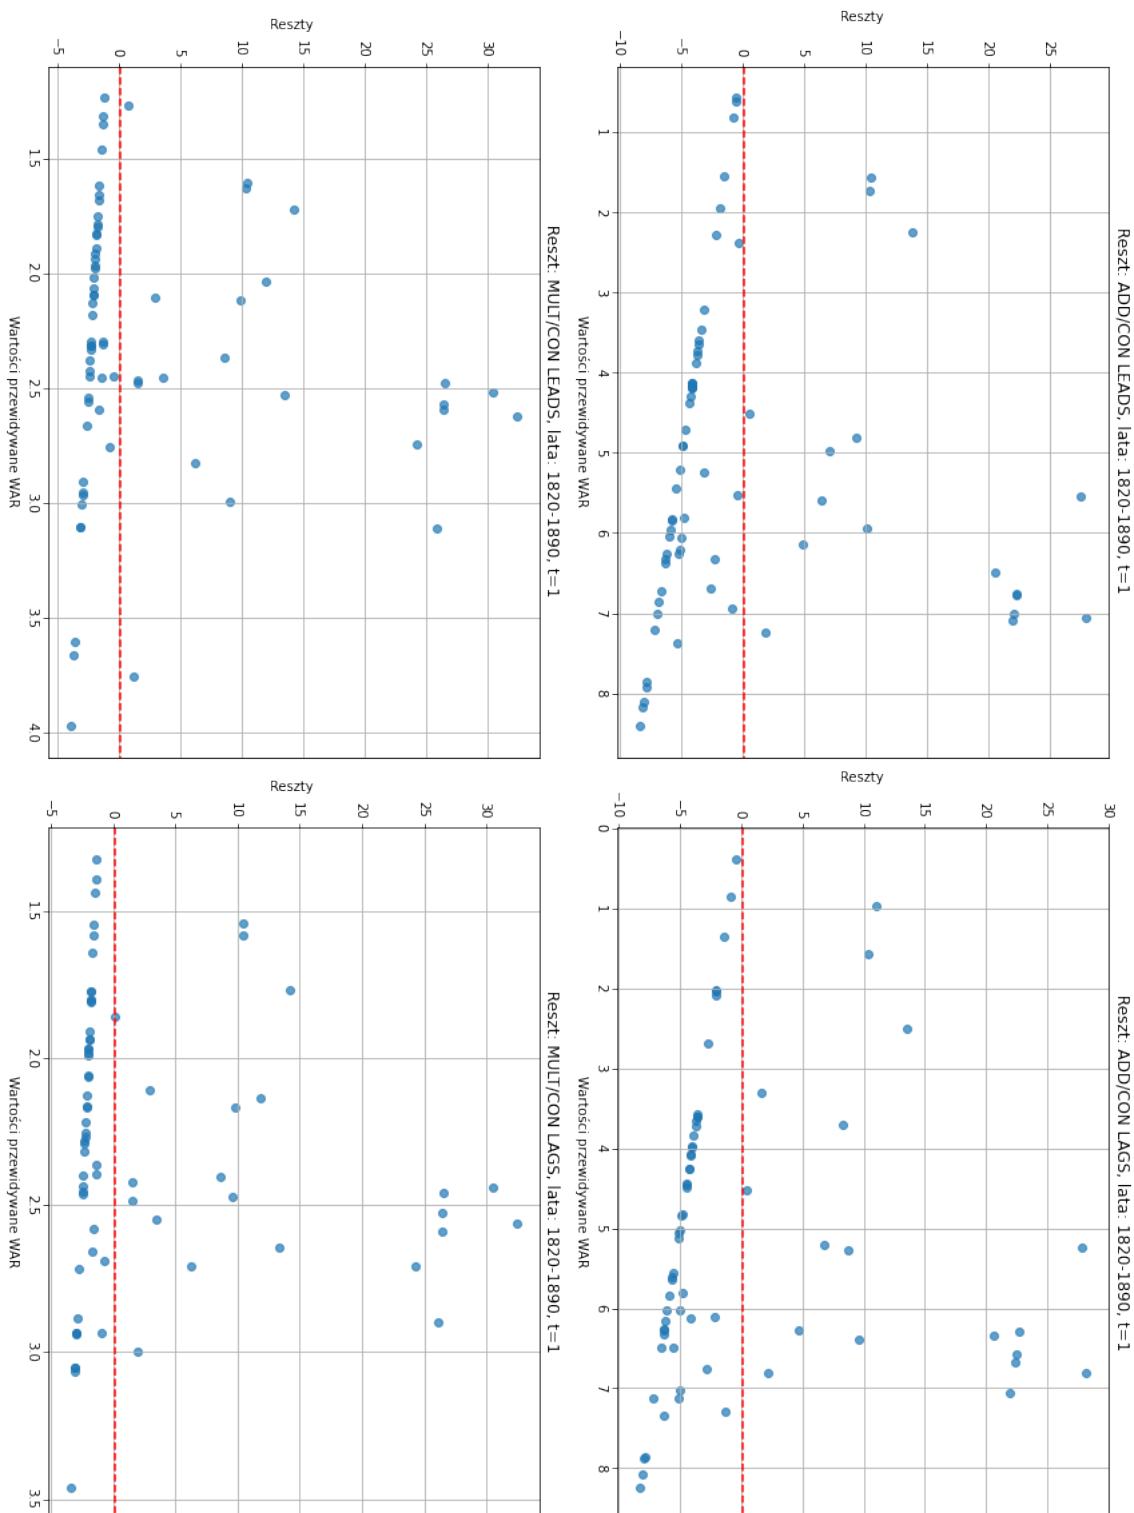
normalnego. Wyniki te wskazują na potencjalne problemy z założeniami modelu liniowego, co może obniżać jakość predykcji. Szczególnie widać to na wykresach reszt, gdzie nie występuje przypadkowy rozkład punktów wokół osi poziomej – pojawiają się wzorce wskazujące na niedopasowanie modeli w różnych zakresach wartości.

Dla dłuższego horyzontu czasowego ($t = 10$) wykresy reszt pokazują lepsze dopasowanie



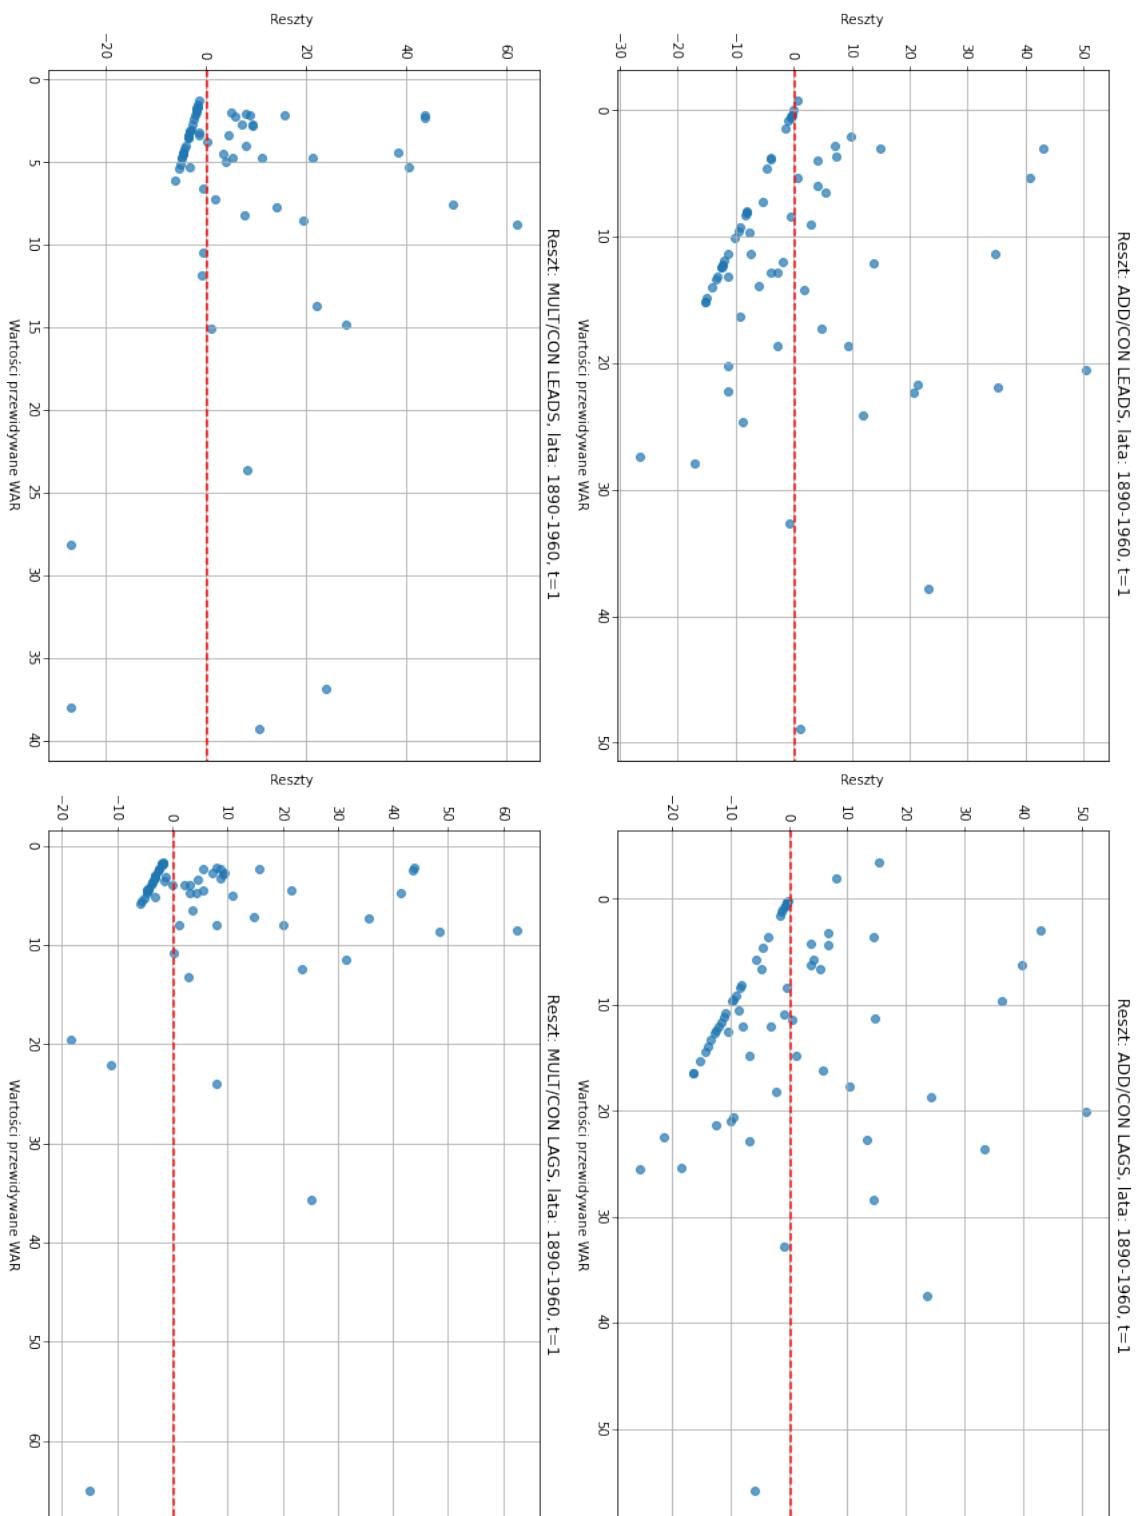
Rysunek 2.13: Analiza reszt dla $t = 1$ dla lat 1820 – 1960

modeli w większości przypadków. Reszty dla ADD są bardziej równomiernie rozproszone wokół linii poziomej (o wartości 0), co sugeruje, że modele te lepiej radzą sobie z przewidywaniem w dłuższych przedziałach czasowych. Jednakże modele MULT w okresie 1820 – 1890 mają wyraźne problemy z dopasowaniem – reszty wykazują znaczne odchylenia i brak równomiernego rozkładu.

Rysunek 2.14: Analiza reszt dla $t = 1$ dla lat 1820 – 1890

Test Shapiro potwierdził, że reszty mają rozkład normalny dla większości modeli w $t = 10$, z wyjątkiem MULT/CON LEADS i MULT/CON LAGS w okresie 1820 – 1890. To wskazuje na lepsze spełnienie założeń modelu w dłuższym horyzoncie czasowym, co może tłumaczyć lepsze dopasowanie tych modeli w porównaniu do $t = 1$.

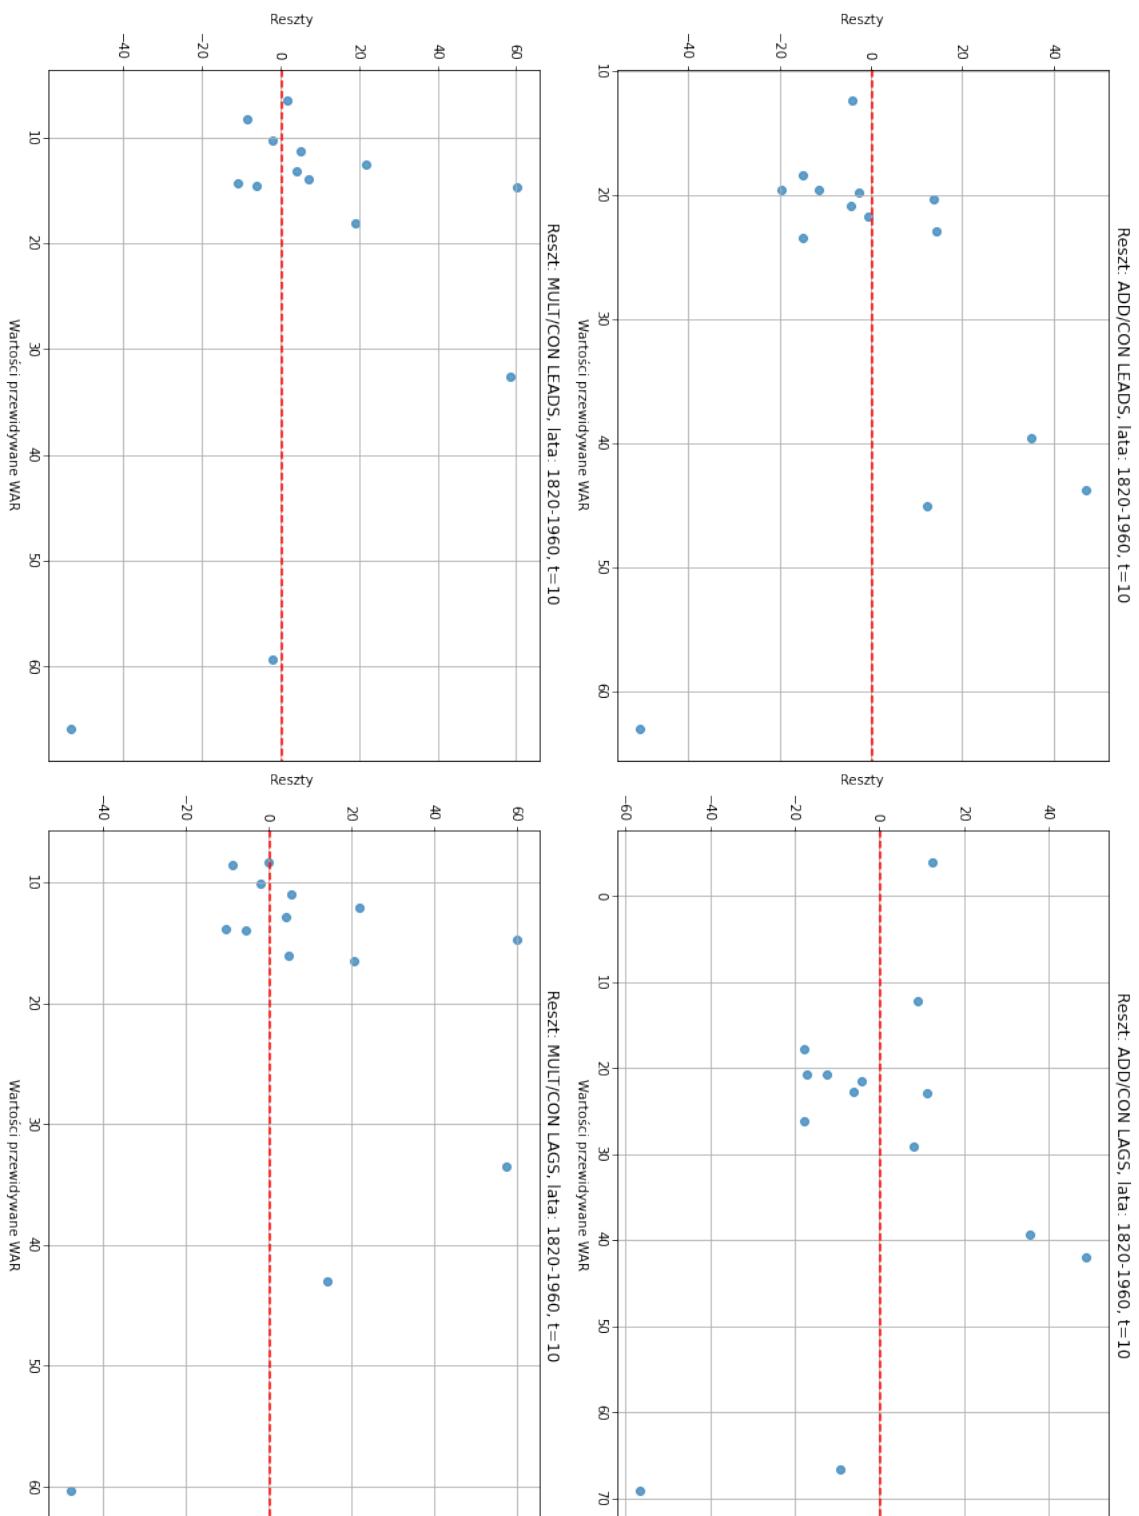
Porównując wyniki dla $t = 1$ i $t = 10$, można zauważyć, że dłuższy horyzont czasowy



Rysunek 2.15: Analiza reszt dla $t = 1$ dla lat 1890 – 1960

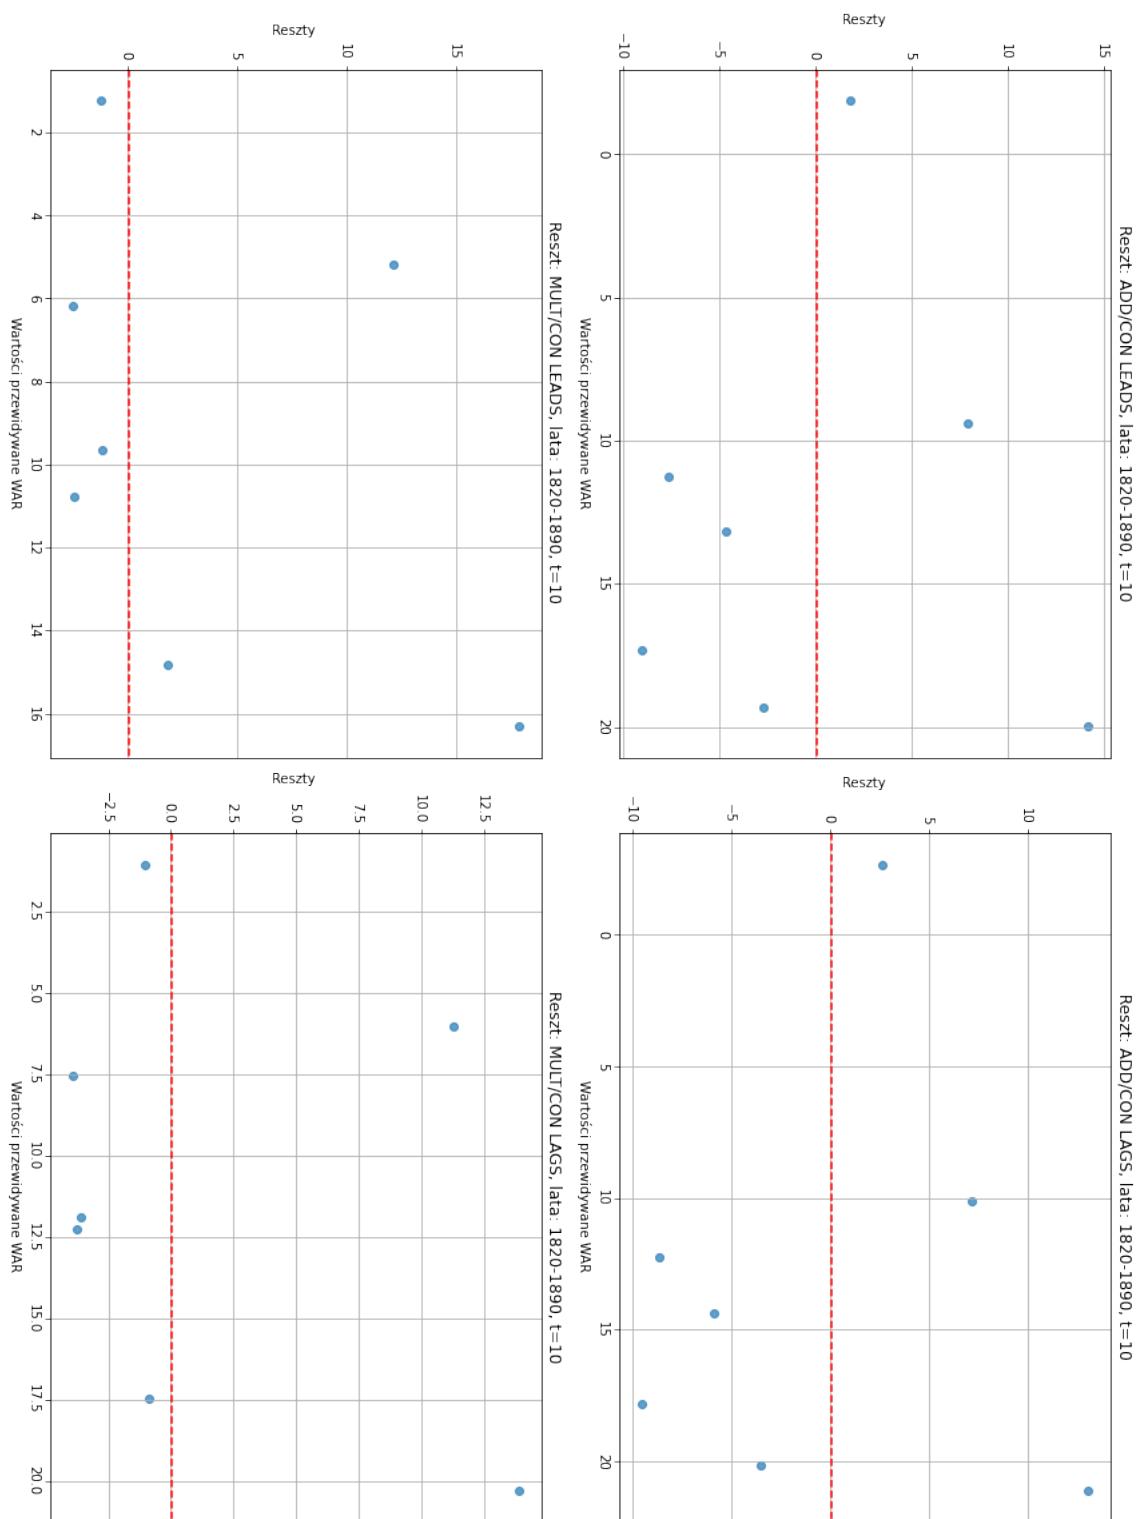
($t = 10$) prowadzi do bardziej stabilnych reszt, szczególnie w modelach ADD. Modele MULT mają trudności zarówno w $t = 1$, jak i $t = 10$, co może wynikać z większej złożoności ich założeń. Reszty w $t = 10$ są mniej rozproszone i bardziej równomierne, co sugeruje, że modele lepiej radzą sobie z danymi historycznymi przy dłuższym przedziale czasowym.

Jednakże test Shapiro ujawnia różnicę w spełnieniu założeń rozkładu normalnego reszt

Rysunek 2.16: Analiza reszt dla $t = 10$ dla lat 1820 – 1960

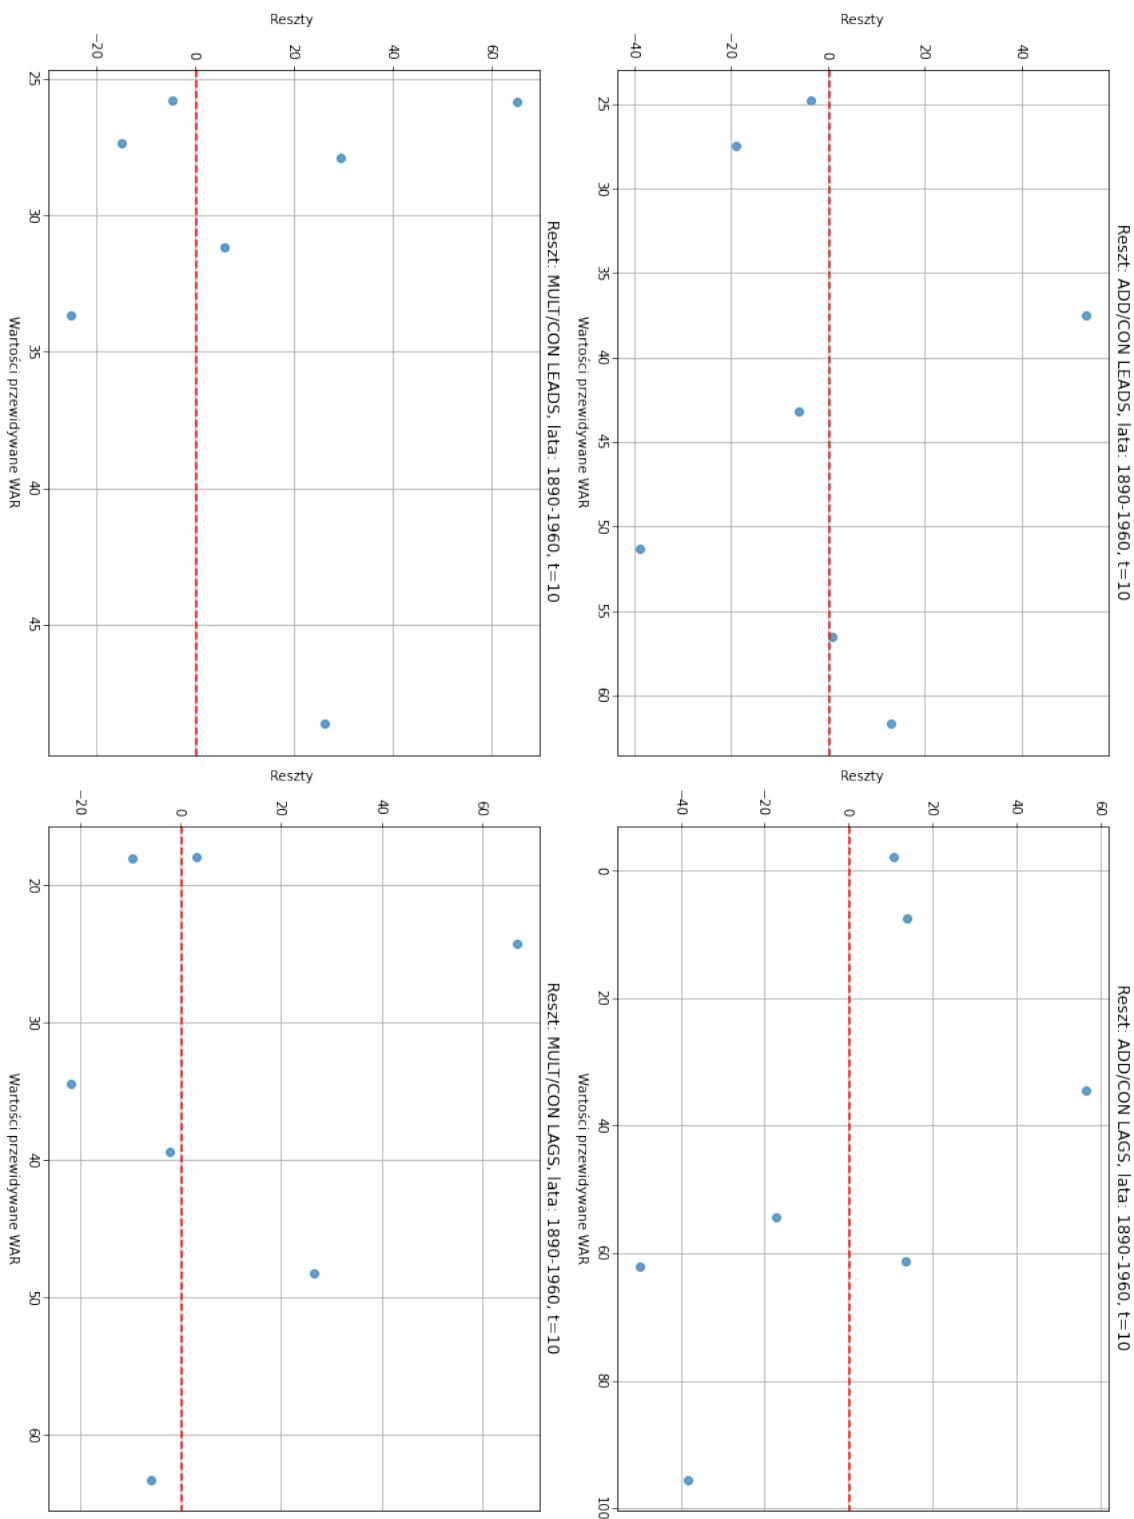
- dla $t = 10$ większość modeli spełnia to założenie, podczas gdy dla $t = 1$ nie spełnia go żaden model. Wskazuje to na potencjalne korzyści stosowania dłuższego horyzontu czasowego w analizach, szczególnie dla predykcji konfliktów w bardziej złożonych systemach historycznych.

Podsumowując, modele w $t = 10$ wydają się bardziej wiarygodne w dłuższych prze-



Rysunek 2.17: Analiza reszt dla $t = 10$ dla lat 1820 – 1890

działach czasowych, jednakże dla krótkoterminowych prognoz ($t = 1$) konieczne może być uwzględnienie dodatkowych zmiennych lub modyfikacja założeń modelu, aby poprawić jakość dopasowania.

Rysunek 2.18: Analiza reszt dla $t = 10$ dla lat 1890 – 1960

Podsumowanie

W tym rozdziale przeprowadzono szczegółową analizę modelu Singera, modyfikując jeden z jego kluczowych parametrów, oznaczony jako parametr t . Parametr ten, jak wskazano, odgrywa istotną rolę w dynamice modelu, wpływając bezpośrednio na trajektorie rozwiązania i ich stabilność w czasie.

Analiza dwuwymiarowa wskazała, że zarówno dla $t = 1$, jak i $t = 10$, zmienna CON ma ujemny wpływ na zmienną zależną WAR , podczas gdy zmienna $MOVE$ niemal zawsze wykazuje największy wpływ na WAR .

Przy ewaluacji modeli, modele dla $t = 10$ wykazały większą zdolność do odzwierciedlania danych rzeczywistych w porównaniu z modelami dla $t = 1$. Co więcej, dla $t = 1$ liderem okazały się modele ADD, a nie MULT, w przeciwieństwie do modeli z $t = 5$, choć żaden z modeli nie osiągnął wysokich wartości współczynnika determinacji R^2 .

Analiza również wykazała, że w przypadku $t = 1$ dla okresu 1820 – 1890 wszystkie modele działały gorzej niż w pozostałych okresach. Wyjątkowe wyniki osiągnął model MULT/CON LEADS dla $t = 10$ w tym samym okresie, uzyskując $R^2 = 0,731$, przy czym zmienna ΔCON wykazała największy wpływ na WAR .

Analiza pokazuje, że modyfikacja parametru t w modelu Singera może znacząco zmieniać jego wyniki, co podkreśla istotność doboru odpowiednich parametrów w modelowaniu konfliktów. Wyciągnięte wnioski stanowią solidną podstawę do dalszych badań nad wykorzystaniem modeli matematycznych w tej dziedzinie.

2.3 Prognozowanie wojen dla okresu czasowego do roku 2000

Ze względu na fakt, że przygotowanie odpowiednich danych i publikacja wyników jest procesem czasochronnym, istotnym wyzwaniem jest ocena możliwości wykorzystania istniejących modeli do prognozowania przyszłych zjawisk. W kontekście analizy konfliktów zbrojnych, szczególnie interesujące jest sprawdzenie, czy model oparty na danych historycznych z poprzednich lat może być użyteczny w przewidywaniu przyszłych konfliktów.

W tym rozdziale podjęto próbę prognozowania zmiennej zależnej WAR dla okresu do roku 2000, korzystając z modeli przygotowanych na podstawie danych z różnych okresów historycznych: 1820 – 1960, 1820 – 1890 oraz 1890 – 1960, a także z wykorzystaniem różnych wartości parametru t ($t = 1, t = 5, t = 10$). Dodatkowo wyniki tych modeli zostaną porównane z modelem uczonym bezpośrednio na danych z lat 1950 – 2000. Analiza ta pozwoli odpowiedzieć na pytanie, czy modele oparte na danych historycznych są w stanie skutecznie prognozować przyszłe zjawiska, czy też bardziej efektywne jest korzystanie z modeli uczonych na bieżących, współczesnych danych.

W pierwszej połowie tego rozdziału zostaną przedstawione wyniki prognoz modeli z różnymi wartościami t , trenowanych na okresach czasowych zaproponowanych przez J.D. Singera: 1820 – 1960, 1820 – 1890, 1890 – 1960. Proces analizy obejmował ocenę jakości prognoz poprzez porównanie przewidywanych wartości WAR z danymi rzeczywistymi, przedstawienie wykresów prognozowanych wartości wraz z rzeczywistymi oraz obliczenie średniego błędu bezwzględnego (MAE) i błędu średniokwadratowego (MSE). Ponadto przeprowadzono analizę reszt, w tym ich wizualizację oraz testowanie normalności przy użyciu testu Shapiro-Wilka.

W drugiej połowie tego rozdziału zostaną przedstawione wyniki dla modeli trenowanych z różnymi wartościami t na okresie lat powojennych – 1950–2000. Wyniki te obejmują ewaluację modeli, przedstawienie wykresów prognozowanych wartości wraz z rzeczywistymi, obliczenie MAE i MSE oraz analizę reszt.

Prognozy modeli z $t = 1$ opartych na danych historycznych z okresu 1820–1960 i jego podziałów

Na przedstawionych wykresach 2.19, 2.20, 2.21 zaprezentowano prognozy wartości zmiennej WAR do roku 2000 dla modeli ADD/CON oraz MULT/CON (LEADS i LAGS), trenowanych na trzech różnych okresach czasowych: 1820 – 1890, 1820 – 1960 oraz 1890 – 1960. W Tabeli 2.20 zaprezentowano również wartości średniego błędu bezwzględnego (MAE) oraz średniego błędu kwadratowego (MSE) dla każdego z modeli.

Tabela 2.20: Średni błąd bezwzględny (MAE) oraz kwadratowy (MSE) dla modeli z $t = 1$ trenowanych na trzech okresach czasowych

Model	1820 – 1960		1820 – 1890		1890 – 1960	
	MAE	MSE	MAE	MSE	MAE	MSE
ADD/CON LEADS	13.89	470.76	13.82	418.01	14.80	499.91
ADD/CON LAGS	13.97	478.41	13.65	416.12	14.91	509.08
MULT/CON LEADS	12.55	422.82	12.29	394.54	12.52	421.03
MULT/CON LAGS	12.58	424.93	12.24	398.85	12.56	423.83

Źródło: opracowanie własne

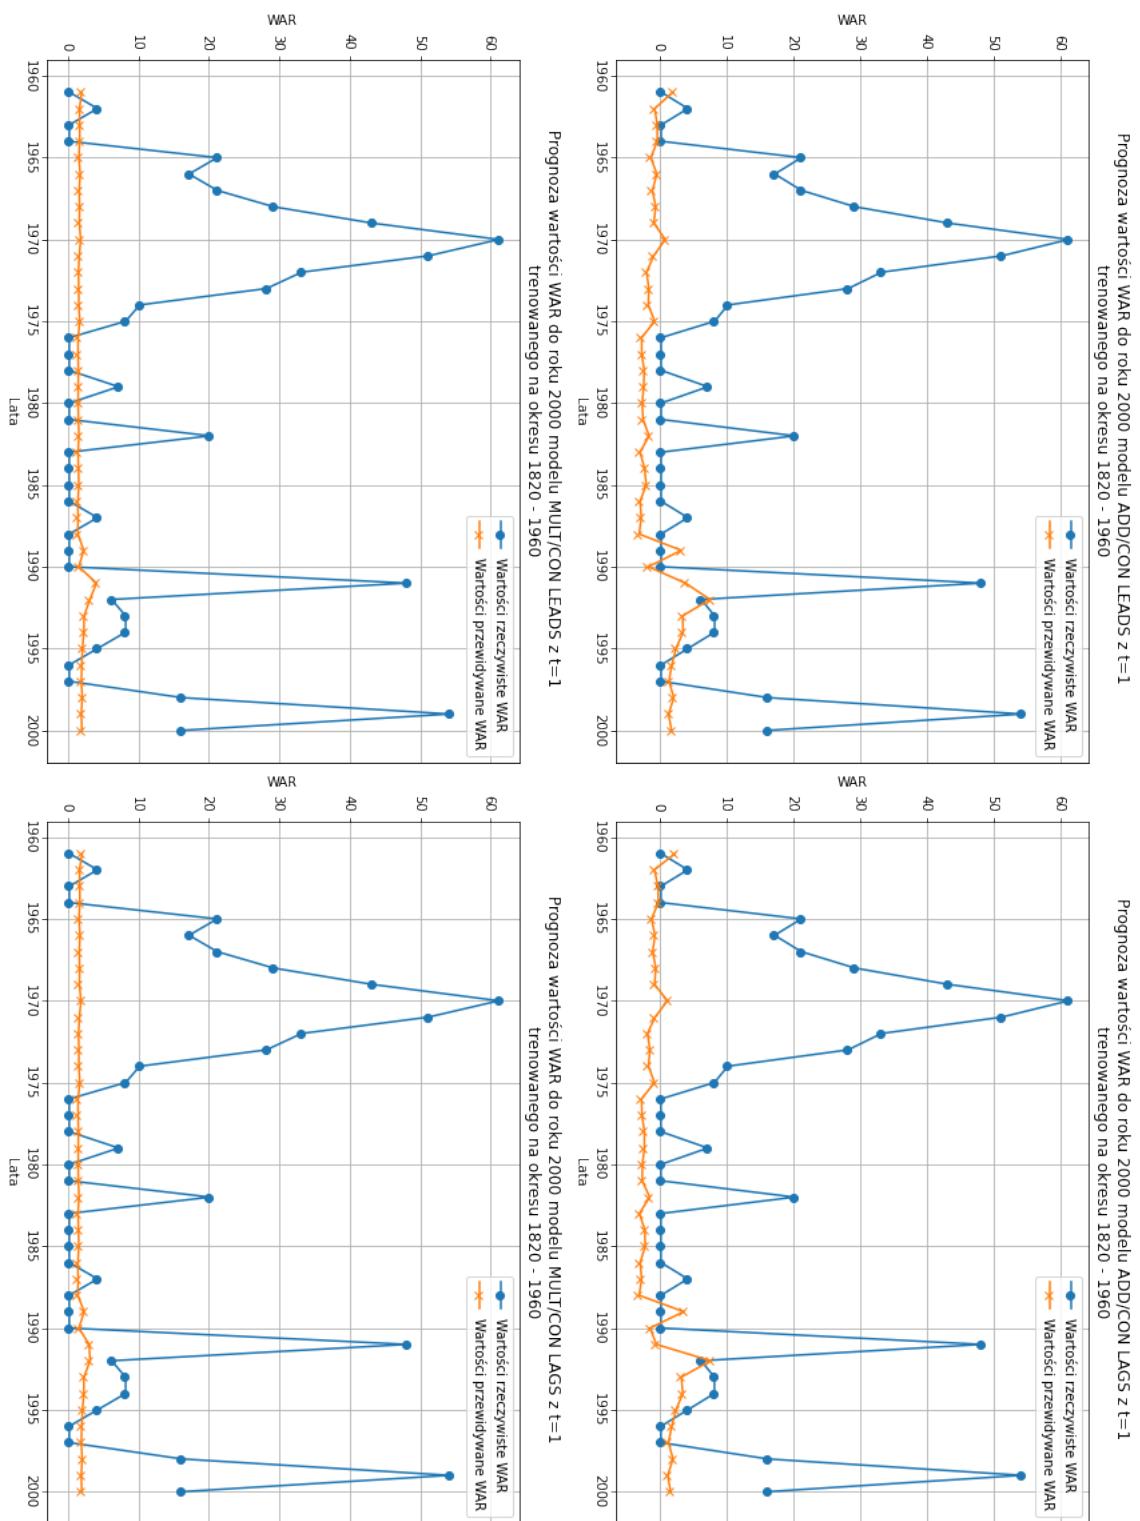
Modele trenowane na okresie 1820 – 1890 charakteryzują się zauważalnymi różnicami między wartościami rzeczywistymi a przewidywanymi dla lat po 1890 roku. Szczególnie widać, że wartości prognozowane przez modele ADD mają tendencję do zaniedania wartości rzeczywistych w okresach wzmożonych konfliktów. Modele MULT, choć nieco lepiej odzwierają dynamikę zmiennej WAR, także mają trudności z uchwyceniem ekstremalnych wartości.

Wartości MAE i MSE dla tego okresu są niższe w porównaniu do dłuższych okresów trenowania, co sugeruje, że modele są lepiej dopasowane do danych historycznych, ale ich zdolność do predykcji przyszłych wartości jest ograniczona. Na przykład, MAE dla MULT/CON LAGS wynosi jedynie 12.24, a MSE 398.85, co jest najniższym wynikiem w porównaniu z innymi okresami.

Okres 1820 – 1960 Modele trenowane na pełnym okresie historycznym mają lepsze dopasowanie do wartości rzeczywistych w latach powojennych (1945 – 1960), co jest szczególnie widoczne w modelach ADD. Niemniej jednak, wartości prognozowane do roku 2000 wykazują znaczne odchylenia od wartości rzeczywistych.

MAE i MSE dla tego okresu są wyższe niż dla okresu 1820 – 1890, co wskazuje na trudności modeli w odtwarzaniu bardziej złożonej dynamiki konfliktów obejmującej XX wiek. Na przykład, MULT/CON LEADS osiąga MSE na poziomie 422.82, co jest wyższe niż dla krótszych okresów.

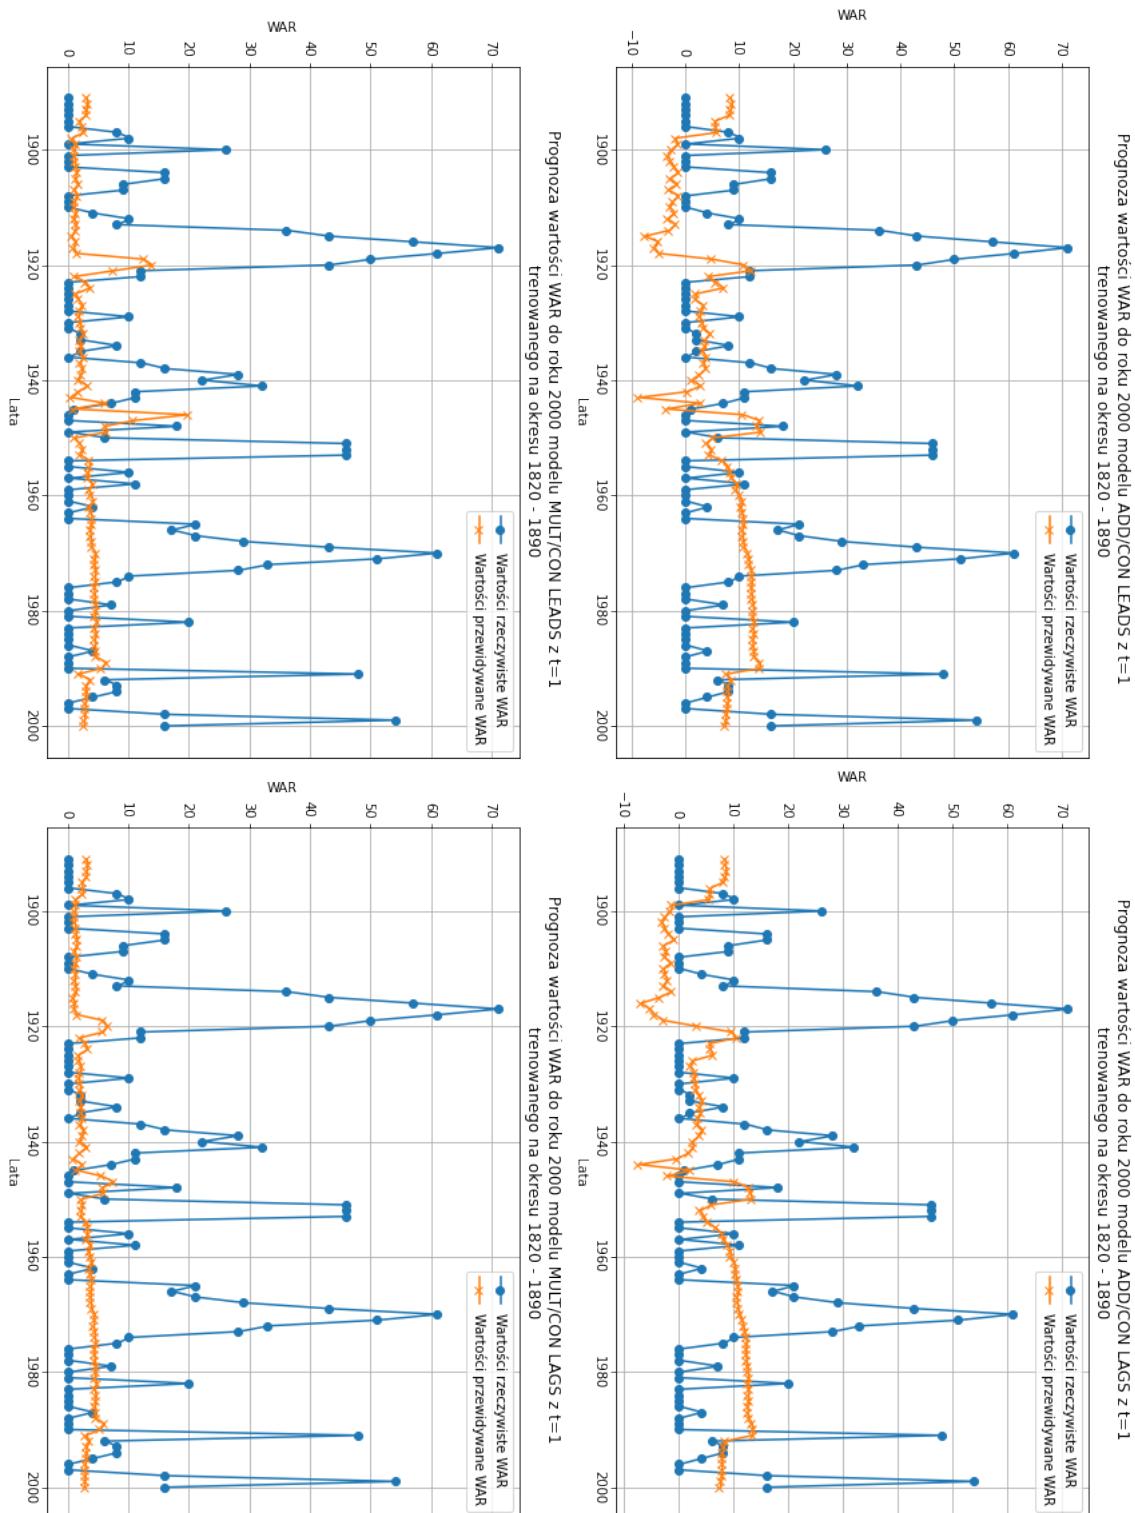
Modele trenowane na okresie 1890 – 1960 wykazują najmniejsze dopasowanie do danych historycznych i wartości prognozowanych do roku 2000. Szczególnie widoczne jest to w modelach ADD, które nie radzą sobie z odtworzeniem wartości rzeczywistych w okresach intensywnych konfliktów, takich jak wojny światowe. MULT, mimo że lepiej odzwierają wartości w okresie trenowania, również mają trudności z predykcją przyszłych wartości, a ich prognozy dla lat po 1960 roku wykazują wyraźne różnice w stosunku do wartości rzeczywistych.



Rysunek 2.19: Prognoza modeli dla $t = 1$ trenowanych na latach 1820 – 1960

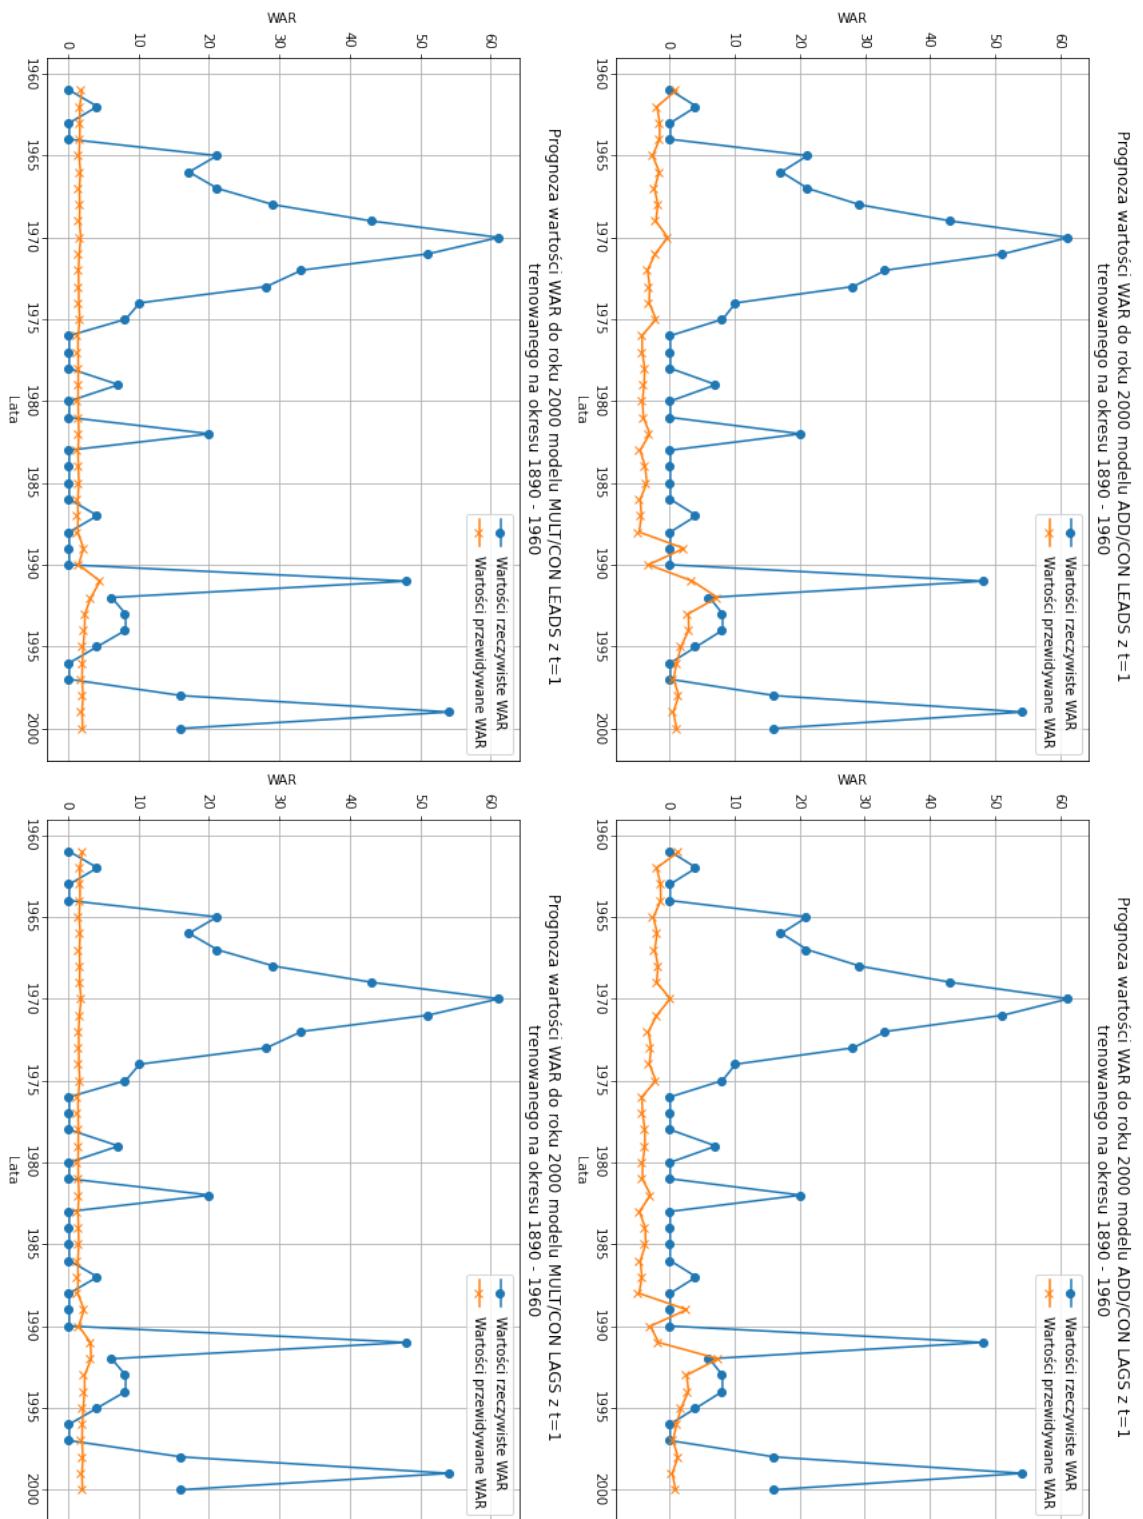
Wartości MAE i MSE dla tego okresu są najwyższe spośród wszystkich analizowanych. Dla przykładu, ADD/CON LAGS osiąga MSE na poziomie 509.08, co jest wyraźnym wskaźnikiem niedopasowania.

Wartości prognozowane w modelach ADD, które często są ujemne, mogą wynikać z liniowego charakteru modeli oraz braku ograniczeń dolnych na prognozowaną zmienną

Rysunek 2.20: Prognoza modeli dla $t = 1$ trenowanych na latach 1820 – 1890

WAR. Modele te nie uwzględniają faktu, że zmienna WAR reprezentuje liczby konfliktów zbrojnych, które w rzeczywistości nie mogą przyjmować wartości ujemnych. Rozwiązaniem tego problemu mogłoby być zastosowanie transformacji logarytmicznej (modele MULT) lub innych metod ograniczających prognozy do wartości nieujemnych.

Modele trenowane na dłuższych okresach czasu mają tendencję do lepszego odzworzo-



Rysunek 2.21: Prognoza modeli dla $t = 1$ trenowanych na latach 1890 – 1960

wania trendów w danych historycznych, jednak ich zdolność do prognozowania wartości poza zakresem trenowania jest ograniczona. Wartości ujemne prognozowane przez modele wskazują na potrzebę modyfikacji metodologii, na przykład poprzez uwzględnienie dodatkowych ograniczeń lub zastosowanie bardziej zaawansowanych technik modelowania. Modele MULT wydają się lepiej radzić z odtwarzaniem dynamiki konfliktów, jednak ich

wyniki również wymagają dalszej optymalizacji.

Analiza reszt

Wykresy reszt dla modeli ADD/CON LEADS, ADD/CON LAGS oraz MULT/CON LEADS, MULT/CON LAGS, trenowanych na trzech okresach czasowych (1820 – 1890, 1820 – 1960 oraz 1890 – 1960) przedstawione na Rysunkach 2.22, 2.23, 2.24. Wykresy reszt pozwalały ocenić jakość dopasowania modeli oraz sprawdzić, czy założenia dotyczące rozkładu normalnego reszt są spełnione. Wyniki testu Shapiro wskazują, że w każdym przypadku reszty nie mają rozkładu normalnego, co sugeruje potencjalne problemy z dokładnością modeli lub ich założeniami.

Dla modeli trenowanych na okresie 1820 – 1890 reszty są bardzo zróżnicowane i wykazują wyraźną asymetrię. Modele ADD/CON LEADS oraz LAGS generują znaczące reszty dla wartości rzeczywistych zmiennej WAR, zwłaszcza w obszarach wysokich wartości przewidywanych. Reszty dla modeli MULT/CON LEADS i LAGS są nieco bardziej rozproszone, co wskazuje na trudności w odwzorowaniu zmiennej WAR przy większych wartościach.

Rozkład reszt dla tego okresu wskazuje na brak losowości, co może sugerować niedopasowanie modeli lub brak kluczowych zmiennych w analizie. To potwierdza wynik testu Shapiro, który wskazuje, że rozkład reszt znacznie odbiega od normalnego.

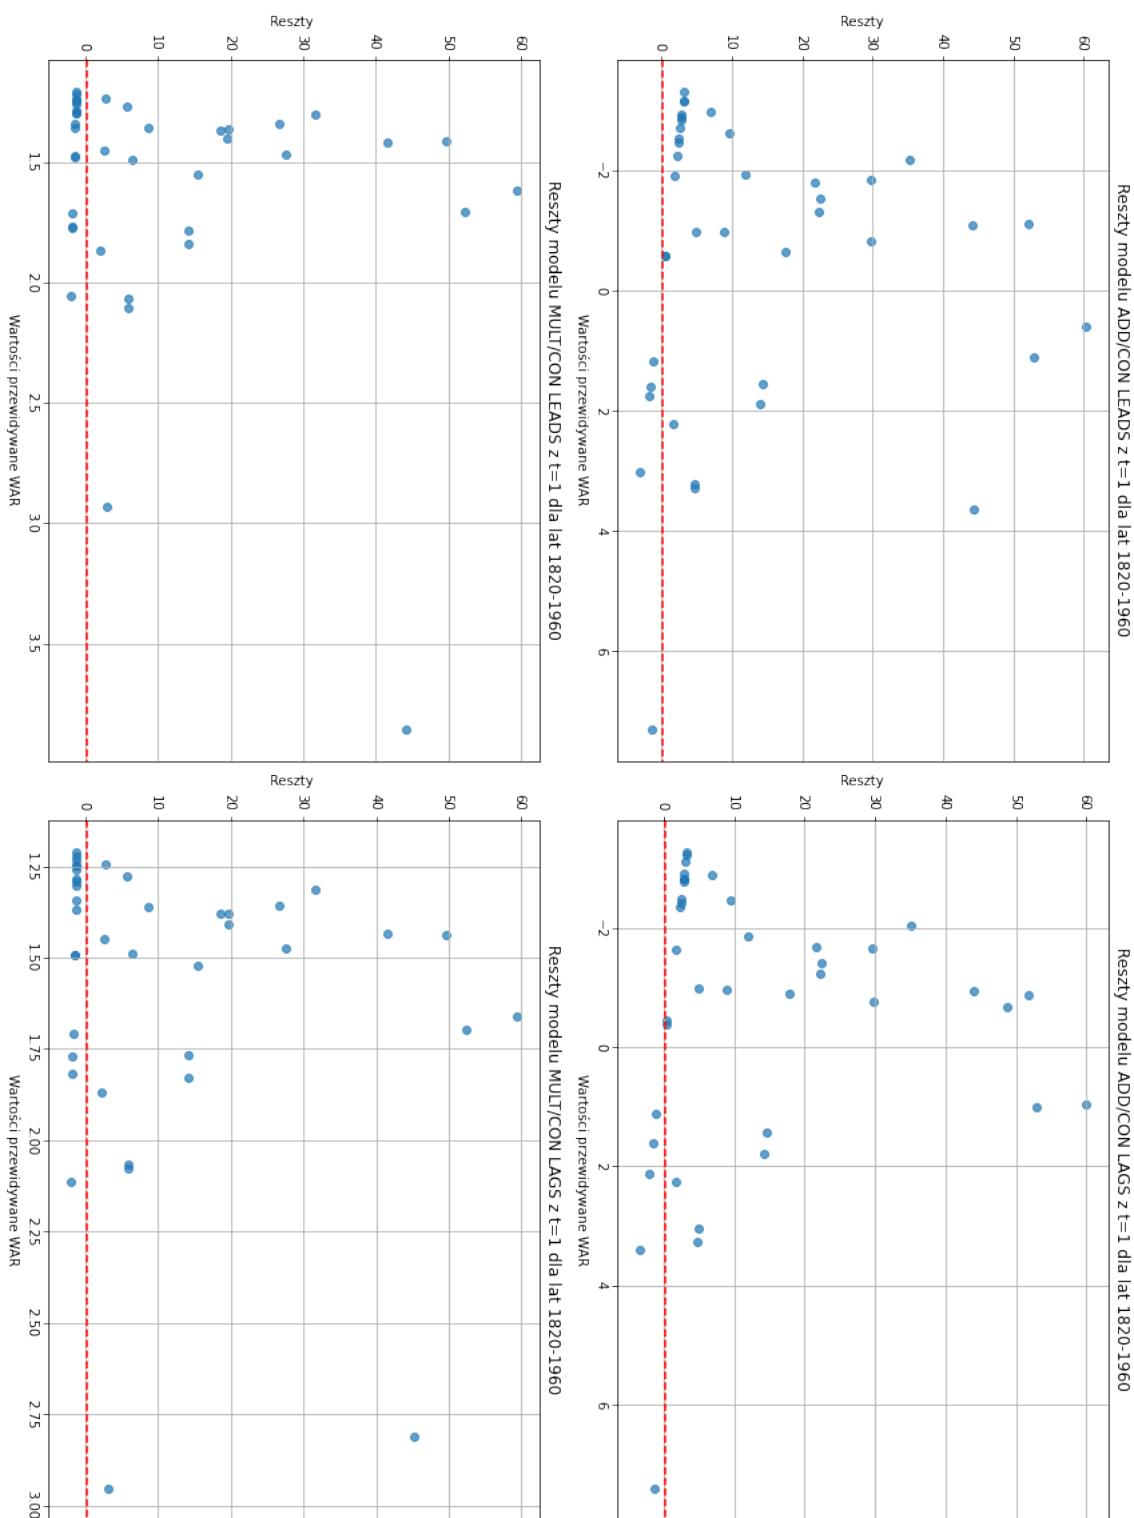
Modele trenowane na dłuższym okresie (1820 – 1960) generują reszty o większym zakresie wartości, co jest szczególnie widoczne w modelach ADD. Dla tych modeli można zauważać, że reszty systematycznie rosną wraz z wartością przewidywaną, co wskazuje na możliwą obecność heteroskedastyczności (zmienność reszt nie jest stała).

W modelach MULT/CON LEADS i LAGS reszty mają bardziej zwarty rozkład, ale nadal występują znaczne odchylenia dla wysokich wartości WAR. Warto zauważać, że dłuższy okres trenowania wprowadza większe zróżnicowanie w resztach, co może wynikać z bardziej skomplikowanych trendów w danych historycznych.

Dla modeli trenowanych na okresie 1890 – 1960 reszty są najmniej losowe, co jest szczególnie widoczne w modelach ADD/CON LEADS i LAGS. Modele te generują wyraźnie systematyczne błędy, co wskazuje na ich niedopasowanie do danych.

W przypadku modeli MULT/CON LEADS i LAGS reszty również nie mają rozkładu normalnego, ale są bardziej równomiernie rozproszone niż w przypadku modeli ADD. Wyniki te wskazują, że modele MULT mogą być lepiej przystosowane do danych z tego okresu, ale nadal mają trudności z odwzorowaniem rzeczywistej zmiennej WAR.

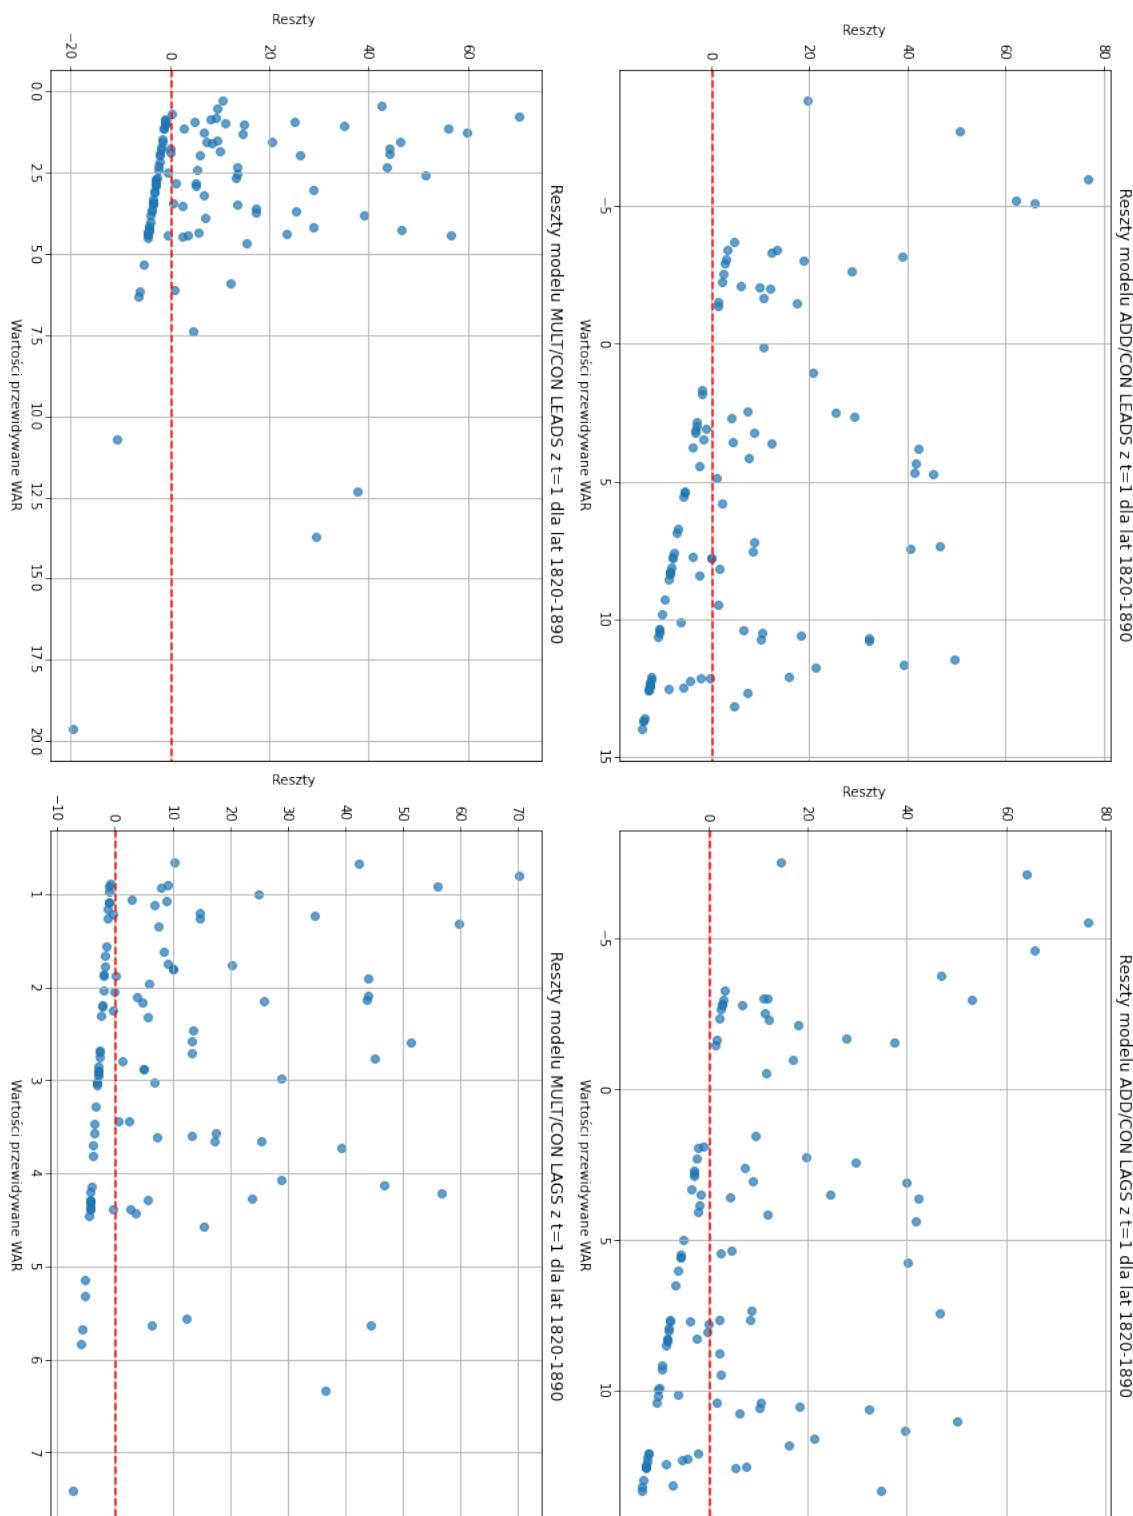
Wszystkie modele generują reszty, które nie spełniają założenia normalności (wynik testu Shapiro). Oznacza to, że modele mogą nie być odpowiednie do pełnej analizy danych lub wymagają dalszej kalibracji. Modele MULT radzą sobie lepiej z odwzorowaniem dynamiki zmiennej WAR, ale nadal generują znaczące reszty, zwłaszcza dla większych wartości zmiennej WAR. Modele ADD wykazują silne niedopasowanie, szczególnie dla wartości skrajnych, co może wynikać z niewystarczającego uwzględnienia dynamiki historycznych konfliktów. Dłuższe okresy trenowania (1820 – 1960) wprowadzają większą różnorodność reszt, co wskazuje na większe trudności w odwzorowaniu danych obejmujących bardziej złożone procesy historyczne. Zaleca się dalsze modyfikacje modeli.



Rysunek 2.22: Wykresy reszt dla $t = 1$ trenowanych na latach 1820 – 1960

Prognozy modeli z $t = 5$ opartych na danych historycznych z okresu 1820–1960 i jego podziałów

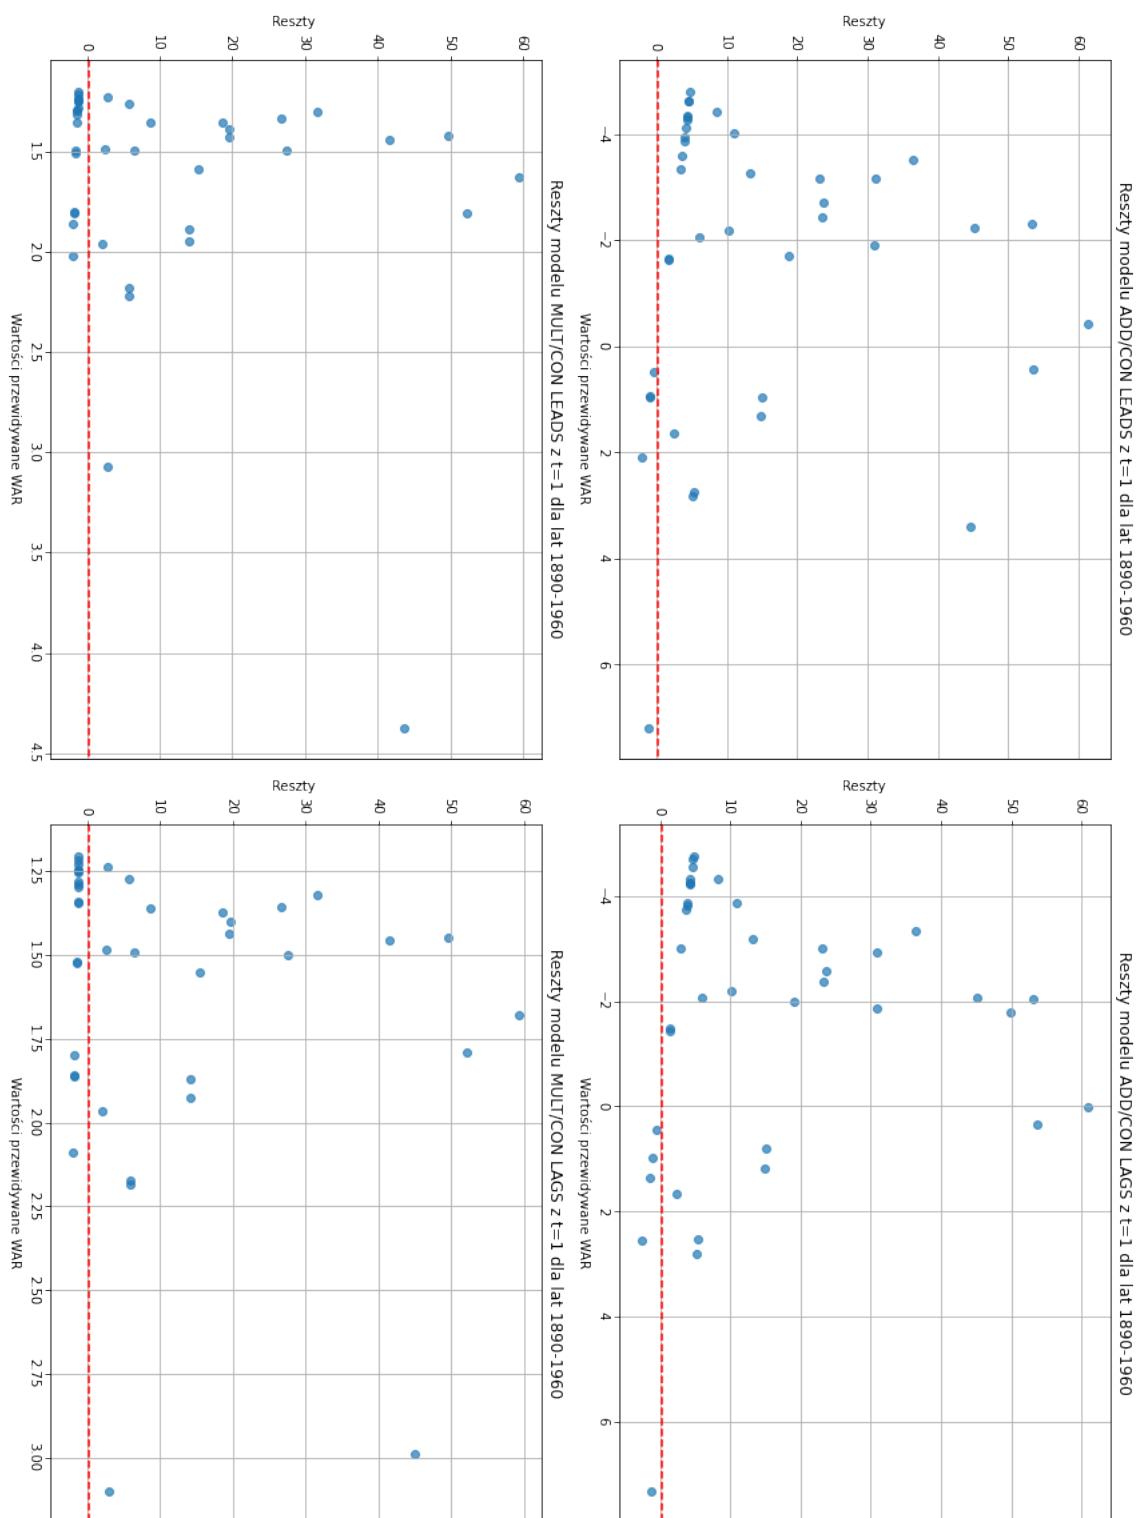
Przeprowadzona analiza prognoz zmiennej WAR dla parametrów modelu ($t=5$) oraz dla trzech okresów czasowych (1820–1960, 1820–1890, 1890–1960) przedstawiona w Tabeli 2.21



Rysunek 2.23: Wykresy reszt dla $t = 1$ trenowanych na latach 1820 – 1890

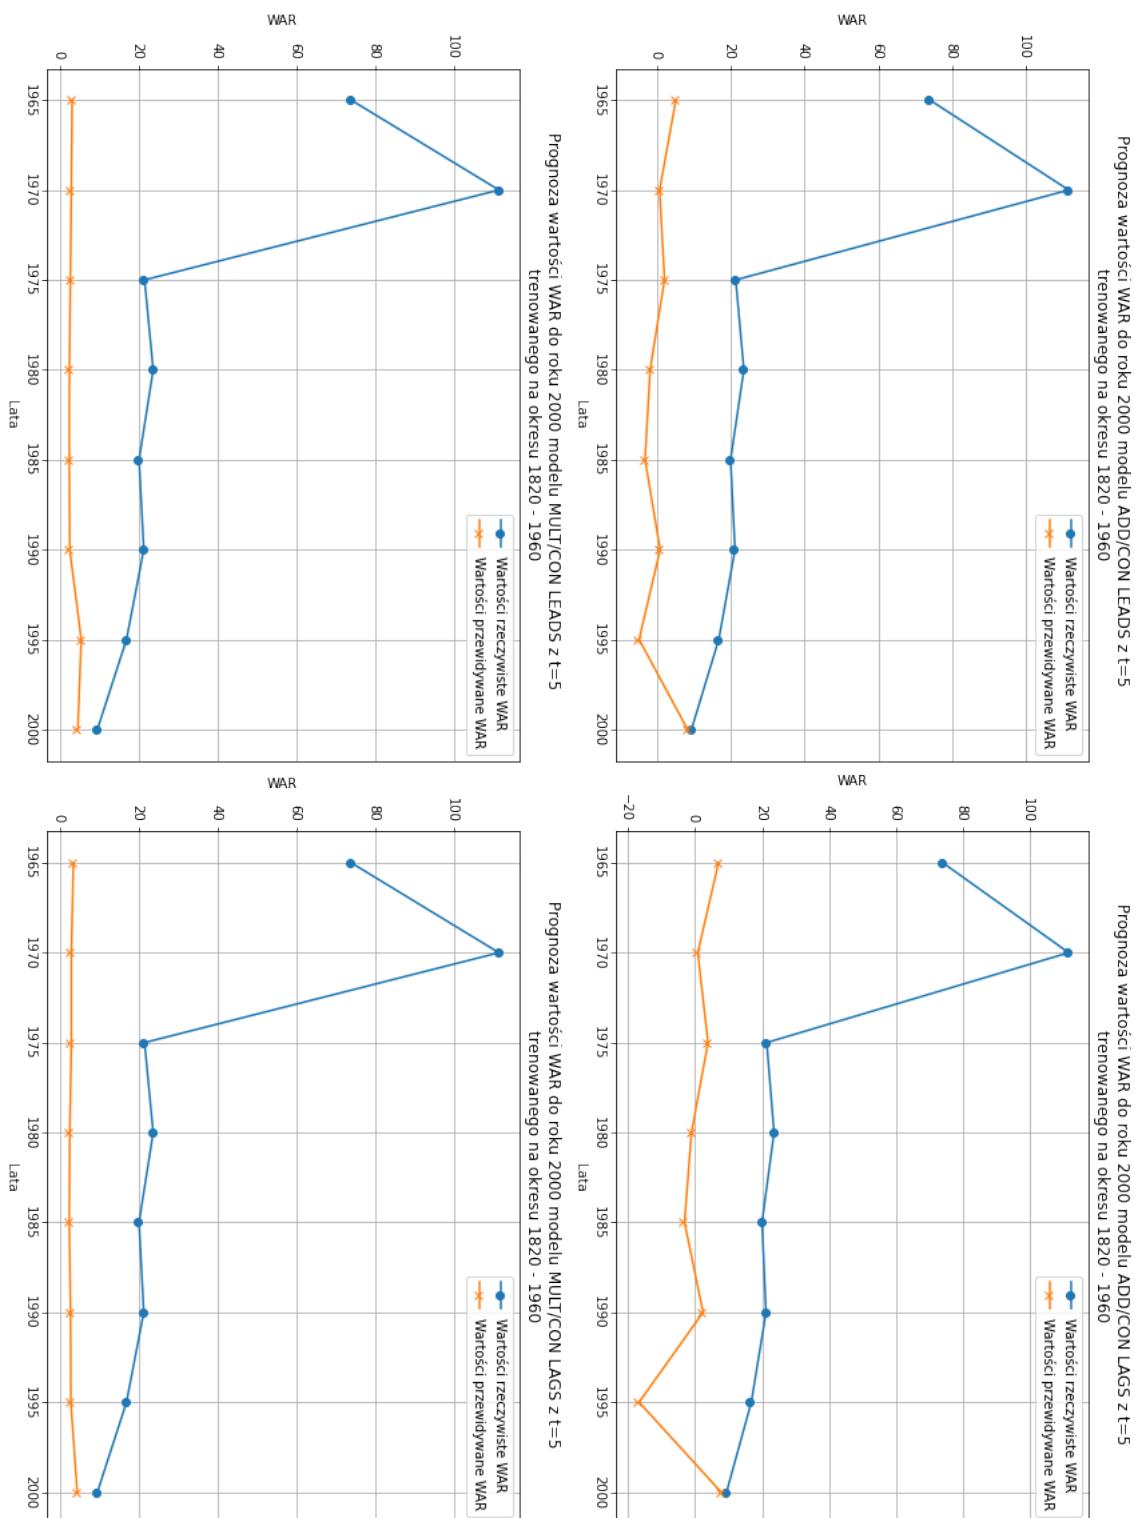
(MAE oraz MSE) oraz na Rysunkach 2.25, 2.26, 2.27 wskazuje na znaczne różnice w jakości predykcji pomiędzy modelami ADD a modelami MULT, a także na istotny wpływ okresu szkoleniowego na wyniki modeli.

Modele ADD/CON LEADS oraz ADD/CON LAGS dla wszystkich trzech okresów czasowych wykazują względnie stabilne predykcje zmiennej WAR. Na wykresach prognozo-



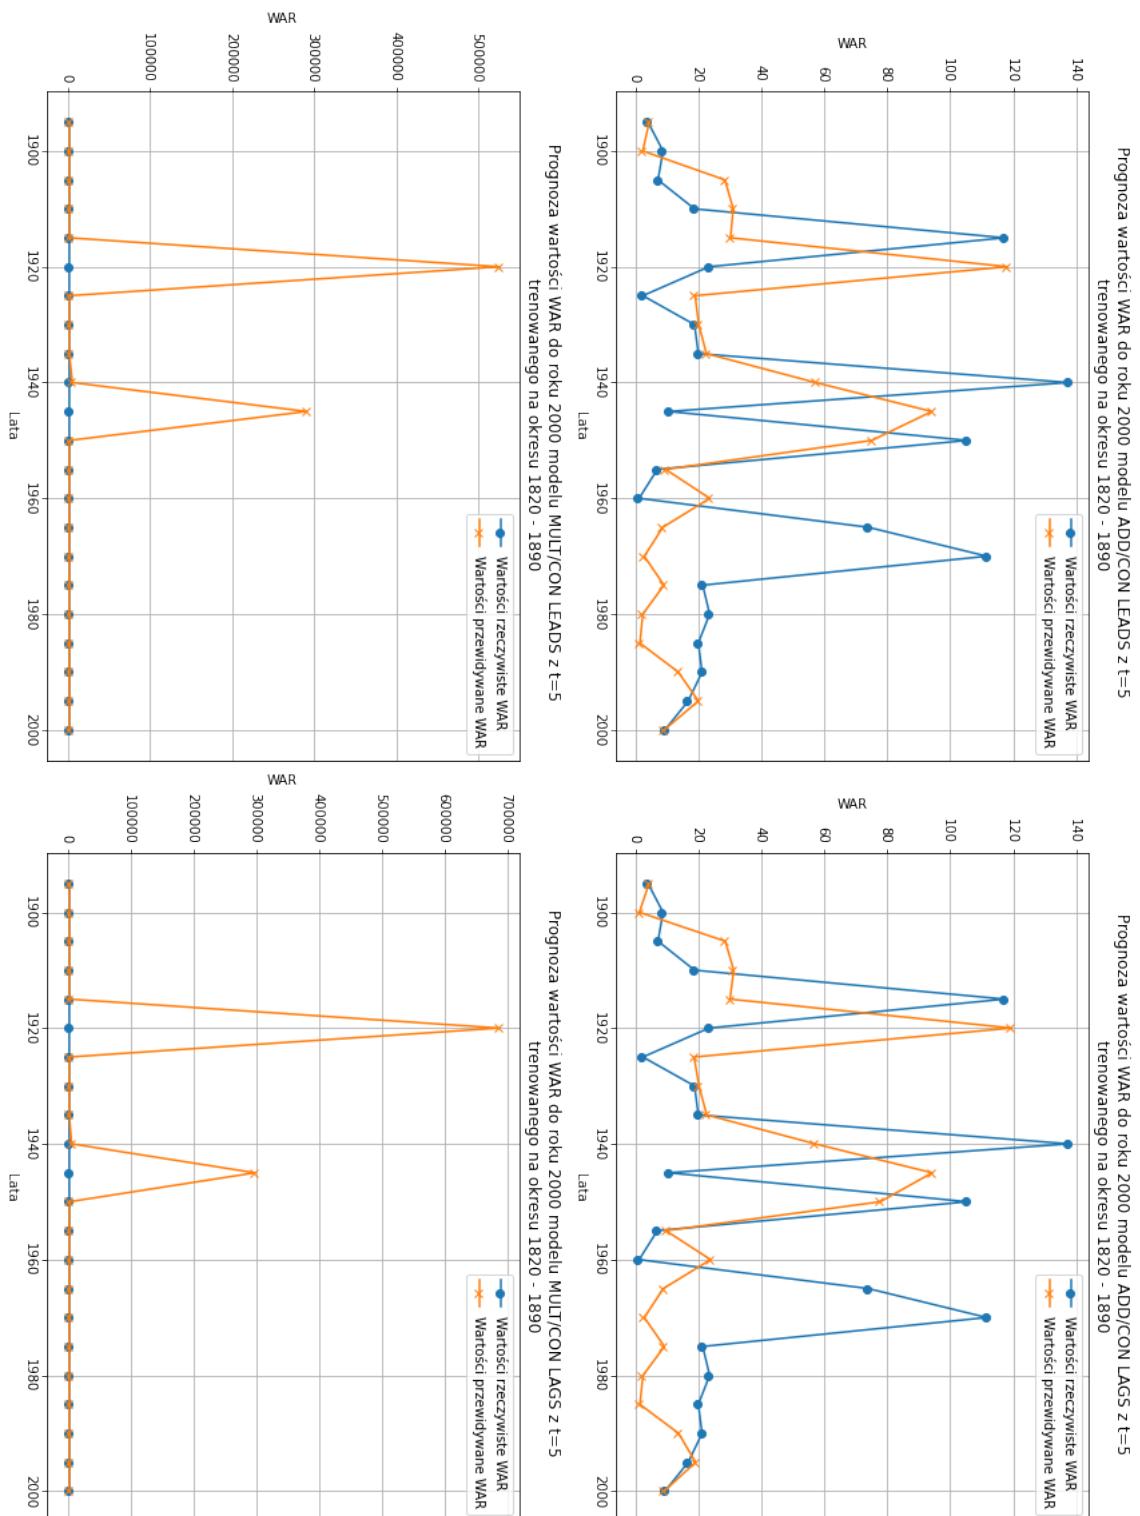
Rysunek 2.24: Wykresy reszt modeli dla $t = 1$ trenowanych na latach 1890 – 1960

wanych wartości zauważalne są niewielkie odchylenia od wartości rzeczywistych, szczególnie w bardziej współczesnych latach. Wskaźniki błędów MSE i MAE w tych modelach są porównywalne, przy czym w przypadku modelu ADD/CON LEADS dla okresu 1820 – 1960 $MSE = 2432.10$ oraz $MAE = 36.31$, a dla okresu 1820 – 1890 $MSE = 2247.09$ oraz $MAE = 31.77$. Wartości te wskazują, że modele ADD generalnie są dobrze dopasowane,

Rysunek 2.25: Prognoza modeli dla $t = 5$ trenowanych na latach 1820 – 1960

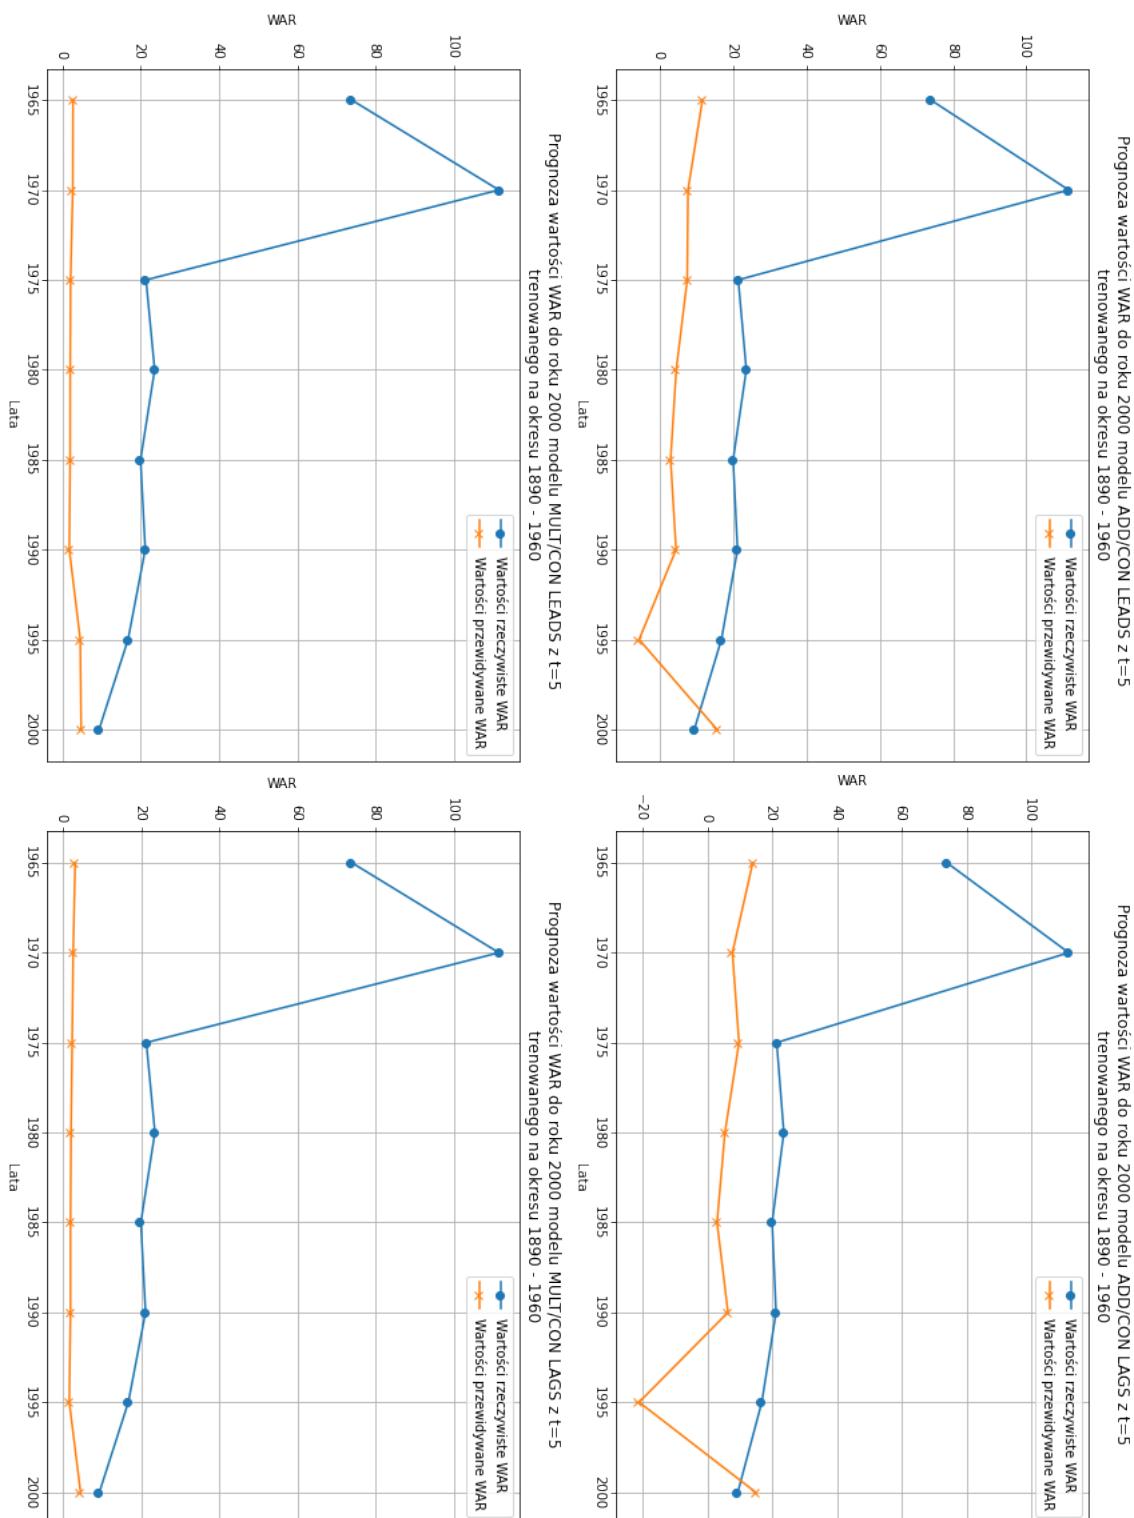
choć ich jakość prognoz spada w miarę oddalania się od okresu szkoleniowego.

Dla modeli MULT/CON LEADS oraz MULT/CON LAGS sytuacja jest diametralnie inna. W przypadku tych modeli zaobserwowano bardzo duże wartości prognozowane zmiennej WAR, szczególnie w okresie 1820 – 1890. Na przykład, w modelu MULT/CON LEADS w latach 1920 oraz 1940 prognozy osiągają wartości przekraczające 500,000, co jest



Rysunek 2.26: Prognoza modeli dla $t = 5$ trenowanych na latach 1820 – 1890

zdecydowanie nierealistyczne i świadczy o znacznym przetrenowaniu modelu. Takie wyniki są efektem niewłaściwego skalowania wartości w modelach MULT, które uwzględniają produkty między zmiennymi, prowadząc do eskalacji wartości przewidywanych w przypadku ich dużych zakresów. Wyniki błędów dla tych modeli są również nieakceptowalnie wysokie, szczególnie dla okresu 1820 – 1890.

Rysunek 2.27: Prognoza modeli dla $t = 5$ trenowanych na latach 1890 – 1960

Analizując okres 1890 – 1960, modele MULT wykazują mniejsze odchylenia wartości przewidywanych, jednak nadal ich MSE oraz MAE są większe niż w przypadku modeli ADD. Wynika to z faktu, że okres szkoleniowy obejmuje bardziej zbliżone wartości zmiennych do tych występujących w prognozowanym okresie.

Tabela 2.21: Średni błąd bezwzględny (MAE) oraz kwadratowy (MSE) dla modeli z $t = 5$ trenowanych na trzech okresach czasowych

Model	1820 – 1960		1820 – 1890		1890 – 1960	
	MAE	MSE	MAE	MSE	MAE	MSE
ADD/CON LEADS	36.31	2432.10	31.77	2247.09	32.73	2046.07
ADD/CON LAGS	37.14	2461.86	31.74	2254.21	33.62	2104.12
MULT/CON LEADS	34.15	2316.57	37090.36	16224055348.28	34.41	2331.87
MULT/CON LAGS	34.39	2316.60	44694.80	25222595267.21	34.66	2330.29

Źródło: opracowanie własne

Podsumowując, modele MULT w analizie z $t = 5$ wykazują znaczco gorsze dopasowanie niż modele ADD. Ich nadmiernie wysokie wartości przewidywane oraz bardzo duże wartości MSE i MAE wskazują na brak możliwości ich zastosowania w praktycznych prognozach. Modele ADD natomiast, mimo pewnych ograniczeń w dokładności, są bardziej stabilne i oferują lepsze dopasowanie w różnych okresach czasowych. Wyniki te podkreślają znaczenie właściwego wyboru struktury modelu oraz precyzyjnego skalowania zmiennych w analizie ilościowej.

Analiza reszt

Dla modeli z $t = 5$, analiza reszt wskazuje na istotne różnice w dopasowaniu dla różnych okresów czasowych i modeli. Analiza została przedstawiona na wykresach 2.28, 2.29, 2.30.

Na podstawie wykresów reszt oraz wyników testu Shapiro-Wilka można sformułować następujące wnioski.

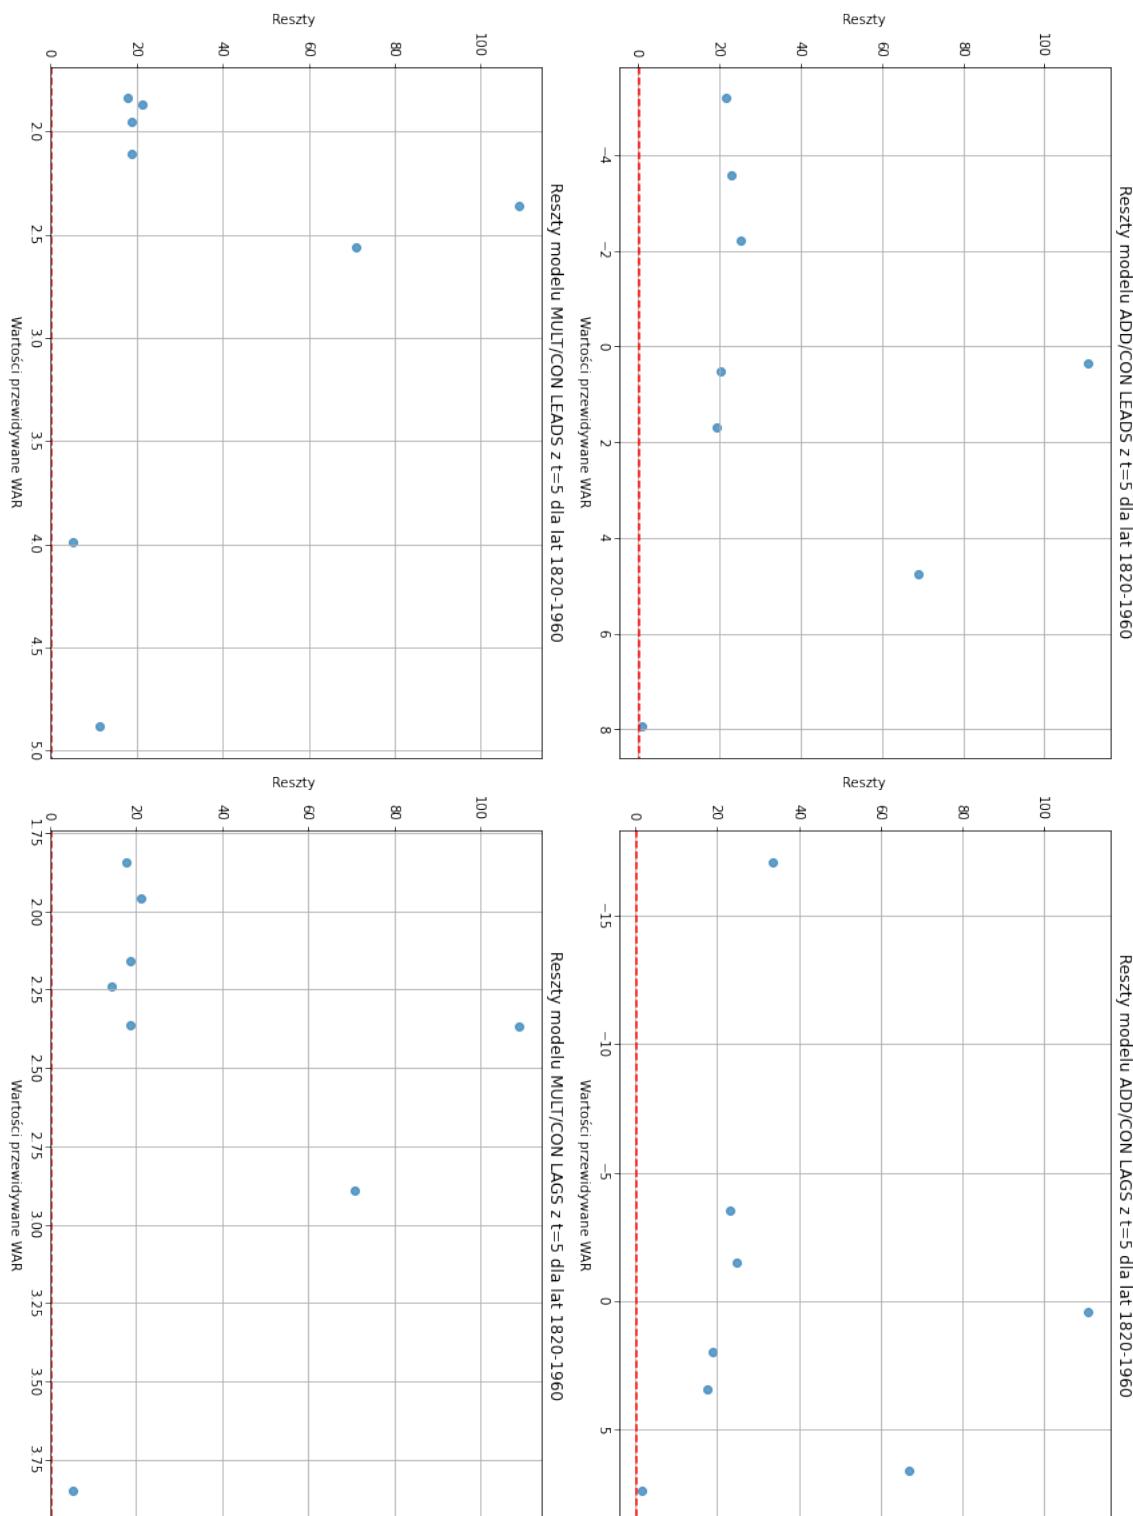
W okresie 1820 – 1960 w modelach ADD/CON LEADS i ADD/CON LAGS reszty pokazują umiarkowane odchylenia, a ich rozkład jest niesymetryczny, co wskazuje na brak normalności reszt w tych przypadkach. Wartości reszt są znacznie mniejsze w porównaniu do modeli MULT/CON, co potwierdza lepsze dopasowanie modeli ADD w tym okresie. Test Shapiro potwierdza brak normalności reszt w obu modelach ADD oraz MULT.

Modele MULT/CON LEADS i MULT/CON LAGS wykazują bardzo duże wartości reszt, zwłaszcza w okresach, gdzie wartości WAR były znaczco zawyżone, co wskazuje na problem z predykcją przy dużych wartościach zmiennych wejściowych. Wartości reszt w modelach MULT wykraczają poza skalę oczekiwania, co czyni te modele niewiarygodnymi.

Dla modeli ADD/CON LEADS i LAGS w okresie 1820 – 1890 reszty mają mniejszą rozpiętość w porównaniu do innych okresów. Dodatkowo test Shapiro wykazuje normalność reszt w obu modelach ADD, co wskazuje na lepszą jakość dopasowania tych modeli w tym okresie.

Modele MULT w tym okresie generują niezwykle wysokie wartości reszt, co wynika z błędów w przewidywaniu ekstremalnych wartości WAR. Te modele są wyraźnie niewłaściwe dla tego okresu, o czym świadczą zarówno wyniki reszt, jak i MSE (które w przypadku MULT/CON LEADS osiągają wartość 16224055348.28).

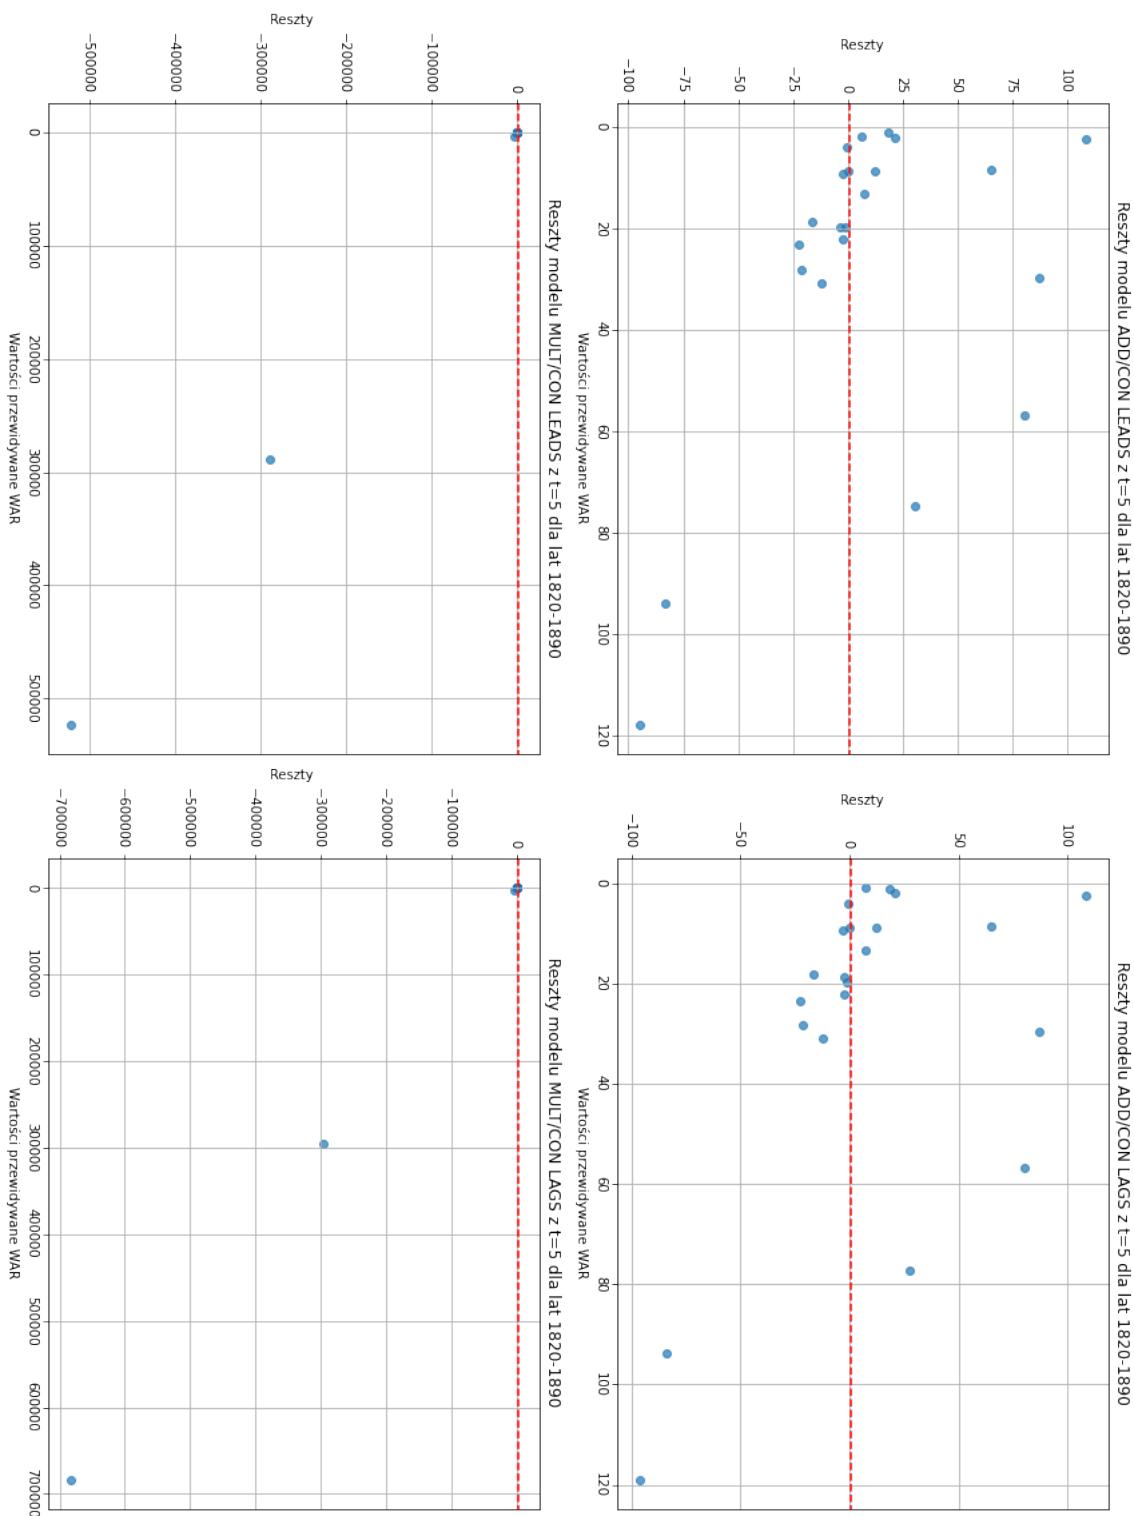
Modele ADD/CON LEADS i ADD/CON LAGS wykazują względnie lepsze dopasowanie w okresie 1890 – 1960, z mniejszymi resztami i względnie niższymi wartościami MSE w porównaniu do okresu 1820 – 1960. Test Shapiro potwierdza normalność reszt w modelu ADD/CON LAGS, co potwierdza jego stabilność w tym okresie.



Rysunek 2.28: Wykresy reszt dla $t = 5$ trenowanych na latach 1820 – 1960

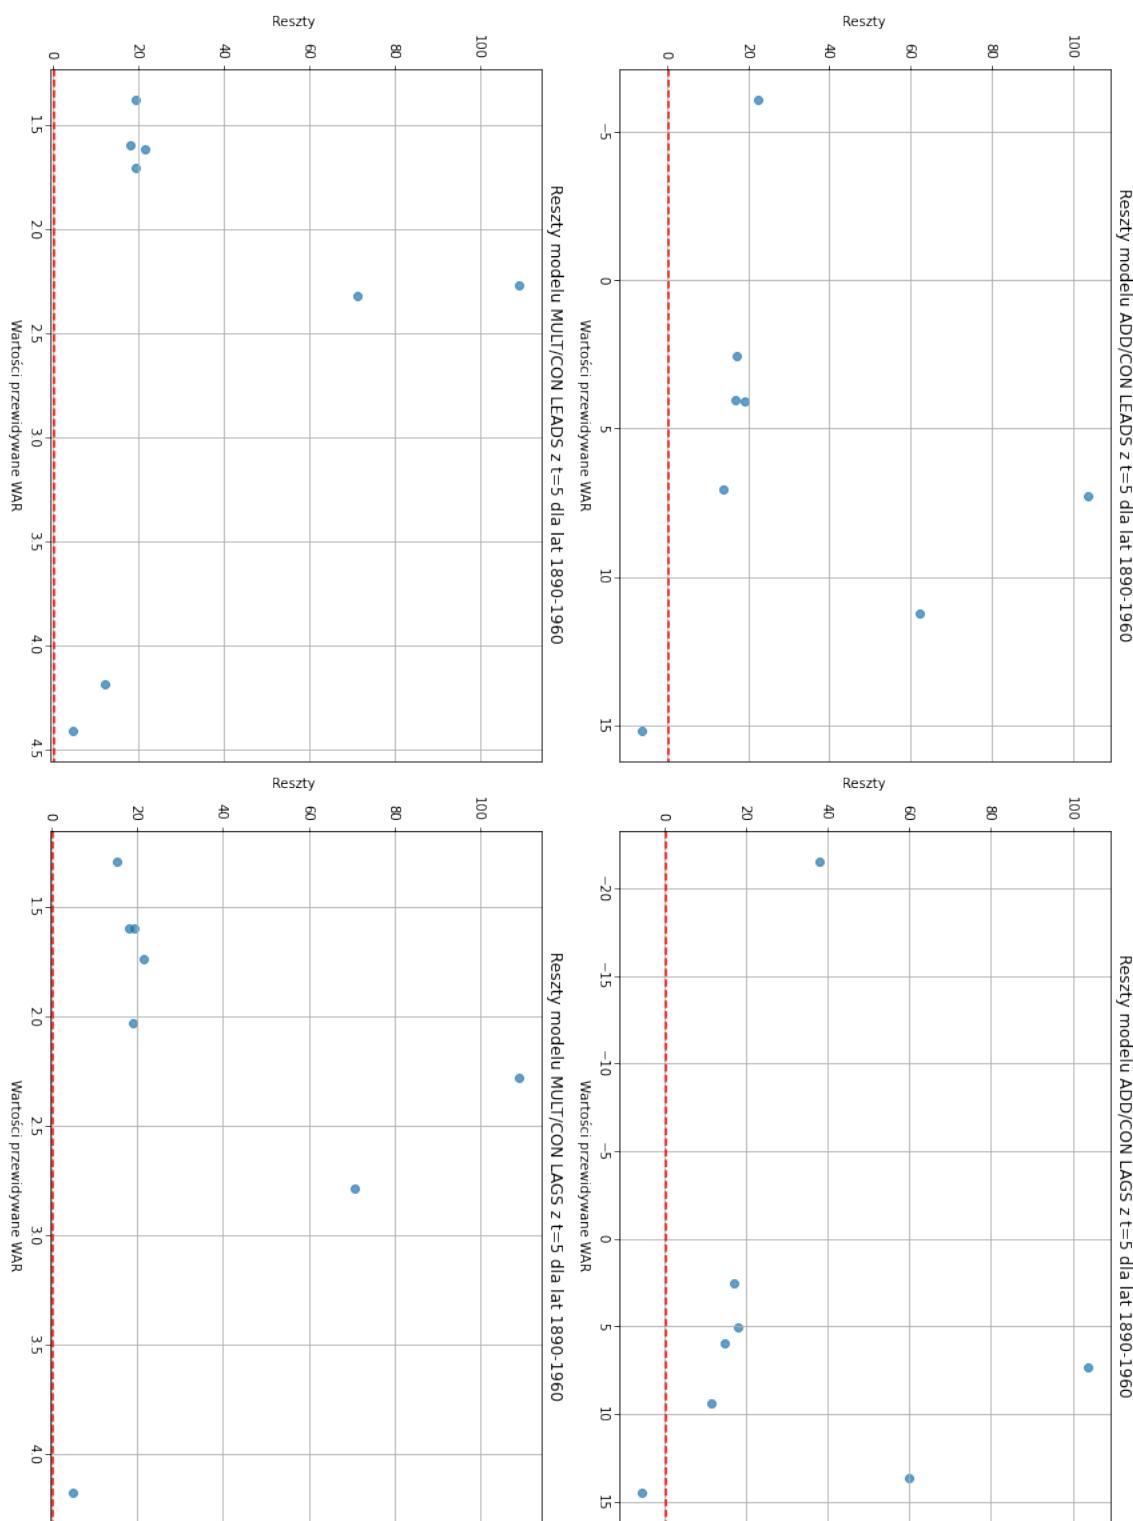
Modele MULT nadal wykazują bardzo wysokie wartości reszt, które są nieproporcjonalne w stosunku do rzeczywistych wartości WAR. Takie wyniki wskazują, że modele MULT są nieodpowiednie dla analizy tego okresu.

Analiza reszt i wyników testu Shapiro wskazuje, że modele ADD są znacznie bardziej stabilne i przewidywalne w porównaniu do modeli MULT, szczególnie dla okresu wieku 19.



Rysunek 2.29: Wykresy reszt dla $t = 5$ trenowanych na latach 1820 – 1890

Modele MULT generują nieproporcjonalnie wysokie wartości reszt, co czyni je nieadekwatnymi dla analizy konfliktów zbrojnych. Warto zauważyć, że modele ADD, mimo lepszego dopasowania, również wymagają dalszej optymalizacji, szczególnie dla okresu 1820 – 1960, gdzie normalność reszt nie została potwierdzona.



Rysunek 2.30: Wykresy reszt modeli dla $t = 5$ trenowanych na latach 1890 – 1960

Prognozy modeli z $t = 10$ opartych na danych historycznych z okresem 1820–1960 i jego podziałów

W analizie wyników prognoz modeli dla $t = 10$, zaprezentowane wykresy (Rysunki 2.31, 2.32, 2.33) przedstawiają prognozowane wartości zmiennej WAR dla modeli trenowanych

na okresach czasowych: 1820 – 1960, 1820 – 1890, oraz 1890 – 1960. W Tabeli 2.22 umieszczone są wyniki liczenia średnich błędów MAE oraz MSE.

Tabela 2.22: Średni błąd bezwzględny (MAE) oraz kwadratowy (MSE) dla modeli z $t = 10$ trenowanych na trzech okresach czasowych

Model	1820 – 1960		1820 – 1890		1890 – 1960	
	MAE	MSE	MAE	MSE	MAE	MSE
ADD/CON LEADS	23.27	961.85	79.95	9531.87	12.23	357.83
ADD/CON LAGS	20.79	877.34	82.20	10056.81	14.62	345.64
MULT/CON LEADS	20.22	844.94	862243.14	8177360507289.98	15.22	480.08
MULT/CON LAGS	21.04	870.39	5854299.55	376994773307771.75	13.90	408.58

Źródło: opracowanie własne

Przyjrzymy się szczegółowo wynikom dla różnych okresów.

Dla okresu 1820 – 1960 wyniki wskazują na stosunkowo dobre dopasowanie modeli ADD, szczególnie w przypadku modelu ADD/CON LEADS, gdzie przewidywane wartości stopniowo maleją, odzwierciedlając ogólny trend spadkowy rzeczywistych wartości. Niemniej jednak, różnice między przewidywaniami a rzeczywistością są nadal widoczne, co znajduje swoje odzwierciedlenie w relatywnie wysokich wartościach MSE i MAE. Modele MULT, zarówno LEADS, jak i LAGS, radzą sobie gorzej, co jest szczególnie widoczne w większych odchyleniach prognozowanych wartości od rzeczywistych.

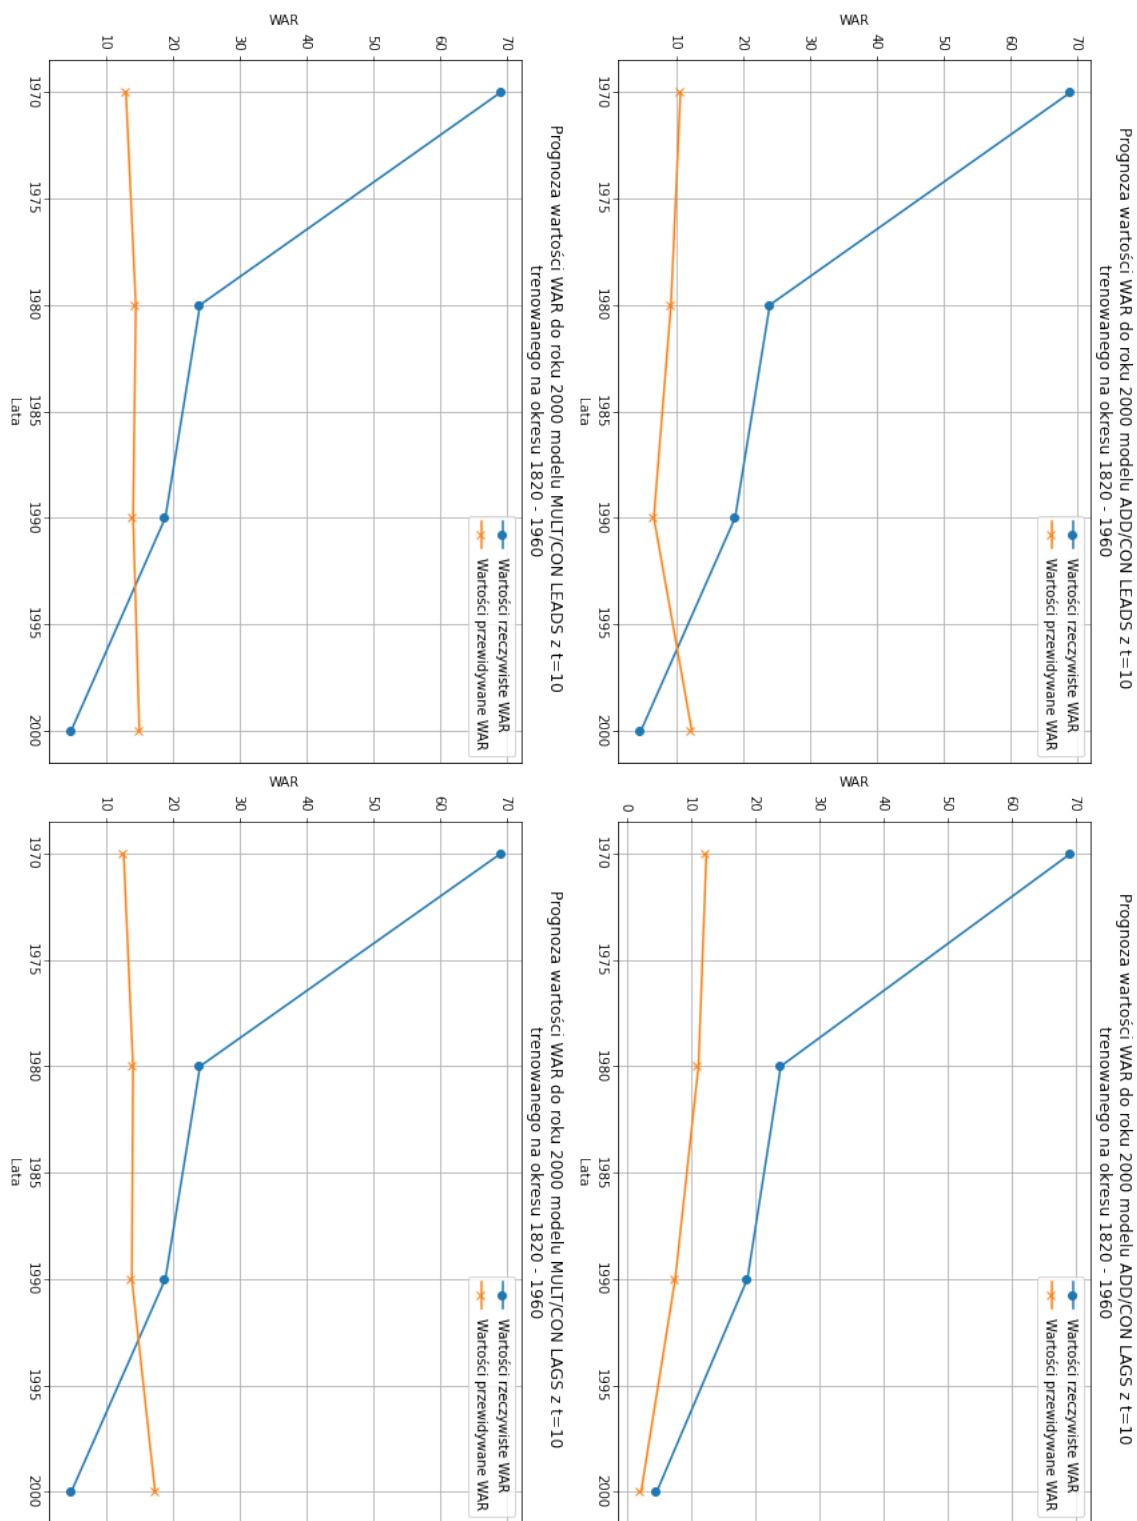
W okresie 1820 – 1890 modele MULT wykazują ekstremalne wartości przewidywane, które znaczco odbiegają od rzeczywistych danych. Na wykresach widoczne są prognozowane wartości rzędu milionów, co jest wynikiem nadmiernej wrażliwości tych modeli na zmienność danych treningowych. Ten wynik można wyjaśnić małą liczbą obserwacji w tym okresie, co ogranicza zdolność modelu do generalizacji. Taki problem często prowadzi do niestabilnych wyników w bardziej złożonych modelach, takich jak MULT. Ponadto, wartości MSE i MAE są ogromne, co dodatkowo wskazuje na nieadekwatność tych modeli w tym kontekście.

Dla okresu 1890 – 1960 modele ADD prezentują lepsze dopasowanie, a przewidywane wartości zmiennej WAR wykazują tendencję spadkową podobną do rzeczywistych danych. Niemniej jednak, wciąż występują odchylenia, szczególnie w modelu LAGS, co uwidacznia większe błędy dla tego wariantu. Modele MULT, choć mniej ekstremalne niż w przypadku okresu 1820 – 1890, nadal mają większe problemy z przewidywaniem, co potwierdzają podwyższone wartości MSE i MAE.

Ogólnie rzecz biorąc, wyniki analizy dla $t = 10$ pokazują, że modele ADD są bardziej stabilne i lepiej dopasowane w każdym analizowanym okresie. Modele MULT, szczególnie w okresie 1820 – 1890, nie nadają się do predykcji, co wynika z małej liczby obserwacji oraz większej złożoności tych modeli, która czyni je podatnymi na przetrenowanie. W kontekście badawczym wyniki te sugerują, że prostsze modele ADD są bardziej odpowiednie do analiz historycznych trendów w zmiennej WAR, szczególnie w przypadku ograniczonych danych.

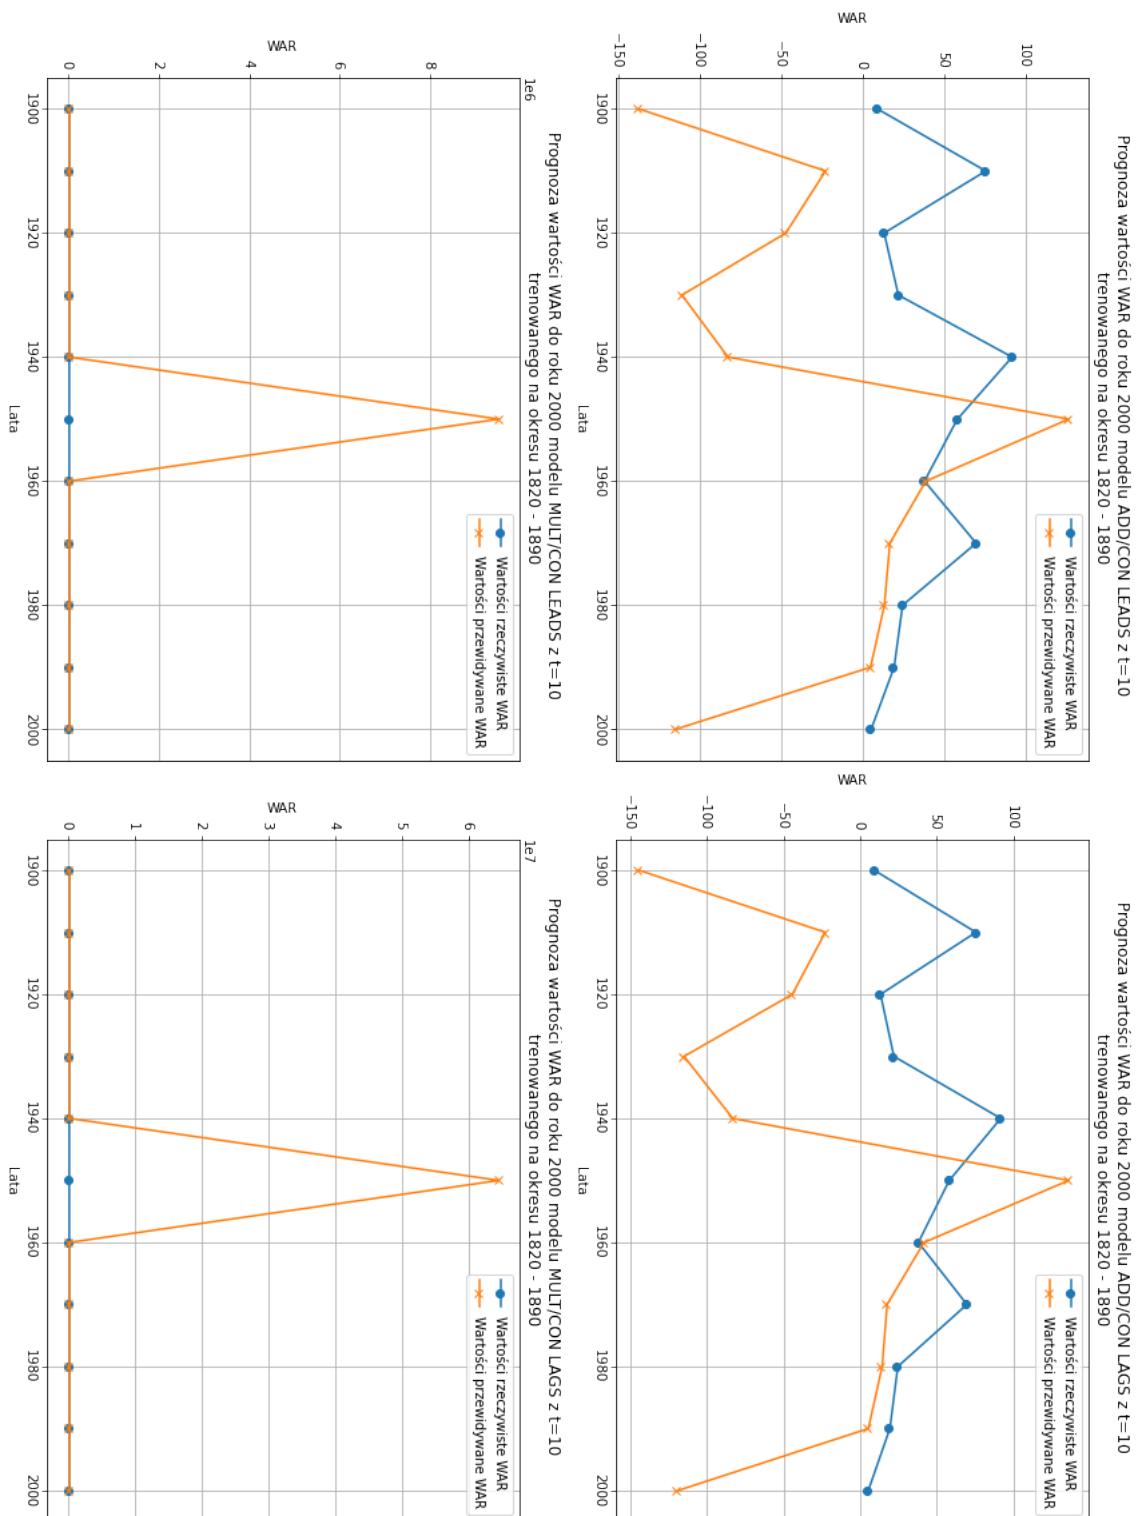
Analiza reszt

Wyniki analizy reszt dla modeli $t = 10$ zostały przedstawione na wykresach 2.34, 2.35, 2.36 i wskazują istotne różnice w jakości prognoz w zależności od okresu czasowego oraz

Rysunek 2.31: Prognoza modeli dla $t = 10$ trenowanych na latach 1820 – 1960

zastosowanego modelu. Przeanalizowano modele dla trzech okresów: 1820 – 1960, 1820 – 1890 oraz 1890 – 1960.

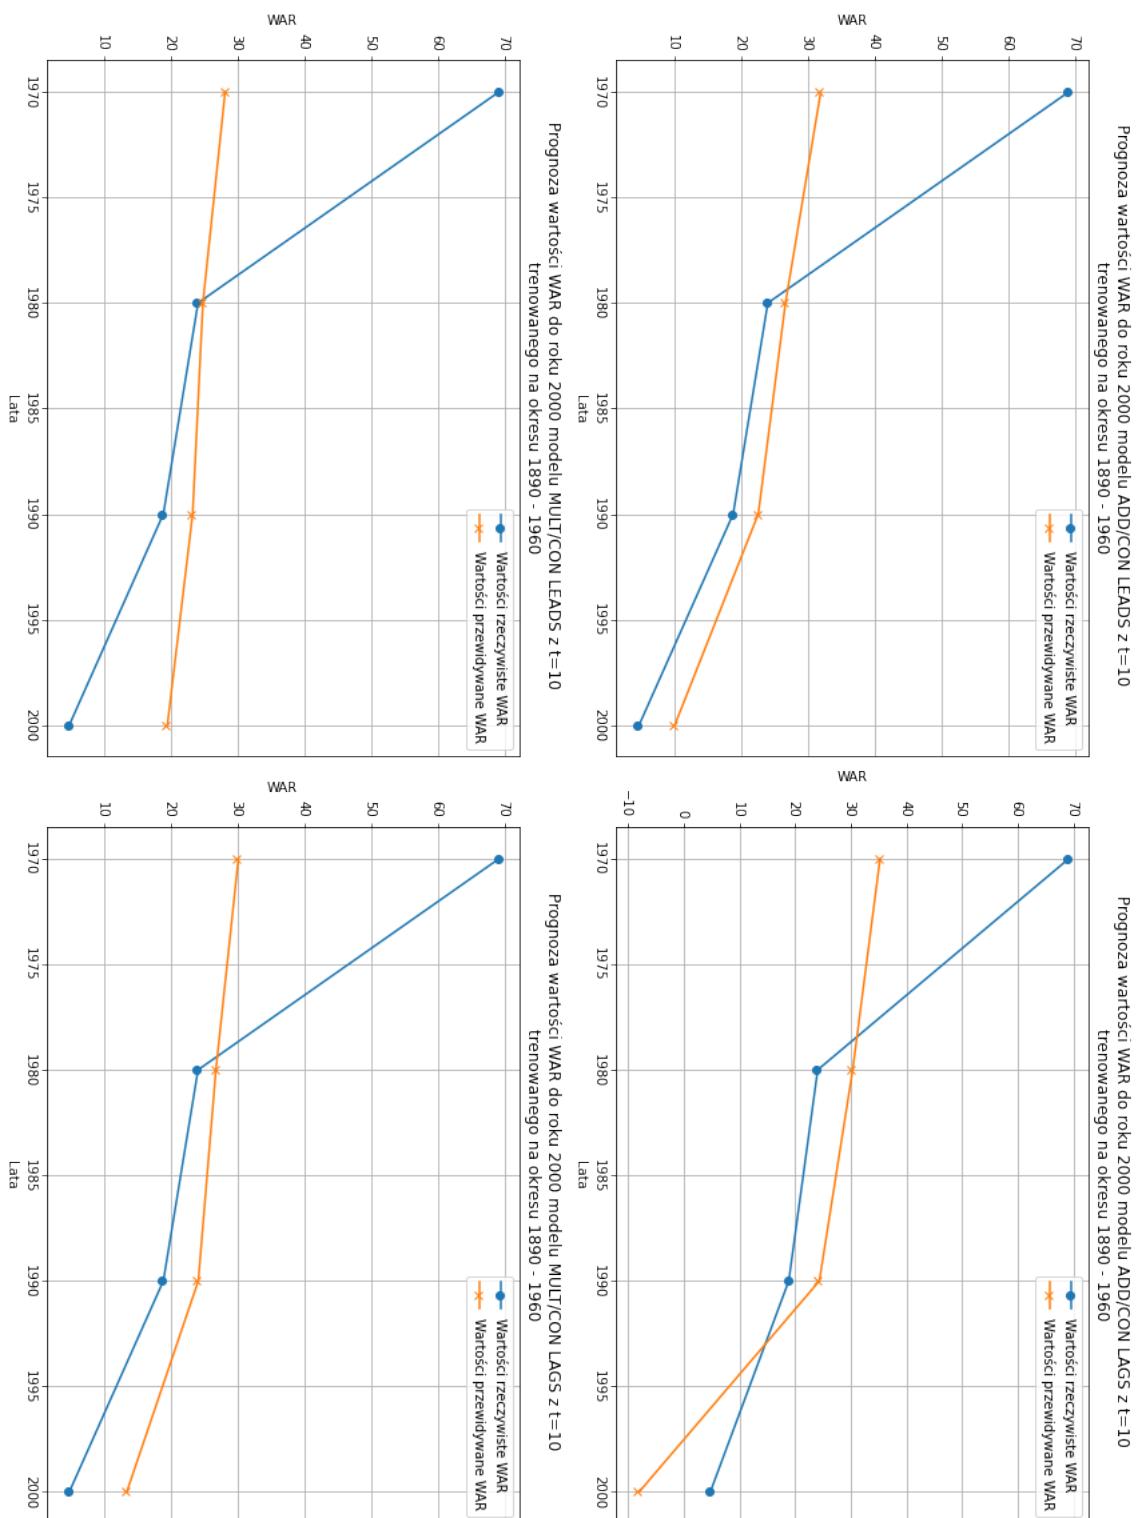
Modele trenowane na okresie 1820 – 1960 wykazują normalność reszt. W okresie 1820 – 1890, modele ADD/CON LEADS i ADD/CON LAGS uczone na wieku 19 mają normalne rozkłady reszt, podczas gdy pozostałe modele, w szczególności MULT, wykazują znaczne



Rysunek 2.32: Prognoza modeli dla $t = 10$ trenowanych na okresie 1820 – 1890

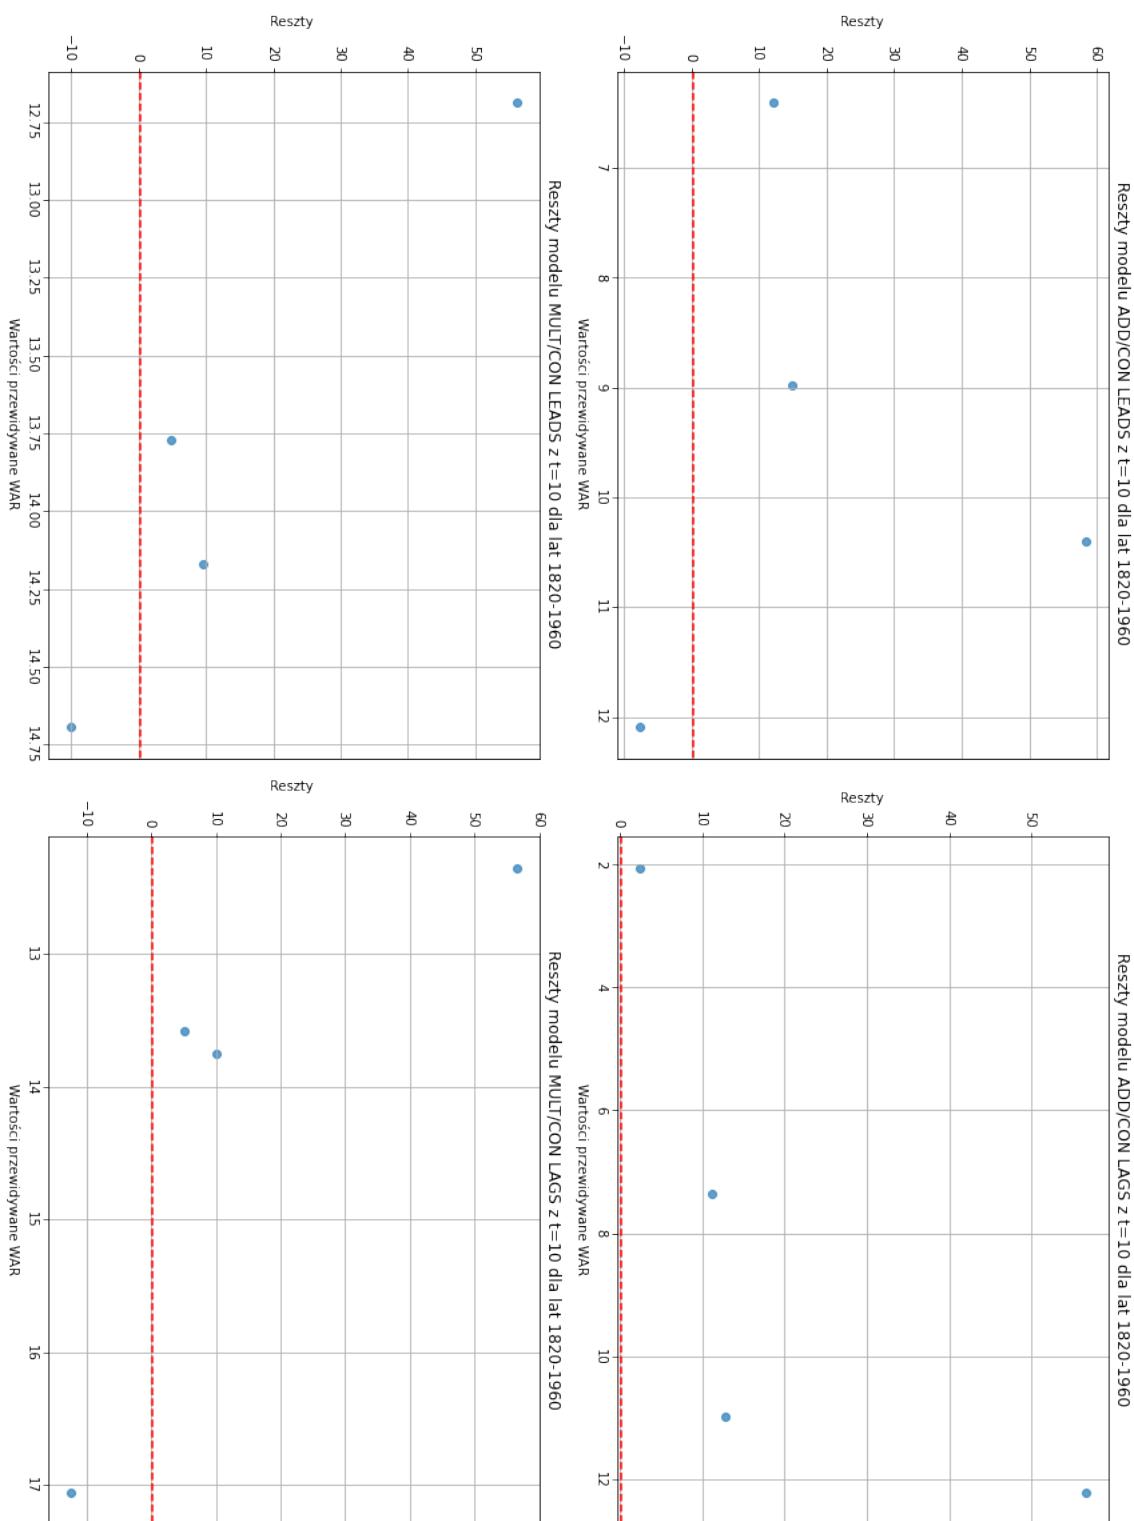
odchylenia od normalności. W okresie 1890 – 1960 modele ADD/CON LAGS i MULT/CON LEADS uczone na wieku 20 wykazują normalność reszt.

W modelach ADD trenowanych na okresie 1820 – 1960 wartości reszt oscylują wokół zera, co wskazuje na stosunkowo dobrą zgodność z rzeczywistymi danymi. Wartości przewidywane przez modele ADD są umiarkowanie dokładne, co potwierdzają niższe

Rysunek 2.33: Prognoza modeli dla $t = 10$ trenowanych na latach 1890 – 1960

wartości MAE i MSE w porównaniu do modeli MULT. Modele MULT charakteryzuja się większym rozrzutem reszt i przewidywaniami nieco oddalonymi od rzeczywistości. Jednakże dla tego okresu wszystkie modele spełniają kryteria normalności rozkładu reszt.

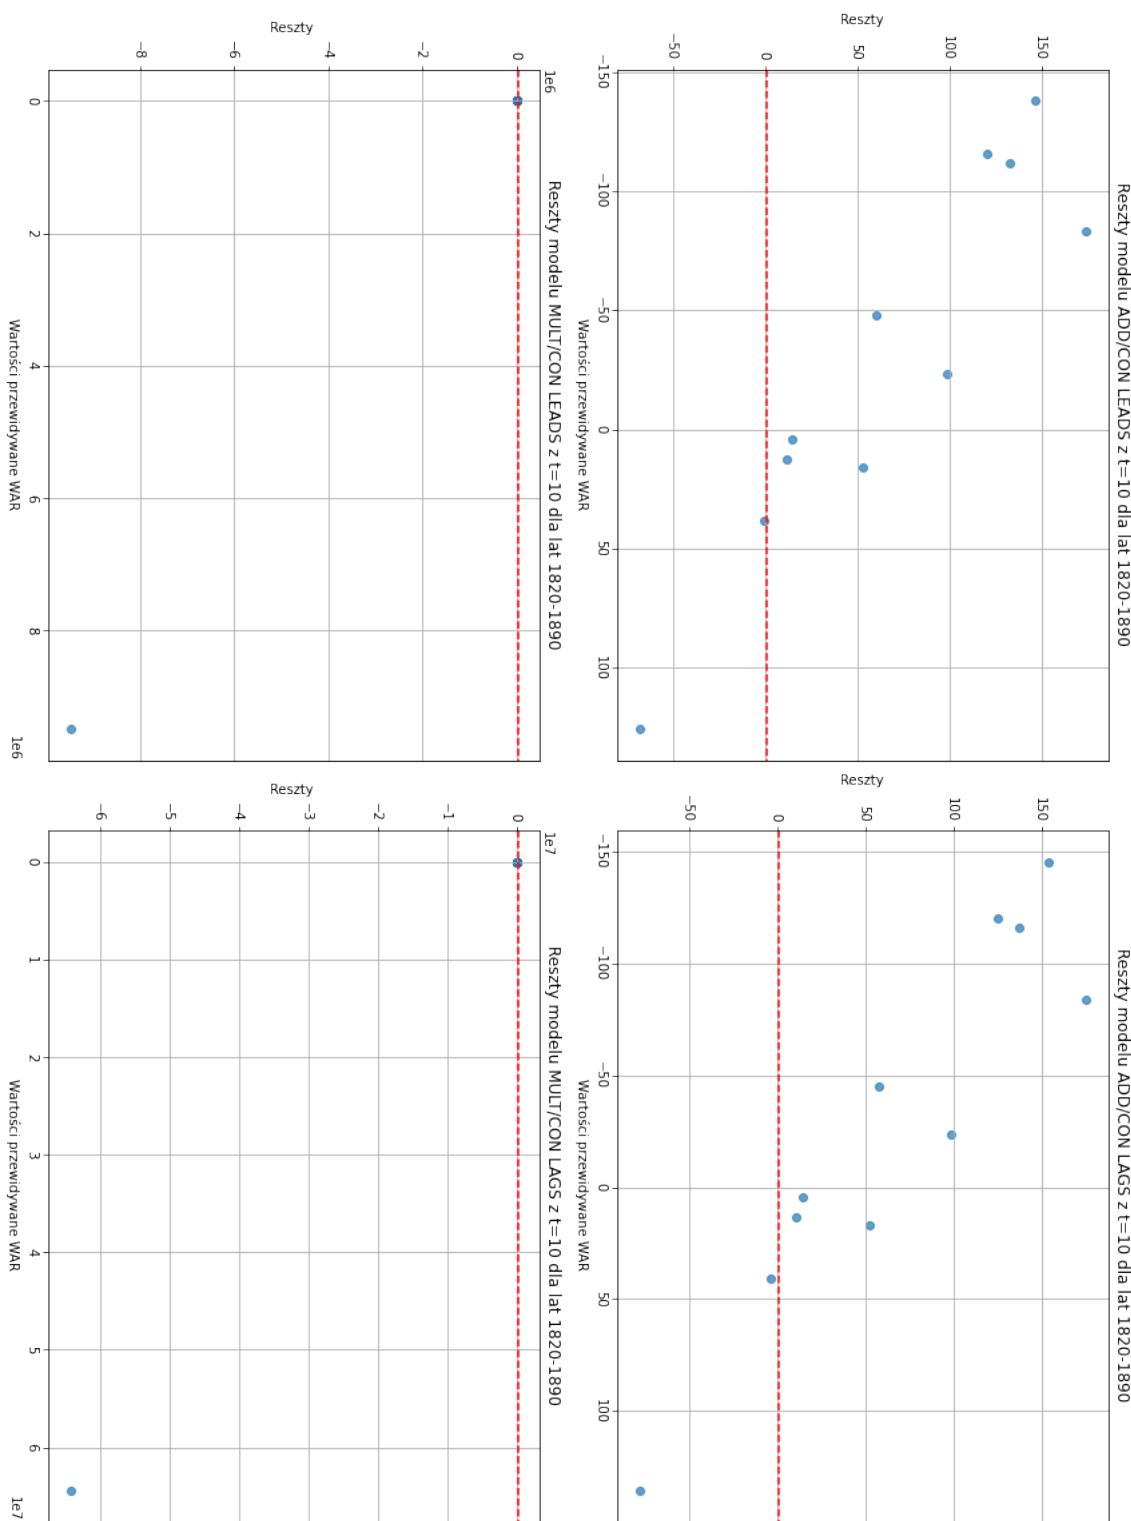
W tym okresie 1820 – 1890 wyraźnie widać, że modele ADD/CON LEADS i ADD/CON LAGS osiągają najlepsze wyniki pod względem zgodności prognoz z danymi rzeczywistymi.



Rysunek 2.34: Wykresy reszt dla $t = 10$ trenowanych na okresie 1820 – 1960

Modele MULT generują ekstremalnie wysokie wartości przewidywane, co prowadzi do bardzo dużych wartości reszt i obniżenia jakości prognoz.

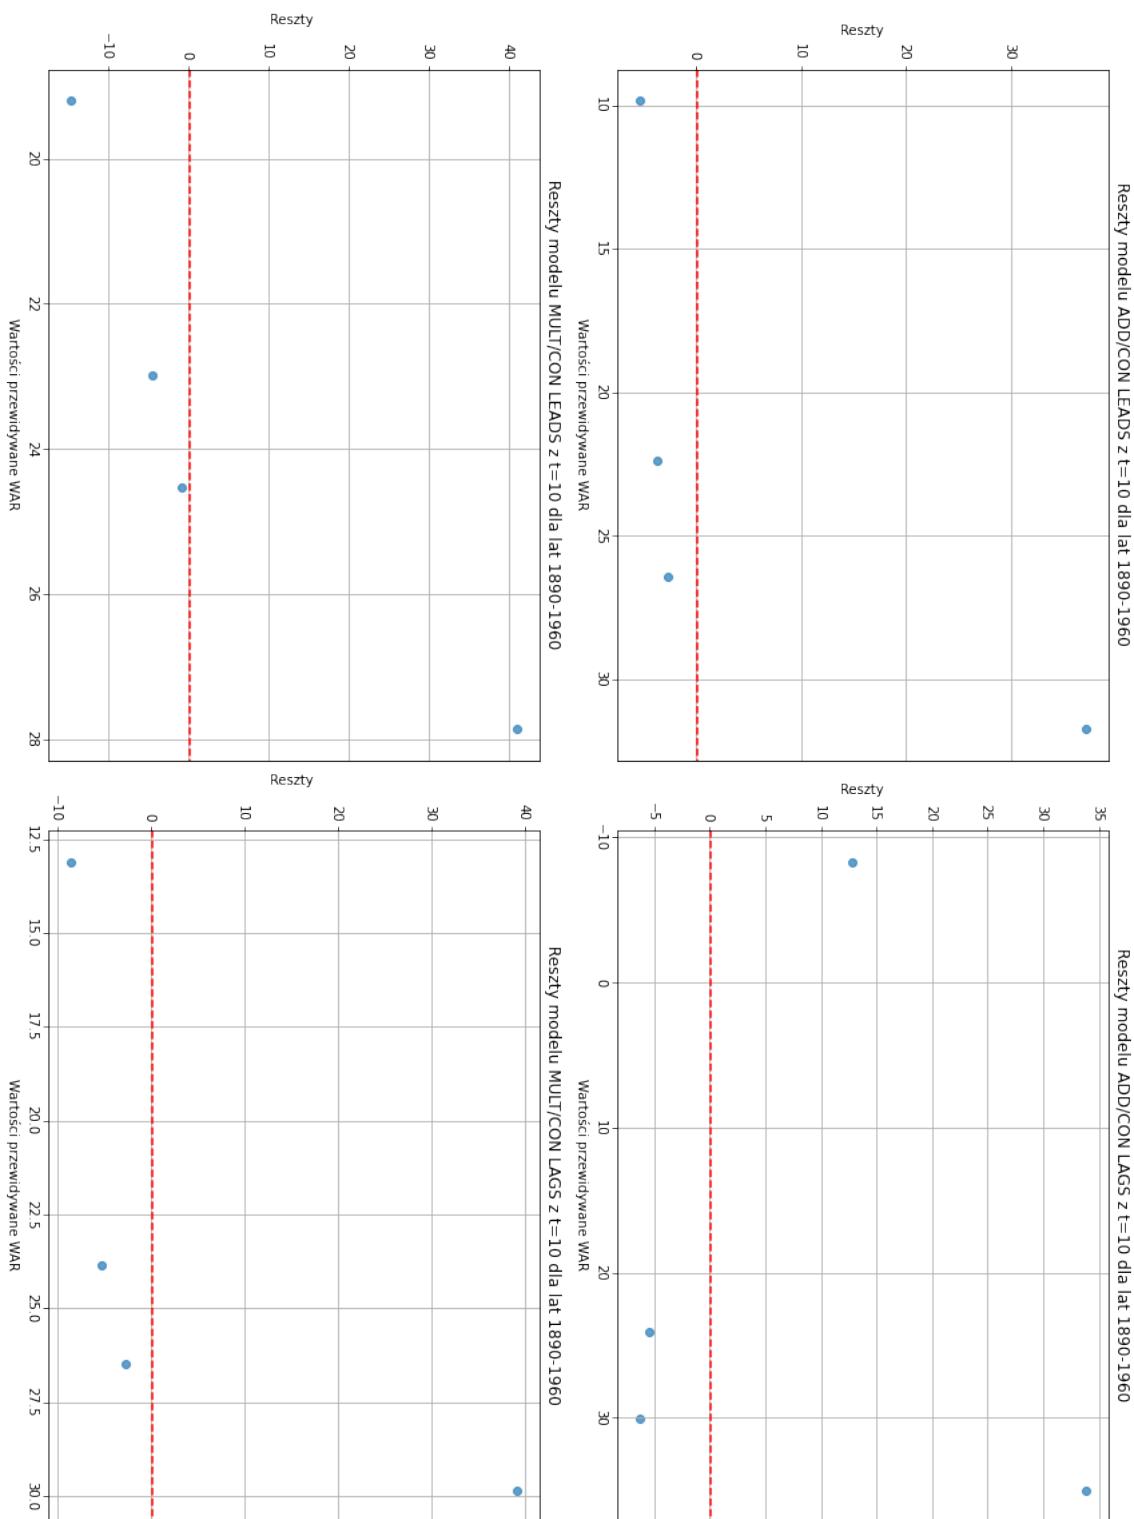
Modele ADD w okresie 1890–1960 nadal prezentują umiarkowanie dobre wyniki, z wartością reszt skoncentrowaną wokół zera. Modele MULT w dalszym ciągu wykazują większe odchylenia i generują wartości reszt wyraźnie różniące się od rzeczywistości. Wartości



Rysunek 2.35: Wykresy reszt dla $t = 10$ trenowanych na okresie 1820 – 1890

MSE i MAE dla modeli MULT są znacznie większe w porównaniu do modeli ADD, co jednoznacznie wskazuje na przewagę modeli ADD w tym okresie.

Należy zauważyć, że w modelach MULT przewidywania dla okresu 1820 – 1890 osiągają ekstremalnie wysokie wartości (rzędu milionów w niektórych przypadkach), co czyni te modele całkowicie nieużytecznymi w kontekście badawczym. Tak wysokie wartości



Rysunek 2.36: Wykresy reszt modeli dla $t = 10$ trenowanych na okresie 1890 – 1960

wynikają z faktu, że niewielka liczba obserwacji oraz specyfika danych w okresie 1820–1890 prowadzą do przeszacowania parametrów modeli MULT. W efekcie, modele MULT stają się niestabilne i niewiarygodne w prognozowaniu.

Analiza reszt dla $t = 10$ potwierdza, że modele ADD wykazują znacznie lepsze wyniki w porównaniu do modeli MULT, zarówno pod względem zgodności prognoz z danymi

rzeczywistymi, jak i stabilności wyników. Modele MULT, szczególnie w okresie 1820 – 1890, są narażone na niestabilności wynikające z małej liczby obserwacji, co prowadzi do generowania nieużytecznych prognoz. Wyniki te potwierdzają konieczność ostrożnego podejścia do modeli MULT w przypadku ograniczonych danych historycznych.

Prognozy modeli z $t = \{1, 5, 10\}$ opartych na danych historycznych z okresu 1950 – 2000

Ewaluacja modeli

Analiza ewaluacji modeli dla różnych wartości t obejmuje okres 1950 – 2000 i jest przedstawiona w Tabeli 2.23. W tabeli tej zaprezentowano oszacowania współczynników R , R^2 , \bar{R}^2 , a także wartości b i r^2 dla zmiennych zależnych CON , ΔCON oraz $MOVE$.

Tabela 2.23: Dopasowanie standaryzowanych modeli dla wszystkich t dla okresu 1950 – 2000

Model				CON		ΔCON		$MOVE$	
	R	R^2	\bar{R}^2	b	r^2	b	r^2	b	r^2
$t = 1$									
ADD/CON LEADS	0.441	0.194	0.142	-0.348	0.101	-0.420	0.153	-0.091	0.008
ADD/CON LAGS	0.441	0.194	0.142	-0.341	0.101	-0.290	0.090	-0.091	0.008
MULT/CON LEADS	0.414	0.171	0.117	-0.346	0.098	-0.382	0.127	-0.088	0.007
MULT/CON LAGS	0.414	0.171	0.117	-0.338	0.098	-0.253	0.068	-0.088	0.007
$t = 5$									
ADD/CON LEADS	0.462	0.213	-0.180	0.136	0.016	-0.125	0.010	-0.477	0.157
ADD/CON LAGS	0.462	0.213	-0.180	0.127	0.016	-0.233	0.046	-0.477	0.157
MULT/CON LEADS	0.786	0.618	0.426	0.336	0.169	-0.379	0.157	-0.736	0.477
MULT/CON LAGS	0.786	0.618	0.426	0.313	0.169	-0.646	0.435	-0.736	0.477
$t = 10$									
ADD/CON LEADS	0.999	0.998	0.993	-2.266	0.997	-2.718	0.996	-2.155	0.997
ADD/CON LAGS	0.999	0.998	0.993	-1.677	0.997	-0.093	0.687	-2.155	0.997
MULT/CON LEADS	1.000	1.000	1.000	-1.293	1.000	-1.133	1.000	-1.381	1.000
MULT/CON LAGS	1.000	1.000	1.000	-0.957	1.000	0.365	1.000	-1.381	1.000

Źródło: opracowanie własne

Dla $t = 1$ najlepsze wyniki osiąga model ADD/CON LEADS, dla którego $R^2 = 0.194$, a $\bar{R}^2 = 0.142$. Wszystkie predyktory w tym modelu wykazują ujemne wartości współczynników względem zmiennej WAR . Jest to wynik nietypowy, porównując z poprzednimi analizami, wskazuje to na ogólną tendencję zmniejszenia prawdopodobieństwa konfliktu przy wzroście analizowanych zmiennych, co może wynikać z dynamiki okresu powojennego i roli równowagi sił w systemie międzynarodowym. Wartość ΔCON ma największy wpływ w modelach LEADS ($b = -0.420$, $r^2 = 0.153$), natomiast CON odgrywa kluczową rolę w modelach LAGS ($b = -0.341$, $r^2 = 0.101$). Zmienna $MOVE$ wykazuje znikomy wpływ, co sugeruje jej ograniczoną istotność w prognozach mniejszymi podziałami t .

Dla $t = 5$ model MULT/CON LEADS charakteryzuje się znacznym wzrostem dopasowania, gdzie $R^2 = 0.618$, a $\bar{R}^2 = 0.426$. Największy wpływ na wynik modelu ma zmienna $MOVE$, której współczynnik $b = -0.736$, a $r^2 = 0.477$. Negatywna wartość współczynnika $MOVE$ w tym przypadku jest zaskakująca i może wskazywać na specyficzną rolę

ruchu mocy w generowaniu napięć w okresie zimnej wojny. Zmienna ΔCON w modelu MULT/CON LAGS również osiąga wysoki poziom dopasowania ($r^2 = 0.435$).

Wyniki dla $t = 10$ wskazują na wybitne dopasowanie modeli, osiągające niemal perfekcyjne wartości $R^2 = 0.998$ oraz $\bar{R}^2 = 0.993$ dla modelu ADD/CON LEADS, a także $R^2 = 1.000$ dla modeli MULT. Predyktory w tych modelach mają współczynniki b o wartościach ujemnych, co może wynikać z systematycznego oddziaływania zmiennych w długim okresie t . Wyjątkiem jest ΔCON w modelu ADD/CON LAGS, gdzie $r^2 = 0.687$, co wskazuje na możliwe różnice w dynamice zmiennych w długoterminowym modelowaniu.

Porównując wyniki dla różnych wartości t , widać wyraźny wzrost zdolności predykcyjnej modeli w miarę wydłużania okresu analizy t . Wyniki dla $t = 10$ przewidują niemal 100% zmienności, co wskazuje na stabilność długoterminowych relacji w systemie międzynarodowym. Ujemne wartości współczynników sugerują, że zmienne te mogą być wskaźnikami adaptacji lub mechanizmów równoważących w systemie międzynarodowym, które zmniejszają prawdopodobieństwo konfliktu.

Rezultaty podkreślają znaczenie koncepcjalizacji modeli w analizie międzynarodowych relacji oraz potrzebę uwzględnienia zarówno krótkich, jak i dłuższych podziałów liczenia zmiennych w celu lepszego zrozumienia mechanizmów w systemie.

Dopasowanie modeli

Analiza modeli dla różnych wartości t ($t = 1$, $t = 5$, $t = 10$) w okresie 1950 – 2000 została przeprowadzona na podstawie średnich błędów bezwzględnych (MAE), błędów kwadratowych (MSE) (Tabela 2.24) oraz wykresów porównujących rzeczywiste wartości zmiennej WAR z wartościami przewidywanymi przez modele (Rysunki 2.37, 2.38, 2.39).

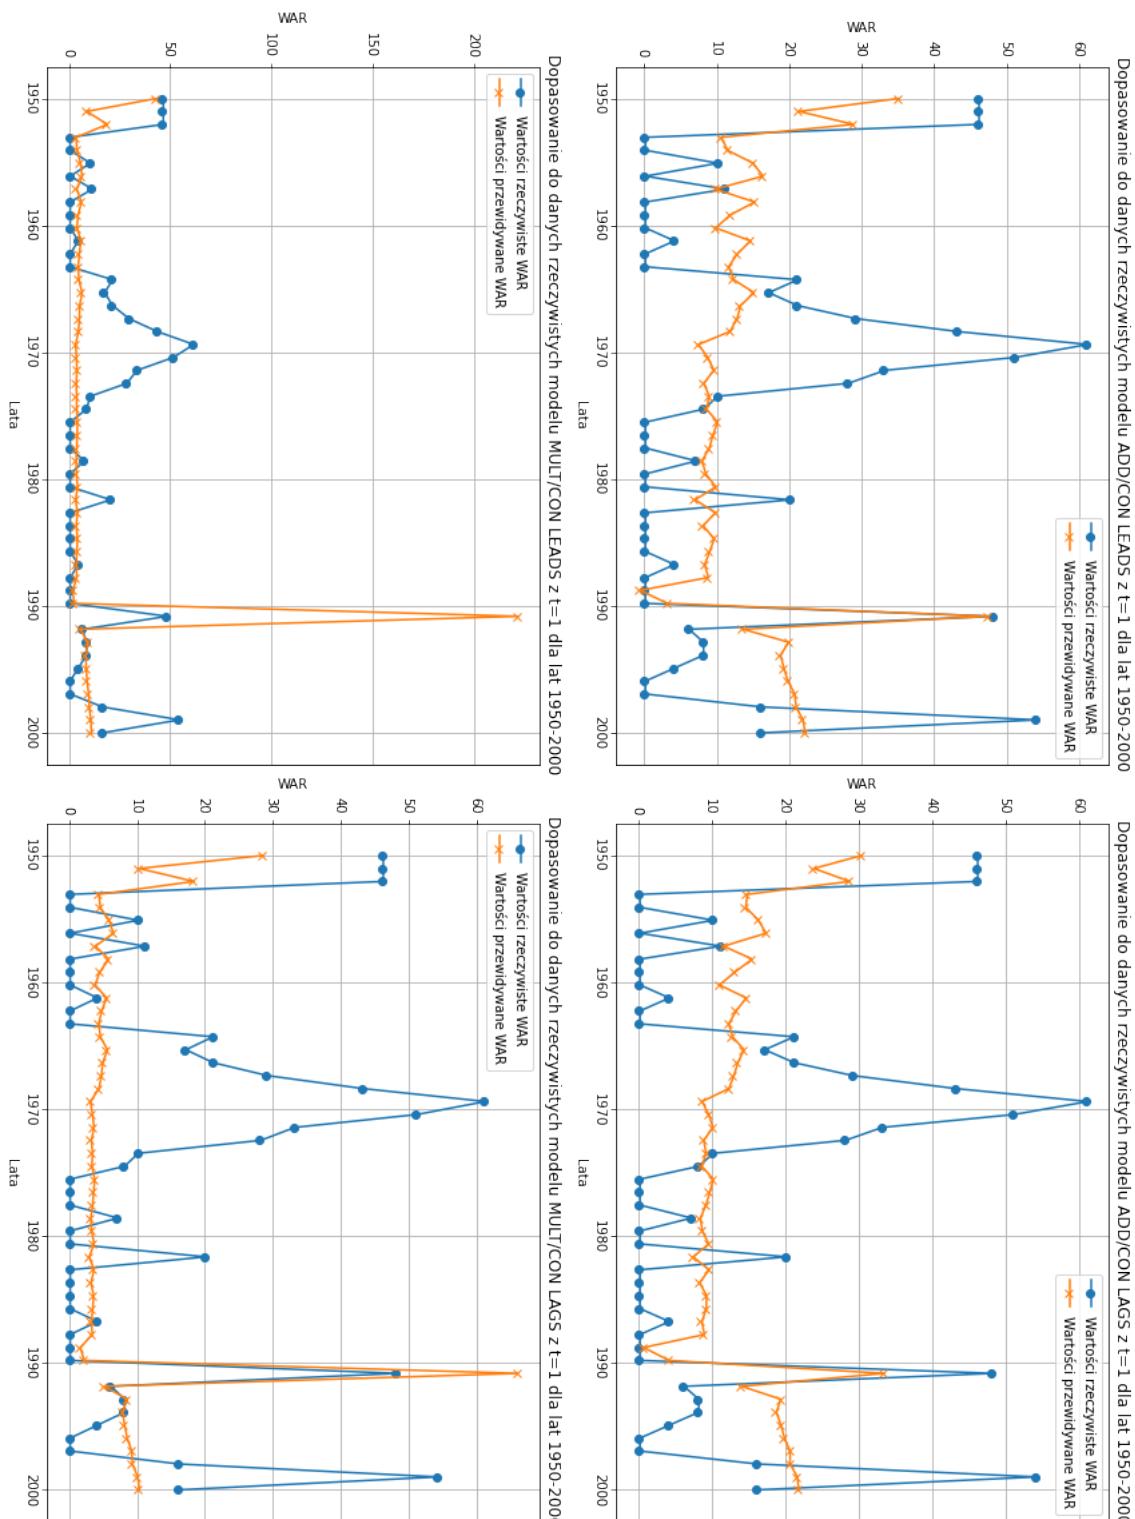
Tabela 2.24: Średni błąd bezwzględny (MAE) oraz kwadratowy (MSE) dla modeli z różnymi t

Model	$t = 1$		$t = 5$		$t = 10$	
	MAE	MSE	MAE	MSE	MAE	MSE
ADD/CON LEADS	12.35	258.53	22.24	853.05	0.64	0.81
ADD/CON LAGS	12.86	263.94	22.96	865.72	44.37	3287.96
MULT/CON LEADS	14.17	902.26	22.58	1115.23	23.86	847.65
MULT/CON LAGS	11.35	310.77	21.71	1116.90	0.05	0.00

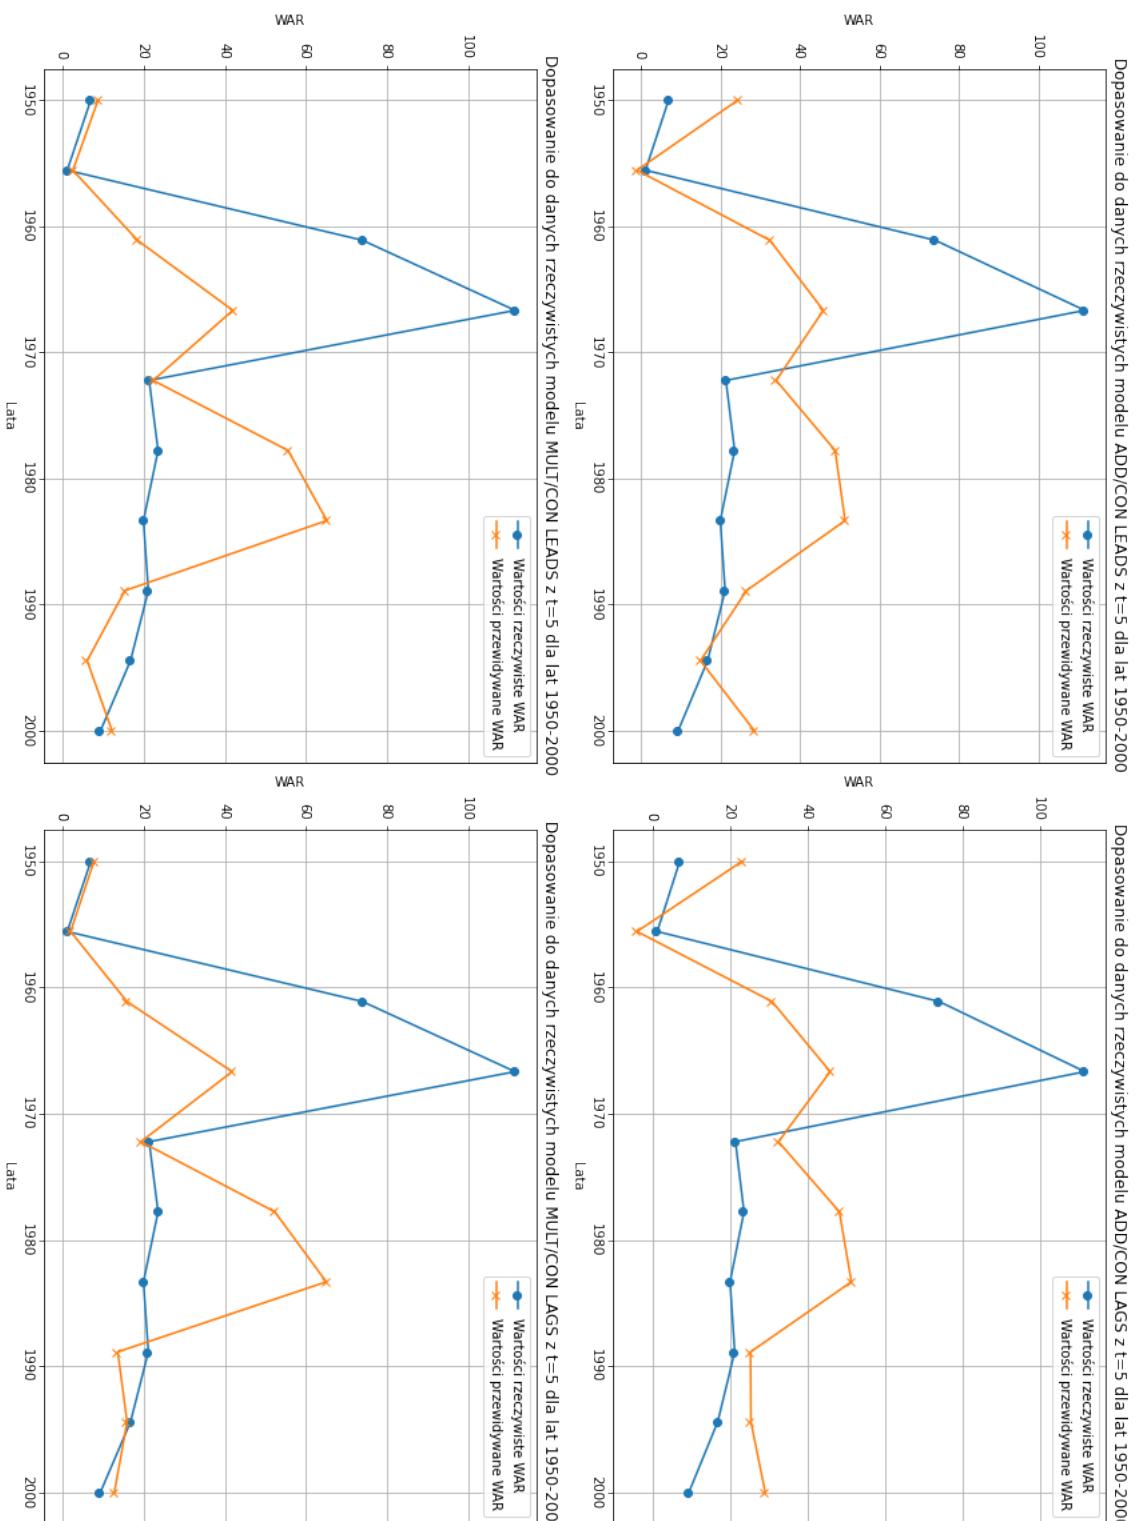
Źródło: opracowanie własne

W przypadku $t = 1$, modele wykazują stosunkowo niskie błędy, co jednak nie przekłada się na wysoką jakość przewidywań. Model MULT/CON LAGS osiągnął najniższe wartości błędów ($MAE = 11.35$, $MSE = 310.77$), wskazując na jego relatywnie lepszą zdolność do prognozowania. Modele ADD mają podobne wyniki ($MAE \approx 12.35\text{--}12.86$), ale ich MSE są wyższe, co sugeruje większe rozbieżności między rzeczywistymi i przewidywanymi wartościami w niektórych punktach. MULT/CON LEADS uzyskał najwyższy błąd ($MSE = 902.26$), co jest wynikiem przeszacowania wartości zmiennej WAR w kluczowych latach, takich jak lata 1970.

Wykresy pokazują, że modele mają trudności z uchwyceniem zmienności rzeczywistych wartości WAR . Modele ADD w większości lat zbliżają się do rzeczywistych wartości, jednak zauważalne są rozbieżności w okresach dużych wahania, takich jak lata 1970 czy

Rysunek 2.37: Dopasowanie modeli dla $t = 1$ dla lat 1950 – 2000

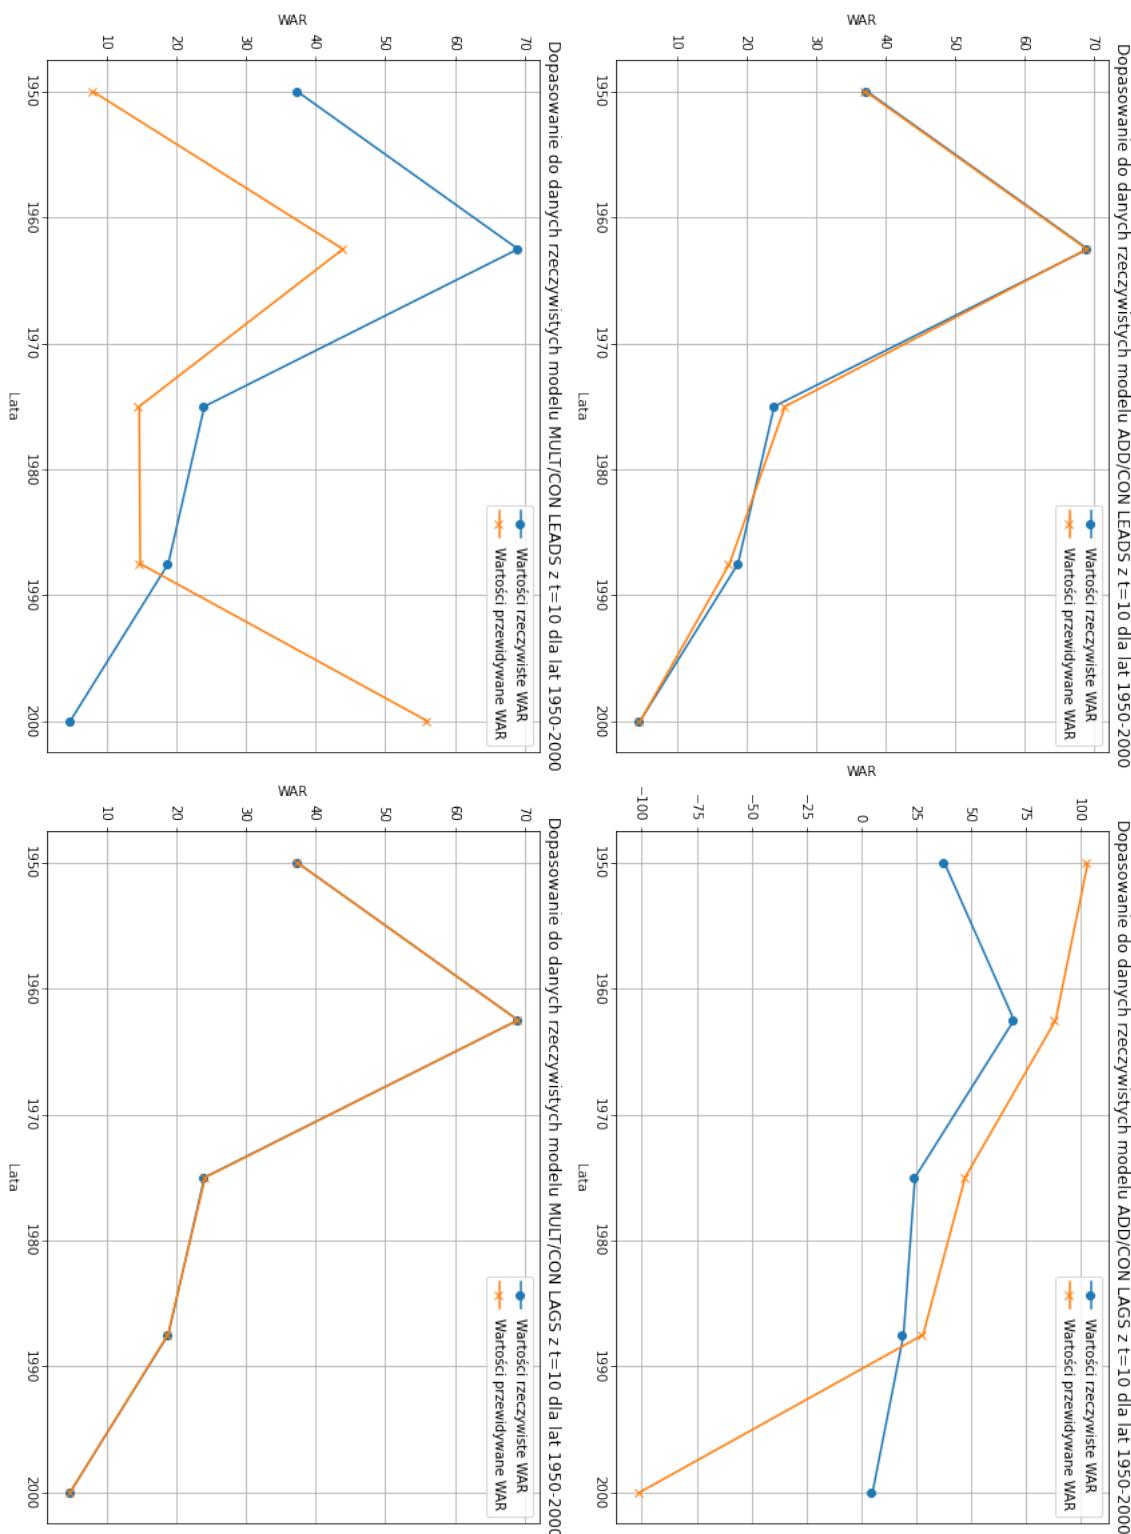
1980. Z kolei modele MULT, szczególnie MULT/CON LEADS, znaczaco przeszacowuja wartosci WAR w kluczowych latach, co prowadzi do wysokiego bledu MSE. MULT/CON LAGS wypada nieco lepiej, ale nadal nie oddaje pełni zmienności danych. Wykresy dla $t = 1$ wskazują na trudnośc modeli w uchwyceniu dużych wań rzeczywistych wartości zmiennej WAR . Modele są w stanie przewiduyać ogólne trendy, ale mają problemy z dy-



Rysunek 2.38: Dopasowanie modeli dla $t = 5$ dla lat 1950 – 2000

namicznymi zmianami charakterystycznymi dla krótkoterminowych wydarzeń w systemie międzynarodowym.

Dla $t = 5$ błędy modeli są wyraźnie wyższe w porównaniu do $t = 1$, ale przewidywania stają się bardziej stabilne. MULT/CON LAGS ponownie wykazuje najniższe wartości błędów ($MAE = 21.71$, $MSE = 1116.90$), co świadczy o jego zdolności do lepszego

Rysunek 2.39: Dopasowanie modeli dla $t = 10$ dla lat 1950 – 2000

odwzorowania rzeczywistych wartości zmiennej WAR w średnim okresie. Modele ADD osiągają podobne wyniki ($MAE \approx 22.24\text{--}22.96$), ale ich wartości MSE są wyższe, co sugeruje mniej precyzyjne dopasowanie w latach o dużych zmianach. MULT/CON LEADS uzyskuje najwyższy błąd kwadratowy ($MSE = 1115.23$), co wskazuje na jego ograniczoną skuteczność w przewidywaniu dynamicznych zmian.

Na wykresach modele wykazują poprawę w odwzorowywaniu ogólnych trendów, ale nadal mają trudności z precyzyjnym odtworzeniem rzeczywistych wartości w latach o dużej zmienności. Modele ADD lepiej radzą sobie z przewidywaniem wartości w spokojniejszych okresach, jednak ich dopasowanie jest słabsze w momentach skrajnych wartości, takich jak lata 1960 czy 1970. MULT pokazują wyraźnie lepsze odwzorowanie rzeczywistych trendów, przy czym MULT/CON LAGS osiąga większą stabilność i dokładność w kluczowych latach.

Dla $t = 10$ modele wykazują największą precyzję w przewidywaniu wartości zmiennej WAR . MULT/CON LAGS osiąga niemal idealne dopasowanie ($MAE = 0.05$, $MSE = 0.00$), co oznacza, że model ten perfekcyjnie odwzorowuje rzeczywiste wartości zmiennej. Podobnie ADD/CON LEADS wykazuje bardzo niskie błędy ($MAE = 0.64$, $MSE = 0.81$), co świadczy o jego skuteczności w prognozowaniu w długim okresie. Z kolei ADD/CON LAGS osiąga wysokie wartości błędów ($MAE = 44.37$, $MSE = 3287.96$), co wskazuje na problemy w dopasowaniu długoterminowym.

Na wykresach dopasowania dla $t = 10$ widać, że modele MULT/CON LAGS i ADD/CON LEADS niemal idealnie odwzorowują rzeczywiste wartości zmiennej WAR . Stabilność tych modeli może wynikać z ich zdolności do uwzględniania powtarzalnych wzorców i zależności systemowych w relacjach międzynarodowych. Podczas gdy ADD/CON LAGS i MULT/CON LEADS pokazują wyraźne rozbieżności w końcowym okresie analizy, chociaż ogólnie też wykrywają trendy.

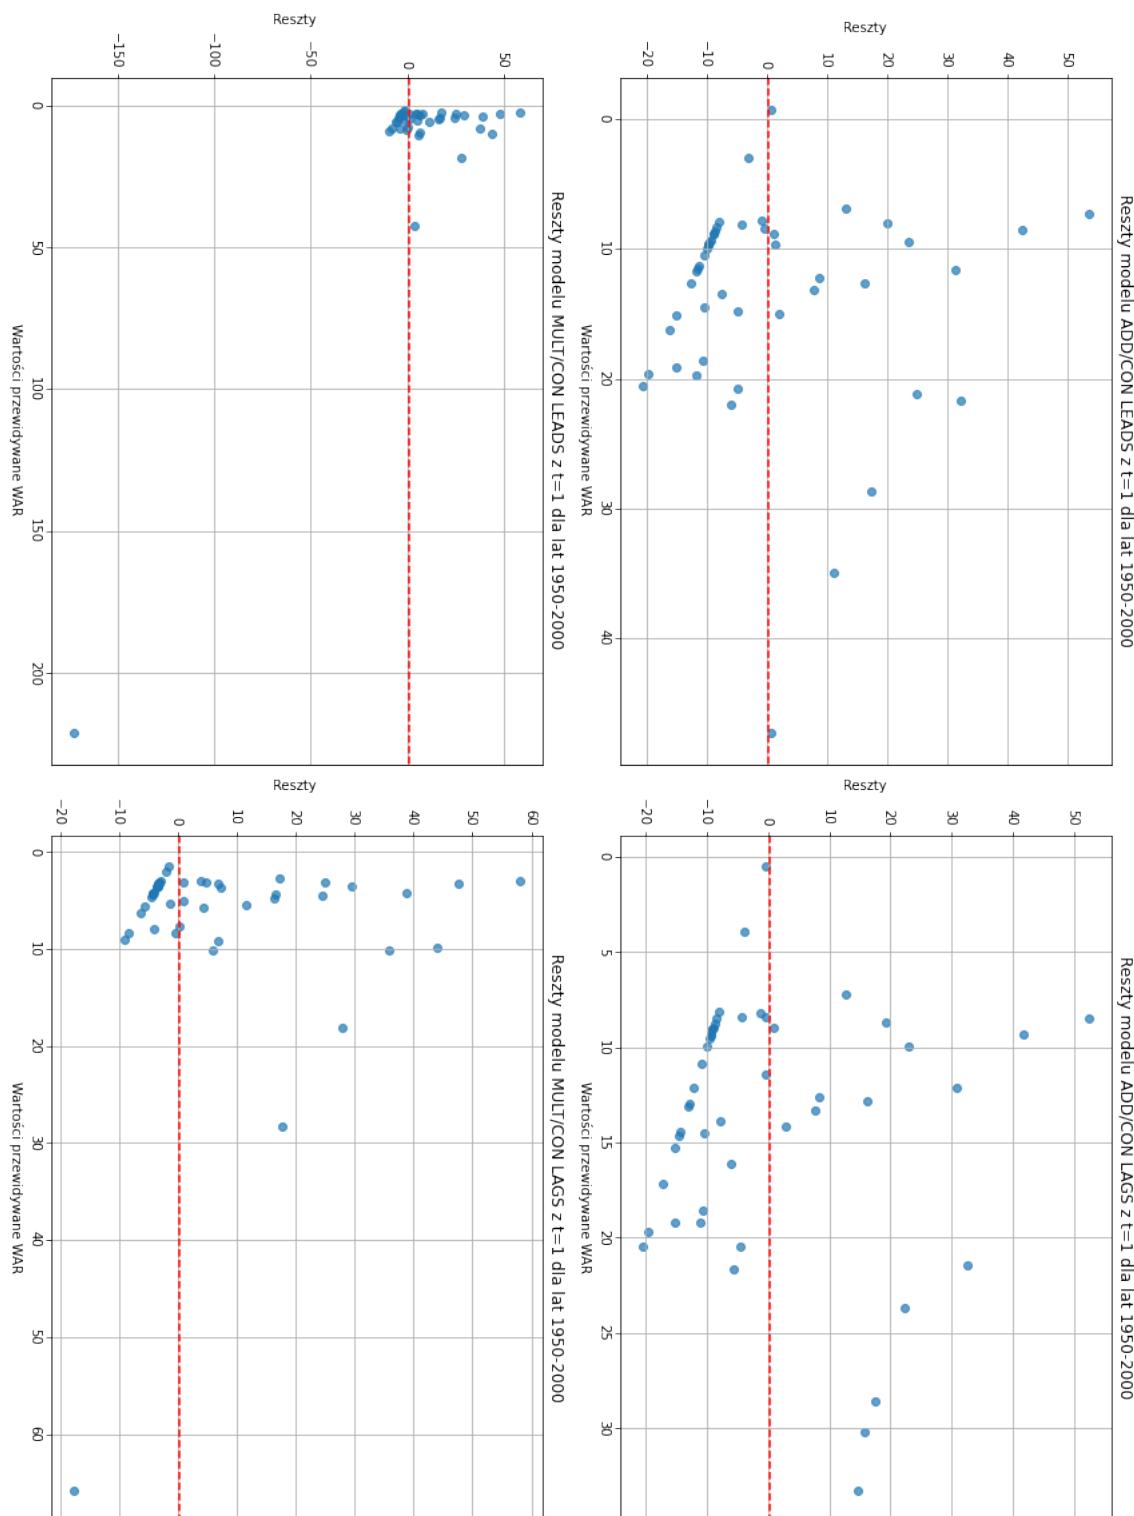
Porównanie wykresów dla różnych wartości t pokazuje, że zdolność modeli do odwzorowywania rzeczywistych wartości zmiennej WAR poprawia się wraz z wydłużaniem okresu t . Dla $t = 1$ modele mają trudności z uchwyceniem dynamicznych zmian i dużych wahań, co prowadzi do większych rozbieżności między wartościami rzeczywistymi i przewidywanymi. Dla $t = 5$ widoczna jest poprawa w uchwyceniu ogólnych trendów, jednak modele nadal mają problemy z dokładnością w kluczowych latach. Dla $t = 10$ modele wskazują na ich zdolność do integracji długoterminowych zależności.

Analiza reszt

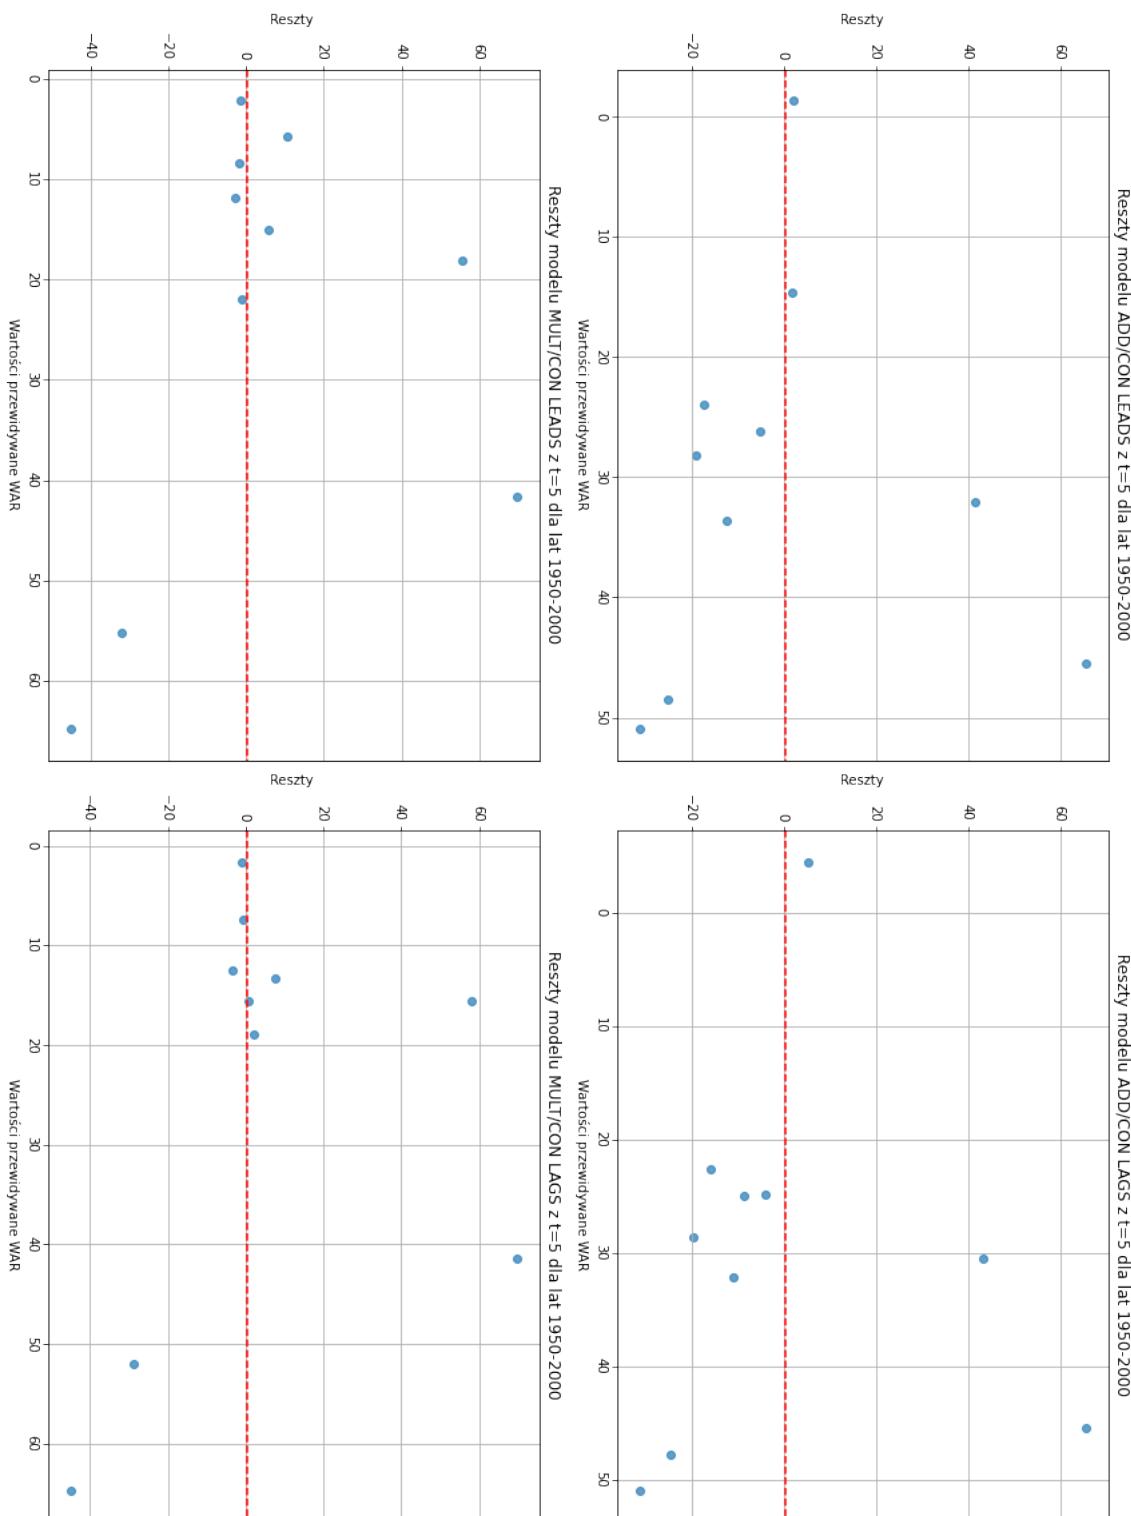
Analiza reszt modeli dla różnych wartości t pozwala na ocenę jakości dopasowania oraz identyfikację potencjalnych błędów systematycznych. Wykresy reszt pokazują różnice między rzeczywistymi a przewidywanymi wartościami zmiennej WAR , co umożliwia ocenę rozkładu błędów predykcji (Rysunki 2.40, 2.41, 2.42). Ponadto testy Shapiro-Wilka zostały przeprowadzone w celu sprawdzenia normalności rozkładu reszt.

W przypadku $t = 1$ reszty dla modeli ADD wykazują duże rozproszenie i brak wyraźnej symetrii wokół osi 0. W szczególności modele te mają tendencję do generowania zarówno wysokich wartości dodatnich, jak i ujemnych reszt w latach o ekstremalnych wartościach zmiennej WAR . Dla modeli MULT widoczne są jeszcze większe rozbieżności, zwłaszcza dla MULT/CON LEADS, gdzie reszty osiągają wartości przekraczające -150 , co wskazuje na silne przeszacowanie w niektórych przypadkach. Warto zauważyć, że test Shapiro-Wilka nie potwierdził normalności rozkładu reszt dla żadnego z modeli przy $t = 1$, co wskazuje na systematyczne odchylenia w predykcjach.

Dla $t = 5$ modele MULT pokazują znaczącą poprawę w rozkładzie reszt. Reszty dla tych modeli są bardziej skoncentrowane wokół osi 0, co sugeruje mniejsze błędy systematyczne. Test Shapiro-Wilka wykazał, że rozkład reszt w modelach MULT/CON jest normalny, co potwierdza ich lepsze dopasowanie w średnim horyzoncie czasowym. W przeciwieństwie do tego, modele ADD nadal pokazują duże odchylenia, a reszty są bardziej rozproszone, szczególnie w latach o dużych wartościach zmiennej WAR . Brak normalności rozkładu reszt w tych modelach sugeruje, że nie są one wystarczająco dobrze dopasowane do danych.

Rysunek 2.40: Wykresy reszt dla $t = 1$ na okresie 1950 – 2000

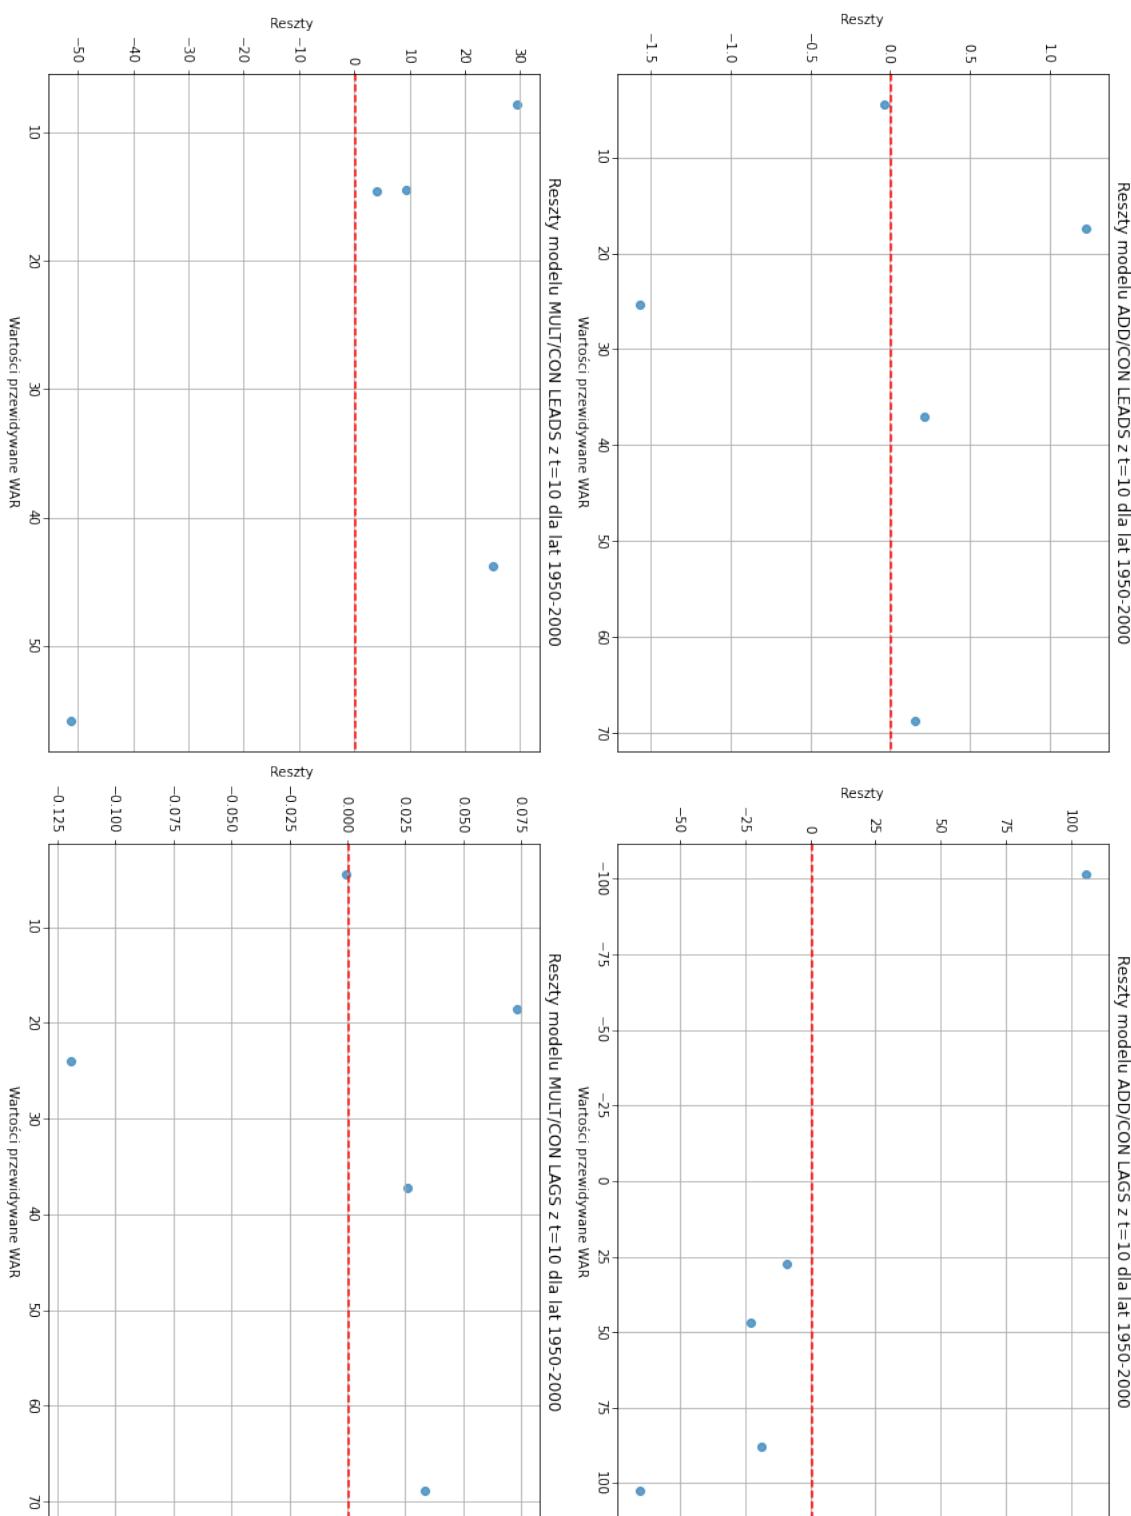
Dla $t = 10$ wykresy reszt pokazują niemal idealne dopasowanie dla modeli MULT. Reszty są bliskie 0 i dobrze rozmiędziane wzdłuż osi przewidywanych wartości WAR , co wskazuje na brak systematycznych błędów. Modele ADD również wykazują dobrą jakość dopasowania, chociaż w modelu ADD/CON LAGS widoczne są pewne odchylenia w końcowym okresie analizy. Test Shapiro-Wilka potwierdził normalność rozkładu reszt



Rysunek 2.41: Wykresy reszt dla $t = 5$ na okresie 1950 – 2000

dla wszystkich modeli przy $t = 10$, co wskazuje na wysoką jakość ich predykcji.

Te wyniki podkreślają, że wydłużenie t poprawia jakość prognoz modeli w latach 1950 – 2000, szczególnie w przypadku modeli MULT. Modele te są bardziej efektywne w uwzględnianiu długoterminowych zależności w systemie międzynarodowym, podczas gdy modele ADD wykazują większe problemy z dokładnością predykcji w krótszych okresach.

Rysunek 2.42: Wykresy reszt dla $t = 10$ na okresie 1950 – 2000

Normalność rozkładu reszt dla $t = 10$ wskazuje, że modele te są dobrze skalibrowane i mogą być wiarygodnym narzędziem w analizie konfliktów zbrojnych.

Podsumowanie

Podsumowanie wyników dla modeli trenowanych na danych historycznych (1820–1960, 1820–1890, 1890–1960). Analiza modeli trenowanych na danych historycznych wykazała istotne różnice w skuteczności prognozowania w zależności od wartości t oraz okresu, na którym uczone modele.

Modele ADD osiągały generalnie lepsze wyniki niż modele MULT. Było to widoczne zarówno w niższych wartościach średniego błędu bezwzględnego (MAE) i błędu średniokwadratowego (MSE), jak i w bardziej stabilnych prognozach, które były bliższe rzeczywistym wartośćom zmiennej WAR . Modele MULT, szczególnie dla $t = 5$ i $t = 10$, wykazywały znaczące odchylenia od rzeczywistych wartości, co wynikało z ich podatności na niestabilności przy ograniczonej liczbie danych. W okresie 1820 – 1890 modele MULT generowały wartości przewidywane, które wielokrotnie przewyższały rzeczywiste poziomy WAR , czyniąc je w praktyce nieprzydatnymi.

Analiza reszt i testy Shapiro-Wilka wykazały, że normalność reszt była spełniona głównie w modelach ADD, co podkreśla ich lepszą jakość predykcji. Modele MULT, w większości przypadków, nie spełniały tego kryterium, co wskazuje na obecność błędów systematycznych. Wyniki te sugerują, że modele ADD są bardziej odpowiednie do długoterminowego prognozowania konfliktów zbrojnych na podstawie danych historycznych, szczególnie w sytuacjach, gdy dane są ograniczone.

Podsumowanie wyników dla modeli trenowanych na danych z lat 1950 – 2000. Analiza modeli trenowanych na danych z okresu 1950 – 2000 potwierdziła wyższą skuteczność modeli uczonych na współczesnych danych w porównaniu do modeli opartych na danych historycznych.

Modele MULT, szczególnie dla $t = 10$, osiągnęły niemal perfekcyjne dopasowanie, co było widoczne zarówno na wykresach prognoz, jak i rzeczywistych wartości, jak i w bardzo niskich wartościach MAE i MSE. MULT/CON LAGS przy $t = 10$ wykazał niemal zerowe błędy ($MAE = 0.05$, $MSE = 0.00$), co wskazuje na idealne odwzorowanie rzeczywistych wartości WAR . Modele ADD również osiągnęły dobre wyniki, choć dla niektórych przypadków (np. ADD/CON LAGS) błędy były większe, zwłaszcza w długim okresie.

Analiza reszt wskazała, że dla $t = 10$ reszty miały rozkład normalny we wszystkich modelach, co potwierdziły testy Shapiro-Wilka. Dla $t = 5$ normalność rozkładu reszt była obecna jedynie w modelach MULT, natomiast dla $t = 1$ żaden z modeli nie spełniał tego kryterium. Wyniki te sugerują, że wydłużenie horyzontu czasowego t pozwala na uzyskanie bardziej stabilnych i przewidywalnych wyników.

Podsumowanie

W niniejszej pracy przeprowadzono szczegółową analizę modelu J. Davida Singera, obejmując zarówno replikację badań autora, jak i własne modyfikacje oraz rozwinięcia modelu. Celem była ocena jego skuteczności w kontekście współczesnych danych i zmian w metodologii.

Pierwszy rozdział analizy empirycznej (2.1) skupił się na zastosowaniu klasycznego modelu Singera przy założeniu $t = 5$, obejmując trzy okresy historyczne: 1820 – 1960, 1820 – 1890 oraz 1890 – 1960. Wyniki tej analizy wykazały różnice w porównaniu z oryginalnymi wynikami Singera, co może być związane ze zmianami w jakości i zakresie danych na przestrzeni ostatnich pięćdziesięciu lat. Na przykład, w analizach Singera modele ADD były dominujące, podczas gdy w niniejszym badaniu model MULT/CON LAGS wykazał się większą skutecznością. Różnice te mogą wynikać z rozwoju metod zbierania danych, zwiększenia dostępności informacji dla większej liczby państw oraz subiektywności w ocenie historycznych konfliktów. Fakt ten uwypukla kluczowe wyzwanie w badaniach historycznych – perspektywa czasowa wpływa na obiektywność interpretacji. Dlatego w zbiorze War Data Set dane nie obejmują lat po 2003 roku, ponieważ potrzeba co najmniej dwóch dekad, aby oceny mogły nabrać większej obiektywności.

Drugi rozdział (2.2) dotyczył analizy wpływu zmiany parametru t na wyniki modeli. Przy $t = 1$ oraz $t = 10$ zidentyfikowano różne wzorce wpływu zmiennych CON , ΔCON i $MOVE$ na zmienną zależną WAR . Na przykład, analiza dwuwymiarowa dla okresu 1820 – 1960 wykazała, że zmienna CON miała znaczący negatywny wpływ na prawdopodobieństwo konfliktów, co może odzwierciedlać historyczną dynamikę władzy międzynarodowej, w której stabilność polityczna była bardziej przewidywalna w czasach wysokiej koncentracji mocy. W tym samym okresie najlepszą skuteczność w analizie dwuwymiarowej ma model MULT/CON LAGS przy $t = 5$, zmienne CON i ΔCON odgrywały kluczową rolę, co można wiązać z okresami intensywnej zmiany układów sił międzynarodowych.

W okresie 1820 – 1890 najwyższą skuteczność miał model MULT/CON LEADS przy $t = 10$, zmienna ΔCON odgrywała kluczową rolę, co może wynikać z relatywnie powolnych zmian w układach międzynarodowych w XIX wieku. Natomiast dla lat 1890 – 1960 dominował model MULT/CON LEADS przy $t = 5$, wskazując na bardziej dynamiczną redystrybucję mocy (CON) w tym okresie, związanym z gwałtownymi konfliktami światowymi i powstawaniem nowych porządków międzynarodowych.

Modele ADD charakteryzowały się wyraźnymi reakcjami na zmiany zmiennych predyktorów, co sprawiało, że dobrze odzwierciedlały trendy krótkoterminowe. Z kolei modele MULT, ignorując intensywne konflikty, lepiej przewidywały stabilne okresy. Podobnie, modele LAGS i LEADS różniły się w zdolności przewidywania w zależności od dynamiki przeszłych i przyszłych zmian układów sił.

W rozdziale 2.3 porównanie modeli trenowanych na danych historycznych oraz współczesnych wskazuje na istotne różnice w ich skuteczności prognozowania. Modele uczone na danych historycznych charakteryzowały się większymi błędami i mniejszą stabilnością, co

szczególnie dotyczyło modeli MULT. W przypadku modeli trenowanych na danych z lat 1950 – 2000 wyraźnie zauważalna była ich wyższa jakość predykcji, co wynikało z lepszej reprezentatywności danych dla analizowanego okresu.

Wyniki te podkreślają znaczenie wykorzystania współczesnych danych w prognozowaniu konfliktów zbrojnych. Modele ADD są bardziej stabilne i lepiej sprawdzają się w sytuacjach, gdy dostępna liczba danych jest ograniczona. Z kolei modele MULT, choć bardziej podatne na niestabilności w warunkach ograniczonych danych, okazały się wysoce skuteczne, gdy trenowano je na pełnym zakresie dostępnych danych dla lat 1950–2000.

Wyniki niniejszej pracy podkreślają znaczenie dalszego rozwijania metodologii Singera, a także potrzebę kontynuacji projektu Correlates of War, który stanowi fundamentalne źródło wiedzy o dynamice konfliktów zbrojnych. Dzięki systematycznemu gromadzeniu danych oraz ich ciągłej analizie możliwe jest tworzenie modeli, które nie tylko będą odwzorowywać dynamikę konfliktów międzynarodowych, ale także przyczynią się do ich lepszego zrozumienia i zapobiegania.

Badania te wskazały również na pewne ograniczenia i wyzwania. Przy krótkich interwałach czasowych ($t = 1$) zmienne nie oddawały w pełni zmian koncentracji (ΔCON) w systemie międzynarodowym, co ograniczało ich skuteczność. Jednocześnie interwały $t = 10$, choć obiecujące, wymagałyby większej liczby danych, aby mogły być w pełni wykorzystane. Te wyzwania jednak nie osłabiają wartości modelu Singera, lecz pokazują, że musi on ewoluować, by sprostać nowym wymaganiom badawczym i wyzwaniom współczesnego świata. Kontynuowanie tych badań jest także kluczowym krokiem w kierunku skuteczniejszego prognozowania i ograniczania konfliktów zbrojnych w przyszłości.

Dodatek

Tabela 2.25: Wyniki obliczeń statystyk opisowych zmiennych modelu w analizie J. D. Singera

Zmienna	Wartość oczekiwana	Odchylenie standardowe	Max	Min	Medianą
1820 – 1960					
<i>WAR</i>	15.36	32.33	123.97	0.0	3.92
<i>CON</i>	0.250	0.0504	0.417	0.202	0.237
ΔCON	-0.0007	0.0105	0.0250	-0.0310	-0.0012
<i>MOVE</i>	0.0096	0.0062	0.0282	0.0018	0.0071
1820 – 1890					
<i>WAR</i>	5.94	6.08	17.24	0.0	4.48
<i>CON</i>	0.244	0.0201	0.280	0.208	0.242
ΔCON	-0.0005	0.0028	0.0050	-0.0049	-0.0004
<i>MOVE</i>	0.0058	0.0026	0.0123	0.0028	0.0050
1890 – 1960					
<i>WAR</i>	24.78	44.07	123.97	0.0	6.08
<i>CON</i>	0.257	0.0692	0.417	0.202	0.226
ΔCON	-0.0009	0.0149	0.0250	-0.0310	-0.0014
<i>MOVE</i>	0.0113	0.0086	0.0245	0.0037	0.0113

Źródło: *Capability Distribution, Uncertainty and Major Power War, 1820 – 1965.* by J. D. Singer

Tabela 2.26: Wyniki obliczeń korelacji zmiennych niezależnych z prawdopodobieństwem wystąpienia wojny w analizie J. D. Singera

Wskaźnik	1820 – 1960		1820 – 1890		1890 – 1960	
	R	R^2	R	R^2	R	R^2
CON_{t_0}	-0.10	0.01	0.81	0.66	-0.23	0.05
$\Delta CON_{t_0 \rightarrow t_1}$	-0.38	0.14	0.19	0.04	-0.41	0.17
$MOVE_{t_0 \rightarrow t_1}$	0.34	0.12	-0.01	0.00	0.24	0.06

Źródło: *Capability Distribution, Uncertainty and Major Power War, 1820 – 1965.* by J. D. Singer

Tabela 2.27: Wyniki ewaluacji standaryzowanych modeli w analizie J. D. Singera

Model	MULTIPLES			CON		ΔCON		MOVE	
	R	R^2	\bar{R}	b	r^2	b	r^2	b	r^2
1820 – 1960									
ADD / CON LEADS	0.56	0.31	0.23	-0.28	0.04	-0.61	0.20	0.45	0.20
ADD / CON LAGS	0.55	0.30	0.22	-0.18	0.02	-0.33	0.11	0.46	0.18
MULT / CON LEADS	0.43	0.19	0.09	-0.27	0.04	-0.57	0.15	0.21	0.04
MULT / CON LAGS	0.43	0.18	0.08	-0.22	0.03	-0.28	0.07	0.24	0.05
1820 – 1890									
ADD / CON LEADS	0.85	0.73	0.65	0.85	0.72	0.29	0.19	-0.38	0.00
ADD / CON LAGS	0.85	0.73	0.65	0.96	0.71	-0.31	0.17	-0.39	0.00
MULT / CON LEADS	0.72	0.52	0.38	0.73	0.52	0.16	0.04	-0.18	0.01
MULT / CON LAGS	0.72	0.52	0.38	0.83	0.50	-0.35	0.13	-0.18	0.01
1890 – 1960									
ADD / CON LEADS	0.59	0.35	0.15	-0.50	0.12	-0.85	0.29	0.44	0.19
ADD / CON LAGS	0.56	0.31	0.10	-0.38	0.07	-0.32	0.10	0.45	0.17
MULT / CON LEADS	0.68	0.46	0.30	-0.81	0.41	-1.11	0.46	0.37	0.18
MULT / CON LAGS	0.64	0.41	0.23	-0.58	0.24	-0.24	0.07	0.42	0.18

Źródło: *Capability Distribution, Uncertainty and Major Power War, 1820 – 1965.* by J. D. Singer

Bibliografia

- [1] CORRELATES OF WAR PROJECT. „State System Membership List, v2016”. <http://correlatesofwar.org>, 2017. Accessed: 2025-01-10.
- [2] HUMPHREYS, M. Natural resources, conflict, and conflict resolution: Uncovering the mechanisms. *Journal of conflict resolution* 49, 4 (2005), 508–537.
- [3] LEAR, J. B., MACAULAY, D., SARKEES, M. R. Escalation and control in international conflict: A simple feedback model 4. In *Advancing Peace Research*. Routledge, 2012, pp. 69–82.
- [4] MAGIERA, R. *Modele i metody statystyki matematycznej: Wnioskowanie statystyczne*. Oficyna Wydawnicza GiS, 2018.
- [5] SARKEES, M. R., WAYMAN, F. *Resort to War: 1816 – 2007*. CQ Press, Washington DC, 2010.
- [6] SINGER, J. D. Inter-nation influence: a formal model. *American Political Science Review* 57, 2 (1963), 420–430.
- [7] SINGER, J. D. Variables, indicators, and data: The measurement problem in macro-political research. *Social Science History* 6, 2 (1982), 181–217.
- [8] SINGER, J. D. Reconstructing the correlates of war dataset on material capabilities of states, 1816–1985. *International Interactions* 14, 2 (1988), 115–132.
- [9] SINGER, J. D. *Advancing Peace Research: Leaving Traces, Selected Articles*. Routledge, 2 Park Square, Milton Park, Abingdon, Oxon, OX14 4RN, 2012.
- [10] SINGER, J. D., BREMER, S. A., STUCKEY, J. Capability distribution, uncertainty, and major power war, 1820–1965 1. In *Peace, War and Numbers*. Sage Publ., 1972, pp. 19–48.